



République Algérienne Démocratique et
Populaire
Ministère de l'Enseignement Supérieur et
de la Recherche Scientifique



Université des Sciences et de la Technologie Houari Boumediene
Faculté d'Informatique
Département ...
Mémoire de Master
Spécialité : Informatique Visuelle

Vers la construction d'un jumeau numérique du poumon pour des applications médicales

Organisme d'accueil : Centre de Recherche sur l'Information Scientifique et Technique
(CERIST)

Sujet proposé par :
Mme HADJADJ Zineb

Présenté par :
BABOUCHE Amina Houria
DADDI ADDOUN Yousra

Projet : IV-17 / 2026

Remerciements

Houria

Je voudrais saisir cette occasion pour exprimer ma plus sincère gratitude à mon Dieu tout-puissant, loué soit-il.

Je voudrais remercier Madame HADJADJ pour ses précieux conseils et son aide et son soutien constants tout au long du projet, ainsi que les membres du jury pour nous avoir donné l'occasion de présenter notre travail.

Un remerciement spécial à ma mère, mon père et mes chers frères, ainsi que ma merveilleuse belle-sœur, les mots ne peuvent pas exprimer à quel point je me sens béni de vous avoir à mes côtés, votre présence et votre soutien constants sont ce qui m'a permis d'arriver là où je suis aujourd'hui, après l'aide et les bénédictions d'Allah, bien sûr.

Enfin, je voudrais remercier ma chère Binôme Yousra pour son travail acharné, son sérieux et sa compréhension, et je lui souhaite sincèrement la meilleure des chances.

Yousra

Je tiens tout d'abord à remercier Allah pour la force, la patience et la persévérance qu'Il m'a accordées tout au long de ce parcours.

Mes sincères remerciements s'adressent à notre promotrice, Mme Hadjaj, pour son accompagnement, sa disponibilité et ses précieux conseils qui ont grandement contribué à la réalisation de ce travail.

Je remercie également les membres du jury d'avoir accepté d'évaluer ce mémoire et de lui consacrer leur temps.

J'adresse une profonde gratitude à mes parents pour leur soutien indéfectible, leurs encouragements et tous les sacrifices qu'ils ont consentis pour me permettre d'atteindre mes objectifs.

Mes remerciements vont également à ma sœur et à mon frère pour leur présence, leur soutien et leurs encouragements tout au long de mon parcours.

Je remercie chaleureusement toute ma famille ainsi que mes amis pour leur aide, leur confiance et les nombreux moments de soutien qu'ils m'ont apportés.

Enfin, je tiens à remercier ma binôme, Houhou, pour son sérieux, son efficacité et son engagement tout au long de ce projet. Je n'aurais pas pu souhaiter une meilleure binôme pour partager cette expérience et mener ce travail à son terme.

Résumé

La modélisation numérique des organes constitue un enjeu croissant en médecine computationnelle, notamment pour la simulation de la mécanique respiratoire. Cependant, le développement de jumeaux numériques pulmonaires réalistes se heurte à des défis majeurs liés à la disponibilité des données, à la segmentation automatique et à la préparation de modèles compatibles avec l'analyse par éléments finis.

Ce mémoire présente la conception et l'implémentation d'un jumeau numérique du poumon humain, développé à partir de données d'imagerie médicale en libre accès, couvrant l'ensemble du pipeline allant de l'acquisition des images jusqu'à la préparation pour la simulation fonctionnelle.

La source de données principale est le dataset LIDC-IDRI, un ensemble d'images CT-scanner disponibles publiquement. En l'absence de masques pulmonaires dans ce dataset, un dataset de segmentation a été constitué à l'aide de techniques classiques de traitement d'images biomédicales. Un modèle de deep learning basé sur l'architecture U-Net 2D a ensuite été développé pour une segmentation robuste, en y apportant des améliorations au niveau de l'augmentation de données, de la régularisation et de la fonction de perte.

Les données segmentées ont servi à la reconstruction 3D de la surface pulmonaire via l'algorithme Marching Cubes, suivie d'un post-traitement incluant le lissage de Taubin, la suppression de la trachée, la séparation des deux poumons et la décimation du maillage surfacique.

Le modèle surfacique obtenu a ensuite été préparé pour l'analyse par éléments finis grâce à un maillage volumique généré avec la bibliothèque Gmsh, avec une réduction tétraédrique pour alléger le modèle tout en respectant les normes FEM.

En contribution additionnelle, une simulation cinématique expérimentale a été mise en œuvre à partir d'estimations heuristiques basées sur des normes physiologiques populationnelles. Sa validation repose sur le suivi des déplacements du diaphragme et la vérification que les volumes courants produits se situent dans les plages cliniquement attendues.

Abstract

Numerical modelling of organs is a growing challenge in computational medicine, particularly for simulating respiratory mechanics. However, the development of realistic pulmonary digital twins faces major challenges related to data availability, automatic segmentation, and the preparation of models compatible with finite element analysis.

This thesis presents the design and implementation of a digital twin of the human lung, developed from open-access medical imaging data. The work follows a complete pipeline, from raw image acquisition to functional simulation readiness.

The primary data source is the LIDC-IDRI dataset, a publicly available CT scan repository. Since the dataset does not include lung masks, a segmentation dataset was constructed using classical bio-imaging techniques. A 2D U-Net deep learning model was then developed for robust lung segmentation, built upon the baseline U-Net architecture and enhanced through improved data augmentation strategies, regularization techniques, and a custom loss function.

The segmented data was subsequently used for 3D surface reconstruction via the Marching Cubes algorithm. Post-processing steps included Taubin smoothing, trachea removal, left-right lung separation, and surface mesh decimation to reduce vertex count.

The resulting surface model was then prepared for finite element analysis through volumetric meshing using the Gmsh library, with tetrahedral mesh coarsening applied to reduce computational load while remaining compliant with FEM standards.

As an additional contribution, an experimental kinematic simulation was implemented using heuristic estimation based on population-derived physiological norms. The simulation was validated by tracking diaphragm displacement patterns and confirming that the tidal volumes produced fall within clinically expected ranges.

Table des matières

Table des figures	6
Liste des tableaux	8
1 Introduction	1
Introduction	1
1.1 Contexte et motivation	1
1.2 Problématique et objectifs	1
1.3 Organisation du mémoire	2
2 État de l’art et bases théoriques	4
2.1 Introduction	4
2.2 Anatomie pulmonaire et imagerie CT	4
2.2.1 Propriétés anatomiques des poumons	4
2.2.2 Principes physiques de l’imagerie CT	6
2.2.3 Le format NIfTI pour les volumes CT	8
2.3 Segmentation pulmonaire : méthodes classiques et approches basées sur l’intelligence artificielle	8
2.3.1 Méthodes de segmentation classiques	8
2.3.2 Apport de l’apprentissage profond	11
2.4 Réseaux de neurones convolutionnels et architecture U-Net	11
2.4.1 Principes des réseaux convolutionnels	11
2.4.2 L’architecture U-Net	12
2.4.3 Variantes architecturales et segmentation volumétrique	13
2.4.4 Stratégies de génération des annotations face à la pénurie de données	15
2.5 Recosntruction 3D surfacique	16
2.5.1 Principe de fonctionnement	16
2.5.2 Variantes et améliorations	17
2.6 Reconstruction volumique	17
2.6.1 Décomposition topologique des maillages surfaciques	18
2.6.2 Représentation géométrique : la Boundary Representation	19
2.6.3 Algorithmes de génération de maillages volumiques tétraédriques	20
2.6.4 Optimisation de la qualité des maillages	21
2.6.5 Critères de qualité pour la simulation par éléments finis	22
2.7 Simulation des mouvements respiratoires	23
2.7.1 Modèles de mouvements respiratoires	23
2.8 Jumeau numérique : définitions et applications médicales	24
2.8.1 Fondements théoriques et architecture du Jumeau Numérique	24

2.8.2	Échelles et domaines d'application en santé :	24
2.9	Conclusion	24
3	Méthode proposée	26
3.1	Introduction	26
3.2	Traitement des données	26
3.2.1	Dataset LIDC-IDRI	26
3.2.2	Dataset LUNA16	26
3.2.3	Ensemble de données annotées par des radiologues	27
3.2.4	Format des données	27
3.2.5	Filtrage et Prétraitement des données	28
3.2.6	Génération des masques	28
3.2.7	Rééchantillonnage Isotropique	31
3.2.8	Écrêtage HU et Normalisation d'Intensité	31
3.3	Segmentation pulmonaire	31
3.3.1	Le réseau U-Net 2D	31
3.3.2	Gestion des données	32
3.3.3	Augmentation des données	32
3.3.4	Architecture et apprentissage	33
3.3.5	Fonction de perte	33
3.3.6	Métriques d'évaluation	34
3.4	Reconstruction 3D surfacique	34
3.4.1	Aperçu du pipeline	35
3.4.2	Préparation des données et gestion de l'espace métrique	36
3.4.3	Nettoyage anatomique : suppression de la trachée	36
3.4.4	Extraction de la surface par l'algorithme des Marching Cubes	40
3.4.5	Lissage par filtre de Taubin	40
3.4.6	Simplification polygonale par décimation quadrique (QEM)	41
3.5	Reconstruction volumique	42
3.5.1	Extraction des composantes connexes	42
3.5.2	Identification anatomique par centroïde	43
3.5.3	Préparation topologique et représentation géométrique	44
3.5.4	Algorithme de génération volumétrique	44
3.5.5	Optimisation du maillage.	46
3.5.6	Validation du maillage volumique par critères FEM	46
3.6	Simulation respiratoire pulmonaire	48
3.6.1	Paramètres de déplacement	48
3.6.2	Fonction de pondération	49
3.6.3	Courbe respiratoire	50
3.6.4	Conclusion	50
4	Résultats et discussion	52
4.1	Introduction	52
4.2	Environnement de travail et outils utilisés	52
4.2.1	Ressources matérielles	52
4.2.2	Ressources logicielles	53
4.2.3	Développement	53
4.3	Paramètres d'entraînement	53

4.4	Résultats de la méthode de segmentation proposée	54
4.5	Validation de la méthode de segmentation proposée	56
4.5.1	Validation sur LUNA16	56
4.5.2	Validation externe sur l'ensemble de données annoté par des radio- logues	58
4.5.3	Analyse comparative avec d'autres méthodes	59
4.6	Résultats de la reconstruction 3D surfacique	60
4.6.1	Sélection du patient et préparation des données	60
4.6.2	Inférence U-Net et reconstruction surfacique	61
4.6.3	Nettoyage anatomique et suppression de la trachée	61
4.6.4	Extraction de la surface par Marching Cubes et lissage de Taubin	63
4.6.5	Simplification géométrique par décimation quadrique (QEM)	65
4.6.6	Évaluation quantitative de la fidélité géométrique	66
4.6.7	Synthèse et validation globale du patient LIDC-IDRI-0370	67
4.6.8	Généralisation à l'ensemble des patients	67
4.7	Résultats et analyse de la reconstruction volumique	69
4.7.1	Séparation anatomique gauche/droite du patient LIDC-IDRI-0370	69
4.7.2	Généralisation de la séparation anatomique	70
4.7.3	Génération des maillages volumiques tétraédriques du patient LIDC- IDRI-0370	70
4.7.4	Validation par critères FEM médicaux du patient LIDC-IDRI-0370	71
4.7.5	Validation FEM et comparaison multi-patients	72
4.8	Résultats de la simulation	73
4.8.1	Matériaux et méthodes	73
4.8.2	Analyse qualitative	74
4.8.3	Analyse quantitative	74
4.9	Conclusion	77
	Conclusion générale	78
	Bibliographie	80

Table des figures

2.1	Schéma illustrant l'anatomie des poumons et leur organisation dans le thorax [1]	5
2.2	Schéma illustrant le déplacement du diaphragme durant l'inspiration et l'expiration [2]	6
2.3	Image CT [3].	7
2.4	Représentation d'un scanner CT [4].	7
2.5	Architecture du réseau U-Net, composée d'un encodeur (chemin de contrac- tion), d'un goulot d'étranglement et d'un décodeur (chemin d'expansion) reliés par des connexions sautées [5]	13

2.6	Les 15 configurations uniques du Marching Cubes [6]	17
3.1	Diagramme illustratif résumant le pipeline de génération de masques mis en œuvre à l'aide de techniques classiques de bio-imagerie	29
3.2	Pipeline de reconstruction 3D surfacique : des logits U-Net au maillage pulmonaire final (.stl).	35
3.3	Pipeline de nettoyage anatomique : suppression de la trachée et séparation des poumons.	37
3.4	Visualisation anatomique et radiologique de la trachée.	38
3.5	Illustration de la fonction de pondération $w(z)$ appliquée au maillage pulmonaire. En dessous, le poids croît linéairement de 0 à 1 jusqu'à la base du diaphragme, où le déplacement est maximal (condition aux limites DBC).	50
4.1	Un graphique illustrant la courbe de perte d'apprentissage et de validation tout au long de l'apprentissage	54
4.2	Un graphique présentant les scores Dice globaux pour l'entraînement et la validation, ainsi que les scores Dice uniquement des coupes avec des poumons tout au long de l'entraînement	54
4.3	Un graphique illustrant les scores de Jaccard (IoU) pour l'entraînement et la validation tout au long de la phase d'entraînement	55
4.4	Un graphique illustrant les scores de sensibilité et de spécificité obtenus tout au long de la phase d'apprentissage	55
4.5	Une illustration présentant les résultats de validation sur un patient à partir de LUNA16, avec un score DICE de 0,97 ; les zones vertes représentent le chevauchement entre le masque original et le masque prédit, les zones rouges correspondent aux faux positifs et les zones bleues aux faux négatifs	57
4.6	Résultats du test de validation de l'Unet sur le dataset LUNA16 d'un cas d'échec avec un dice=0.63, les zones vertes représentent le chevauchement entre le masque original et le masque prédit, les zones rouges correspondent aux faux positifs et les zones bleues aux faux négatifs	57
4.7	Une illustration présentant les résultats de validation sur un patient à partir de dataset des 20 patients, avec un score DICE de 0,96 ; les zones vertes représentent le chevauchement entre le masque original et le masque prédit, les zones rouges correspondent aux faux positifs et les zones bleues aux faux négatifs	58
4.8	Résultats du test de validation de l'Unet sur le dataset de 20 patients d'un cas d'échec avec un dice=0.89, les zones vertes représentent le chevauchement entre le masque original et le masque prédit, les zones rouges correspondent aux faux positifs et les zones bleues aux faux négatifs	59
4.9	Trachée détectée (zone centrale) sur le volume brut du patient LIDC-IDRI-0370.	62
4.10	Maillage pulmonaire après suppression de la trachée	62
4.11	Maillage avec faces colorées avant lissage : l'effet d'escalier lié à la discrétisation voxel est clairement visible sur le flanc du volume.	64
4.12	Reconstruction après lissage de Taubin - patient LIDC-IDRI-0370.	65
4.13	Maillage avant décimation QEM : 743 696 faces.	66
4.14	Maillage après décimation QEM : 60 000 faces.	66
4.15	Reconstruction volumique du patient LIDC-IDRI-0370.	71

4.16	Images illustrant la déformation pulmonaire au cours d'un cycle respiratoire : T1 (fin de l'expiration) et T2 (fin de l'inspiration).	75
4.17	Images illustrant la déformation pulmonaire au cours d'un cycle respiratoire : T1 (fin de l'expiration) et T2 (fin de l'inspiration) ; variation vue sous un angle différent, mettant en évidence les mouvements latéraux et ventraux.	75

Liste des tableaux

4.1	Métriques d'évaluation du meilleur checkpoint de validation.	55
4.2	Métriques d'évaluation sur l'ensemble de test (validation interne).	56
4.3	Résultats détaillés de la validation sur la base de données LUNA16.	56
4.4	Un tableau présentant les résultats de la validation sur l'ensemble de données des 20 patients	58
4.5	Métrique de performance de divers algorithmes flous pour la segmentation pulmonaire sur l'ensemble de données LUNA16, tirées de l'article de recherche de Hong, L., et al. [7]	59
4.6	Tableau comparatif des performances des modèles récents de segmentation pulmonaire [8]	60
4.7	Caractéristiques du maillage brut de segmentation U-Net pour le patient LIDC-IDRI-0370.	61
4.8	Impact quantifié de la suppression de la trachée pour le patient LIDC-IDRI-0370.	63
4.9	Caractéristiques du maillage après Marching Cubes (avant lissage) pour le patient LIDC-IDRI-0370.	63
4.10	Impact du lissage de Taubin : conservation de la topologie et amélioration de la régularité de surface.	64
4.11	Comparaison géométrique avant et après décimation QEM pour le patient LIDC-IDRI-0370.	65
4.12	Métriques de fidélité géométrique après décimation QEM pour le patient LIDC-IDRI-0370.	66
4.13	Résumé des transformations géométriques du pipeline pour le patient LIDC-IDRI-0370.	67
4.14	Synthèse du pipeline de reconstruction surfacique pour quatre patients (LIDC-IDRI-0164, 0072, 0469, 0370).	68
4.15	Caractéristiques des maillages surfaciques après séparation des poumons gauche et droit pour le patient LIDC-IDRI-0370.	69
4.16	Résultats de la séparation anatomique des poumons gauche et droit pour les quatre patients étudiés.	70
4.17	Caractéristiques structurelles des maillages volumiques tétraédriques pour le patient LIDC-IDRI-0370.	70
4.18	Métriques de validation par analyse éléments finis (FEM) des maillages volumiques du patient LIDC-IDRI-0370.	71

4.19 Métriques de validation FEM pour les huit poumons des quatre patients étudiés (D = droit, G = gauche).	72
4.20 Conformité des huit maillages pulmonaires aux critères de qualité FEM rapportés dans la littérature.	72
4.21 Déplacement du diaphragme pendant la respiration tidale pour plusieurs patients, avec une estimation SI de 13 % de la hauteur pulmonaire.	75
4.22 Volume courant (VT) pour plusieurs patients (fourchette cible : 400–500 ml).	76
4.23 Paramètres quantitatifs sur 7 cycles respiratoires consécutifs patient 100.	76

Liste des équations

2.2 Convolution discrète 2D	11
2.3 Fonction ReLU	11
2.4 Fonction sigmoïde	11
3.1 Combo Loss	33
3.2 Dice score	34
3.3 Jaccard score (IoU)	34
3.4 Sensibilité	34
3.5 Spécificité	34
3.8 Distance de Hausdorff au 95 ^e percentile (HD95)	41
3.9 Distance surfacique moyenne symétrique (MSD)	42
3.10 Calcul du centroïde d'une composante maillée	43
3.13 Calcul du volume d'un élément tétraédrique	46
3.14 Calcul de l'erreur volumique relative	47
3.15 Calcul du facteur de forme (Aspect Ratio)	47
3.16 Calcul du rayon de la sphère inscrite d'un tétraèdre	47
3.17 Calcul du volume normalisé d'un tétraèdre	48
3.18 Fonction de pondération linear de déplacement	49

Chapitre 1

Introduction

1.1 Contexte et motivation

L'évolution des pratiques cliniques s'appuie de plus en plus sur la personnalisation des soins. Dans ce cadre, le concept de jumeau numérique s'impose comme une approche prometteuse. Appliqué au domaine médical, il permet de créer une réplique virtuelle d'un organe ou d'un système biologique afin de simuler son comportement, d'optimiser une intervention chirurgicale ou de prédire l'efficacité d'un traitement.

Le poumon, de par sa complexité structurelle et sa dynamique fonctionnelle, constitue un sujet d'étude majeur pour la modélisation. La Tomodensitométrie (CT scan) est aujourd'hui l'examen de référence pour l'imagerie thoracique, fournissant des coupes transversales détaillées du parenchyme. Cependant, l'exploitation de ces données brutes pour la simulation numérique nécessite une chaîne de traitement complexe : de l'acquisition des données à la reconstruction d'un modèle 3D exploitable.

Notre travail de master s'inscrit dans le cadre d'un projet du Centre de Recherche sur l'Information Scientifique et Technique (CERIST) intitulé : “ Intégration de l'imagerie médicale et de l'intelligence artificielle pour le développement d'un jumeau numérique ”. Le projet vise à développer des approches basées sur l'intelligence artificielle et l'imagerie médicale afin de contribuer à la conception de jumeaux numériques pour des applications biomédicales et cliniques.

1.2 Problématique et objectifs

La genèse d'un jumeau numérique pulmonaire fiable ne se résume pas à une assistance logicielle ; elle se heurte à des verrous scientifiques et techniques où la précision du modèle est intrinsèquement liée à la qualité de l'extraction d'informations. Le passage de la donnée brute au modèle géométrique est ainsi limité par trois obstacles majeurs :

- **L'hétérogénéité anatomique inter-patients** : La morphologie bronchique, la segmentation lobaire et les volumes varient de façon significative selon l'âge, le sexe ou les antécédents pathologiques. Cette variabilité proscrit l'usage de modèles statistiques rigides et impose le développement de solutions de segmentation hautement adaptatives.
- **La dégradation du signal et les artefacts d'imagerie** : La capture de l'organe est soumise aux bruits de mesure et, surtout, aux artefacts de mouvement liés au cycle respiratoire et aux battements cardiaques. Ces phénomènes induisent un flou

cinétique et des effets de volume partiel qui altèrent la netteté des structures fines, compliquant la reconstruction des parois parenchymateuses.

- **L’ambiguïté des contrastes tissulaires :** La transition entre les tissus sains, les réseaux vasculaires denses et d’éventuelles zones pathologiques présente souvent des gradients de gris très faibles. La délimitation précise des frontières, particulièrement dans les zones hilaires (carrefour des vaisseaux et des bronches), constitue un défi critique pour garantir la topologie du modèle.

Afin de répondre à cette problématique, ce mémoire vise à développer une chaîne de traitement permettant de générer un modèle pulmonaire tridimensionnel exploitable dans le cadre d’un futur jumeau numérique. Les objectifs poursuivis sont les suivants :

- Mettre en place un pipeline de traitement des images CT thoraciques, depuis l’acquisition des données jusqu’à la reconstruction anatomique 3D.
- Développer et entraîner un modèle de segmentation basé sur l’architecture U-Net afin d’extraire automatiquement les poumons à partir des coupes tomodensitométriques.
- Reconstruire des maillages surfaciques et volumiques à partir des segmentations obtenues, tout en préservant la géométrie et la topologie des structures anatomiques.
- Évaluer la qualité des segmentations à l’aide de métriques quantitatives telles que le Dice Score et l’IoU.
- Vérifier la qualité géométrique et la conformité des maillages générés aux critères requis pour les simulations par éléments finis.
- Réaliser une première simulation numérique afin de valider l’exploitabilité des modèles reconstruits dans une perspective de jumeau numérique pulmonaire.

1.3 Organisation du mémoire

Le présent mémoire est structuré en quatre chapitres dont les contenus s’enchaînent de manière progressive, depuis les fondements théoriques jusqu’aux résultats obtenus et aux perspectives envisagées.

Le **Chapitre 2** pose les bases théoriques et bibliographiques indispensables à la compréhension du projet. Il couvre l’anatomie pulmonaire et les spécificités de l’imagerie CT, puis présente les différentes approches de segmentation, des méthodes classiques aux architectures d’apprentissage profond. Une attention particulière est portée aux réseaux de neurones convolutionnels et à l’architecture U-Net, devenue une référence en segmentation médicale. Enfin, le concept de jumeau numérique est présenté ainsi que ses principales applications dans le domaine médical.

Le **Chapitre 3** décrit en détail la méthodologie mise en œuvre pour construire le pipeline du jumeau numérique. Il expose successivement les étapes d’acquisition et de préparation des données CT, la mise en place et l’entraînement d’un réseau U-Net 2D pour la segmentation pulmonaire, puis les opérations de reconstruction anatomique 3D, notamment la génération, le nettoyage et la visualisation des maillages surfaciques et volumiques. Ce chapitre présente également la mise en place de la simulation numérique réalisée sur les maillages générés.

Le **Chapitre 4** présente et analyse les résultats obtenus à chaque étape du pipeline. Les performances de la segmentation sont évaluées à l’aide des métriques Dice et IoU, tandis que la qualité géométrique des reconstructions 3D est étudiée à travers différentes

mesures quantitatives. Les résultats de la simulation sont ensuite présentés et discutés afin d'évaluer le comportement du modèle numérique obtenu.

Le mémoire se conclut par une liste de références bibliographiques regroupant l'ensemble des travaux scientifiques, jeux de données et outils logiciels ayant contribué à ce projet.

Chapitre 2

État de l’art et bases théoriques

2.1 Introduction

Développer un jumeau numérique pulmonaire nécessite de combiner plusieurs domaines : l’anatomie, l’imagerie médicale et la vision par ordinateur. Il faut à la fois comprendre la structure de l’organe et la façon dont elle est représentée numériquement. Ce chapitre présente les bases théoriques et le contexte de notre travail. On y aborde le cadre anatomique et technique, les méthodes de segmentation et de reconstruction utilisées pour transformer une image brute en modèle numérique utilisable.

2.2 Anatomie pulmonaire et imagerie CT

L’étude de l’anatomie pulmonaire a considérablement évolué avec le développement des outils d’imagerie. Historiquement, les analyses des poumons reposaient d’abord sur des études cadavériques, puis sur l’imagerie 2D, réalisées par des spécialistes du domaine. Ces approches ont toutefois montré leurs limites. Les études cadavériques longtemps considérées comme la référence, sont notamment affectées par les modifications post-mortem et par l’impossibilité d’obtenir des données exploitables à grande échelle, ce qui réduit la fiabilité des observations.

Par la suite, les techniques d’imagerie 2D ont permis une meilleure représentation des structures pulmonaires chez le patient vivant et ont constitué un progrès important pour le diagnostic. Toutefois, elles restaient limitées par leur nature plane, ne permettant qu’une compréhension partielle des relations spatiales entre les différentes structures anatomiques, ce qui laisse une part d’ombre sur leur organisation et leur position relative dans le volume pulmonaire.

L’imagerie CT 3D a répondu à cette limitation en fournissant une représentation volumétrique complète de l’organe. Elle est aujourd’hui utilisée comme standard pour l’étude de l’anatomie interne du poumon, ainsi que pour améliorer la précision diagnostique et la sécurité des interventions chirurgicales [9].

2.2.1 Propriétés anatomiques des poumons

La structure anatomique des poumons constitue un prérequis essentiel à notre étude. Ces deux organes sont logés dans la cavité thoracique, de part et d’autre du médiastin, qui abrite le cœur, les gros vaisseaux, la trachée et l’œsophage. Chaque poumon est

enveloppé d'une double membrane pleurale [10]. Comme l'illustre la figure 2.1, le poumon droit se divise en trois lobes (supérieur, moyen et inférieur), contre deux pour le poumon gauche (supérieur et inférieur), asymétrie qui résulte de la place occupée par le cœur [10]. La trachée, voie aérienne principale descendant vers les poumons, se bifurque en deux bronches souches qui pénètrent chaque poumon au niveau du hile [10].




FIGURE 2.1 – Schéma illustrant l'anatomie des poumons et leur organisation dans le thorax [1]

Le poumon est un organe passif, ce qui signifie qu'il ne dispose pas de contrôle musculaire et n'exerce aucune force ; il subit plutôt l'influence des structures anatomiques environnantes, ce qui entraîne des mouvements respiratoires et des variations de volume [11]. Le comportement respiratoire du poumon repose sur deux opérations : l'inspiration et l'expiration ; lors de l'inspiration, le diaphragme, un muscle en forme de dôme situé entre le thorax et l'abdomen [12], se contracte et se déplace vers le bas, augmentant ainsi le diamètre vertical de la cavité thoracique et générant une pression négative dans l'espace pleural, appelée pression intrapleurale. Cette différence entre la pression à l'intérieur des poumons (pression alvéolaire) et la pression intrapleurale est appelée pression transpulmonaire [13], comme le montre la figure 2.2. Il présente généralement un mouvement restreint dans sa partie supérieure, située à l'intérieur de la cage thoracique, ce qui se traduit par un mouvement significativement réduit à son sommet par rapport à sa base [14], tandis que l'expansion la plus importante se produit à la base des poumons [15].




FIGURE 2.2 – Schéma illustrant le déplacement du diaphragme durant l'inspiration et l'expiration [2]

2.2.2 Principes physiques de l'imagerie CT

La tomodensitométrie (CT, *Computed Tomography*) est une modalité d'imagerie médicale qui emploie des rayons X et un traitement informatique pour générer des images détaillées de l'intérieur du corps humain [16]. Son principe repose sur la mesure de l'**atténuation** des rayons X le long d'une multitude de trajectoires dans un plan perpendiculaire à l'axe longitudinal du patient, afin de reconstruire une carte des coefficients d'atténuation linéaire pour ce plan [17].

L'examen CT se déroule en trois phases distinctes : l'acquisition des données, la reconstruction de l'image et l'affichage [16].

Acquisition : du tube aux détecteurs

Lors de la phase d'acquisition, le tube à rayons X et les détecteurs, montés sur le **statif** (anneau rotatif), tournent à 360° autour du patient allongé sur la table d'examen, comme on le voit dans la **Figure 2.3**. Le tube génère un faisceau étroit de rayons X dont l'intensité est contrôlée par la tension (kV) et le courant (mA) ; les détecteurs situés du côté opposé captent les photons transmis et les convertissent en courant électrique, traité ensuite par le système d'acquisition de données (DAS, *Data Acquisition System*) [16].

Les données de projection sont réorganisées sous forme de **sinogramme** : une représentation bidimensionnelle dans laquelle un axe correspond à l'angle de rotation du statif et l'autre à la position spatiale le long de la rangée de détecteurs [18]. Un sinogramme est donc une carte complète des projections en fonction de l'orientation du gantry [19].



FIGURE 2.3 – Image CT [3].

Reconstruction et Affichage : du sinogramme au volume 3D

À partir du sinogramme, des algorithmes de reconstruction restituent la distribution spatiale des coefficients d'atténuation [18]. Ces coefficients sont exprimés sur l'**échelle de Hounsfield** (HU, *Hounsfield Units*), normalisée de sorte que l'eau corresponde à 0 HU et que l'air corresponde à -1000 HU [17] :

$$HU = 1000 \times \frac{\mu - \mu_{\text{eau}}}{\mu_{\text{eau}} - \mu_{\text{air}}} \quad (2.1)$$

où μ désigne le coefficient d'atténuation linéaire du tissu considéré. Les structures denses (os : $+400$ à $+1000$ HU) apparaissent en blanc, les structures peu denses (graisse : -100 à -50 HU, air : -1000 HU) en noir [16]. La Figure 2.4 présente une coupe axiale thoracique typique, mettant en évidence la morphologie pulmonaire et le contraste marqué avec les tissus environnants.

Les coupes 2D reconstruites sont ensuite empilées pour former un **volume 3D**, permettant au clinicien de visualiser l'anatomie et d'identifier les anomalies [16].



FIGURE 2.4 – Représentation d'un scanner CT [4].

2.2.3 Le format NIfTI pour les volumes CT

Le format **NIfTI** (*Neuroimaging Informatics Technology Initiative*) est le standard de référence pour le stockage et l'échange de données volumétriques médicales (IRM, CT, TEP) [20, 21]. Il regroupe le volume en une structure unique composée de deux sections [22] :

- **L'en-tête (348 octets)** : contient les métadonnées critiques (dimensions $I \times J \times K$, résolution des voxels en mm, type de données et orientation spatiale).
- **Les données voxels** : une grille 3D brute où chaque unité encode une valeur scalaire (ex : Unités Hounsfield pour le CT). La taille totale est définie par $I \times J \times K \times S$ octets, avec S la précision par voxel.

En *Deep Learning*, le NIfTI centralise le pipeline de prétraitement. Les données issues du format DICOM y sont converties pour subir une standardisation rigoureuse : écrêtage des valeurs HU (windowing) et normalisation dans l'intervalle $[0, 255]$ ou $[0, 1]$ avant l'entraînement [23]. Cette approche garantit la reproductibilité des modèles et facilite la manipulation de volumes 3D complexes.

2.3 Segmentation pulmonaire : méthodes classiques et approches basées sur l'intelligence artificielle

La segmentation d'image, c'est le fait de diviser une image en zones distinctes selon ce qu'elles représentent ou leurs caractéristiques visuelles, pour pouvoir isoler ce qui nous intéresse. En imagerie médicale, c'est une étape qu'on ne peut pas contourner : sans elle, impossible de délimiter correctement un poumon, un foie ou une tumeur par rapport au tissu environnant, et donc impossible d'en extraire des mesures fiables ou de reconstruire un modèle 3D exploitable [24]. Pour segmenter une image, deux grandes familles de méthodes existent. Les approches classiques, d'abord, qui s'appuient sur des règles définies manuellement à partir de propriétés comme l'intensité ou le gradient. Puis les méthodes d'apprentissage profond, qui ont progressivement pris le dessus parce qu'elles s'adaptent aux données plutôt que de suivre des règles figées [25].

2.3.1 Méthodes de segmentation classiques

Jusqu'au début des années 2010, la segmentation pulmonaire reposait intégralement sur des algorithmes déterministes, construits autour d'hypothèses anatomiques explicites et d'opérations mathématiques appliquées aux niveaux de gris des images [25, 26].

Seuillage (thresholding)

Le seuillage est l'une des premières approches utilisées pour la segmentation pulmonaire en CT. Il exploite le contraste naturel entre le parenchyme pulmonaire, dont les valeurs d'atténuation se situent généralement entre -900 et -500 HU pour les zones normalement aérées, et les tissus mous environnants, dont la densité est supérieure à -100 HU [27]. En fixant un seuil dans cet intervalle, on obtient un masque binaire qui sépare le parenchyme pulmonaire du reste du volume.

La méthode d'Otsu automatise ce choix en maximisant la variance inter-classes entre les niveaux de gris des deux régions résultantes [25]. Elle fonctionne correctement sur des poumons sains, mais ses limites apparaissent dès qu'une pathologie modifie localement

la densité du tissu : une pneumonie, une fibrose ou une tumeur peuvent faire remonter l'atténuation de certaines zones au-delà du seuil fixé, qui se retrouvent alors exclues du masque bien qu'elles fassent partie du poumon. Pour pallier ce problème, des variantes adaptatives ont été proposées, calculant des seuils locaux selon la région considérée [25]. Néanmoins, le seuillage reste aujourd'hui principalement utilisé comme étape d'initialisation, combiné à des méthodes complémentaires pour corriger ses lacunes [24].

Croissance de région (region growing)

La croissance de région segmente l'image en regroupant progressivement des pixels voisins partageant des propriétés similaires, notamment en termes d'intensité ou de texture [25]. Le processus part de points initiaux appelés **graines** (*seeds*), placés manuellement ou automatiquement à l'intérieur de la structure cible. À chaque itération, les pixels adjacents dont les caractéristiques sont proches de celles de la région courante y sont intégrés, jusqu'à ce qu'aucun pixel voisin ne satisfasse le critère de similarité.

Cette méthode est bien adaptée aux structures homogènes comme le parenchyme pulmonaire sain, et a été largement utilisée dans les pipelines de segmentation pulmonaire [24] mais elle reste fortement dépendante du choix des graines et peut conduire à des erreurs de segmentation, notamment lorsque les frontières entre structures sont peu marquées [24].

Méthodes par contours et modèles déformables

Les approches basées sur les contours visent à détecter les frontières des structures anatomiques à partir des variations brusques d'intensité dans l'image [25]. Des opérateurs de gradient comme *Sobel* ou *Canny* estiment ces transitions à chaque pixel ; l'image est ensuite binarisée pour séparer les bords du reste, avant une étape de post-traitement pour combler les discontinuités et former des contours fermés.

Des modèles plus élaborés comme les contours actifs (*snakes*) et les *level sets*, formulent la segmentation comme un problème d'optimisation [25]. Une courbe est initialisée à proximité de la structure cible, puis elle évolue sous l'effet de deux types de forces concurrentes : des forces internes, qui pénalisent les irrégularités géométriques du contour afin de maintenir sa régularité, et des forces externes, dérivées des gradients de l'image, qui attirent la courbe vers les zones de forte variation d'intensité. Les *level sets* représentent cette courbe de façon implicite comme la ligne de niveau zéro d'une fonction scalaire définie sur tout le domaine image. Cette représentation implicite présente un avantage fondamental : elle permet de gérer naturellement les changements de topologie, c'est-à-dire la fusion ou la séparation de régions au cours de l'évolution, sans avoir à reparamétriser la courbe [25]. Ces méthodes produisent des contours lisses et géométriquement réguliers, mais leur résultat est sensible à l'initialisation et leur coût de calcul est élevé.

Méthodes basées sur les graphes (graph cuts)

Les méthodes *graph cuts* modélisent l'image sous forme de graphe, où chaque voxel correspond à un nœud et chaque arête représente la similarité entre voxels voisins. Dans cette approche, la segmentation est reformulée comme un problème de coupure optimale visant à minimiser une fonction d'énergie globale [25]. Cette fonction combine un terme

d’attache aux données, évaluant la probabilité qu’un voxel appartienne à une classe donnée, et un terme de régularisation spatiale, qui pénalise les discontinuités entre voxels voisins appartenant à des classes différentes. La minimisation de cette énergie revient à résoudre un problème de flot maximum dans le graphe, pour lequel des algorithmes polynomiaux existent.

Comparées au seuillage, les méthodes *graph cuts* sont plus robustes au bruit et aux variations d’intensité grâce à leur prise en compte globale du contexte spatial [25]. Cependant, leur principal inconvénient réside dans leur complexité computationnelle, qui augmente avec la taille du volume et limite leur application directe aux volumes CT sans recours à des stratégies d’approximation.

Morphologie mathématique

La morphologie mathématique regroupe un ensemble d’opérations géométriques appliquées au masque binaire issu d’une segmentation initiale, en le confrontant à une forme géométrique de référence, généralement un disque ou une sphère de rayon r , appelé *élément structurant* [25].

Les deux opérations fondamentales sont l’**érosion** et la **dilatation**. Tout d’abord, l’érosion supprime tout pixel du masque dont le voisinage ne contient pas entièrement l’élément structurant : concrètement, elle réduit la taille des objets segmentés et élimine les structures isolées dont la dimension est inférieure à r [25]. À l’inverse, la dilatation réalise l’opération opposée : elle ajoute au masque tous les pixels situés à une distance inférieure à r d’un pixel déjà inclus, ce qui agrandit les objets et permet de combler les petits trous.

En combinant ces deux opérations de base, on obtient deux opérateurs composés. Ainsi, l’**ouverture** consiste à appliquer une érosion suivie d’une dilatation avec le même élément structurant. Elle permet d’éliminer les petites structures parasites ou les jonctions fines, sans modifier sensiblement la forme globale de l’objet [25]. De son côté, la **fermeture** réalise l’ordre inverse, à savoir une dilatation suivie d’une érosion. Elle sert à combler les cavités internes et les petits trous du masque, tout en soudant les régions voisines séparées par un écart inférieur à r [25].

Enfin, ces opérations constituent une étape de post-traitement quasi systématique dans les pipelines de segmentation pulmonaire classiques [24] : après un seuillage ou une croissance de région, une fermeture est typiquement appliquée pour reconnecter les lobes pulmonaires séparés par des scissures fines, tandis qu’une érosion peut être utilisée pour détacher les poumons de la paroi thoracique lorsqu’ils y sont accidentellement connectés.

Toutes ces approches classiques reposent sur une hypothèse commune : les caractéristiques discriminantes entre le poumon et les tissus environnants, telles que l’intensité, les gradients ou la connectivité spatiale, sont suffisamment stables pour être décrites par des règles fixes. Cependant, cette hypothèse devient fragile face à la variabilité anatomique inter-individuelle ainsi qu’à la diversité des pathologies pulmonaires. En effet, une règle calibrée sur des poumons sains peut rapidement montrer ses limites lorsqu’elle est appliquée à des cas de fibrose, de consolidation ou d’emphysème. C’est précisément cette limite structurelle qui a progressivement conduit au recours aux méthodes d’apprentissage automatique, capables d’adapter leurs représentations directement à partir des données d’entraînement [25, 24, 26].

2.3.2 Apport de l'apprentissage profond

Contrairement aux méthodes classiques où les caractéristiques pertinentes sont définies manuellement par les experts, les approches par apprentissage profond les apprennent directement depuis les données d'entraînement, de façon hiérarchique [26]. En segmentation pulmonaire, ça se traduit par des résultats nettement meilleurs, surtout sur des structures dont la forme varie fortement d'un patient à l'autre.

Ça ne veut pas dire que ces méthodes sont sans problèmes. Elles ont besoin de beaucoup de données annotées, ce qui reste coûteux à produire surtout dans le cadre médical [24]. Elles peuvent aussi perdre en fiabilité face à la diversité des scanners ainsi qu'aux cas complexes, notamment les infections étendues ou les situations inhabituelles par rapport aux données d'apprentissage du modèle à l'entraînement. C'est ce qui pousse à concevoir des architectures adaptées au contexte médical.

2.4 Réseaux de neurones convolutionnels et architecture U-Net

2.4.1 Principes des réseaux convolutionnels

Un réseau de neurones convolutionnel (CNN) est conçu pour traiter des données structurées sous forme de grille [28]. Sa principale différence avec un réseau pleinement connecté repose sur l'opération de convolution (2.2), dans laquelle chaque neurone n'analyse qu'une petite région locale de l'entrée (image) I à l'aide d'un filtre K appris pendant l'entraînement, appelé *champ réceptif* [26].

$$(I * K)(i, j) = \sum_u \sum_v I(i - u, j - v) K(u, v). \quad (2.2)$$

Cette propriété réduit fortement le nombre de paramètres, puisqu'un filtre 3×3 ne contient que neuf coefficients partagés sur toute l'image, et permet au réseau de reconnaître un même motif quelle que soit sa position. Cela est particulièrement utile en imagerie médicale, où la localisation des structures anatomiques varie d'un patient à l'autre [25].

Chaque convolution produit une carte de caractéristiques (*feature map*). Pour permettre au réseau d'apprendre des relations non linéaires, une fonction d'activation est appliquée après chaque convolution. Parmi les plus utilisées, on trouve la ReLU (*Rectified Linear Unit*) [29], qui annule toutes les valeurs négatives en ne conservant que les activations positives :

$$f(x) = \max(0, x), \quad (2.3)$$

et la fonction sigmoïde [28], qui écrase toute valeur réelle dans l'intervalle $]0, 1[$:

$$\sigma(x) = \frac{1}{1 + e^{-x}}. \quad (2.4)$$

En empilant plusieurs couches convolutionnelles, le réseau élargit progressivement la région d'entrée qu'il couvre et construit des représentations de plus en plus générales. Les

premières couches capturent des motifs simples comme les bords et les textures, tandis que les couches profondes représentent des structures plus globales [26].

Pour réduire la résolution spatiale entre ces étages tout en gardant les informations les plus importantes, des opérations de max-pooling sont généralement appliquées en utilisant des fenêtres glissantes qui divisent la largeur et la hauteur par leur coefficient [28].

Cette réduction progressive de la résolution spatiale entraîne toutefois une perte d'informations fines, notamment au niveau des contours. En segmentation médicale, cela complique la reconstruction d'une prédiction précise pixel à pixel à partir d'une représentation de plus faible résolution. La section suivante présente l'architecture proposée pour résoudre ce problème.

2.4.2 L'architecture U-Net

U-Net est un dérivé des CNN. Il a été conçu initialement pour la segmentation biomédicale [5], car il apporte une solution à la problématique de reconstruction spatiale, en changeant la structure des réseaux de neurones et en optimisant l'apprentissage malgré les contraintes de ressources propres à ce domaine. Sa structure, schématisée en forme de « U » est illustrée dans la figure 2.5 se compose de deux chemins symétriques :

Le chemin de contraction (encodeur) : Il suit la logique classique d'un CNN en alternant les couches de convolution, généralement par blocs de deux convolutions 3×3 suivies d'une activation non linéaire, et de couches de max-pooling 2×2 , qui divisent à chaque étage la résolution spatiale par deux tout en doublant le nombre de canaux afin d'apprendre un ensemble plus riche de caractéristiques visuelles. Cette succession d'opérations permet au réseau de construire des représentations de plus en plus abstraites et de plus en plus indépendantes de la position exacte dans l'image.

Cette phase de compression progressive conduit finalement à une représentation fortement condensée des informations de l'image.

Au point de jonction entre les deux chemins se trouve le **goulot d'étranglement (bottleneck)**, où la résolution spatiale est minimale et le nombre de canaux maximal. Le réseau y construit une représentation compacte et riche en information de l'image d'entrée, regroupant l'essentiel du contexte global [26]. C'est à partir de ce point que le décodeur commence la reconstruction vers la résolution d'origine.

Le chemin d'expansion (décodeur) : Il reconstruit progressivement la résolution d'origine en sens inverse, par des convolutions transposées qui doublent la résolution spatiale à chaque étage. Chaque bloc du décodeur traite la concaténation de deux informations : la représentation remontée depuis le bas de l'architecture, et les canaux issues du niveau correspondant de l'encodeur, directement transférées via des connexions sautées (skip connections).

C'est ce mécanisme de connexions sautées qui constitue l'innovation architecturale fondamentale de U-Net [5]. Sans elles le décodeur ne disposerait que des représentations compressées du bas du « U », qui ont perdu une grande partie des informations de localisation précise. Grâce aux connexions sautées, le décodeur reçoit simultanément le « que segmenter » (fourni par les couches profondes, riches en sémantique) et le « où exactement » (fourni par les couches peu profondes de l'encodeur, riches en détails spatiaux

fin). Cette complémentarité est décisive pour segmenter avec précision les frontières anatomiques, souvent fines et complexes [26].

Une autre particularité intéressante du U-Net est sa capacité à donner des résultats décents même quand il y a peu de données pour l'entraîner. Pour y arriver, il ne regarde pas toute l'image d'un coup. Au lieu de ça, il la découpe en petits morceaux, des « patches », ce qui donne l'impression d'avoir bien plus d'exemples à apprendre. En plus, il existe des augmentations pour rendre ces exemples encore plus variés, comme faire pivoter les images, les étirer ou changer leur contraste. C'est grâce à ces méthodes que U-Net a pu montrer de très bonnes performances dès ses premières utilisations, surtout dans des domaines où préparer et annoter des images médicales est souvent compliqué et coûteux [5].




FIGURE 2.5 – Architecture du réseau U-Net, composée d'un encodeur (chemin de contraction), d'un goulot d'étranglement et d'un décodeur (chemin d'expansion) reliés par des connexions sautées [5]

2.4.3 Variantes architecturales et segmentation volumétrique

Le U-Net a rapidement inspiré une série de variantes, chacune cherchant à corriger une limite spécifique du modèle original. On peut les regrouper en trois grandes directions : les variantes basées sur l'attention, celles qui étendent la segmentation au volume 3D, et les architectures conçues pour capturer un contexte spatial plus large.

Variantes basées sur l’attention

Les *skip connections* du U-Net transmettent les cartes de caractéristiques de l’encodeur telles quelles, y compris des régions sans intérêt pour la segmentation comme le fond ou les côtes. **Attention U-Net** [30] corrige ce problème en ajoutant des portes d’attention (*attention gates*) à chaque connexion. Ces portes apprennent à ne retenir que les caractéristiques utiles à la tâche, en supprimant les activations non pertinentes. Le surcoût en paramètres est négligeable, environ 8 % de plus, mais le gain en précision sur les petites structures est mesurable [30].

Variantes orientées segmentation volumétrique

Le U-Net original traite des images 2D coupe par coupe, sans exploiter la continuité entre coupes. L’extension volumétrique la plus directe remplace simplement toutes les convolutions 2D par des convolutions 3D, ce qui permet au réseau de raisonner sur le volume entier. Le problème, c’est que la mémoire GPU nécessaire augmente fortement, ce qui contraint à travailler sur des volumes de résolution réduite.

V-Net [31] s’inscrit dans cette direction en y apportant deux modifications importantes. D’abord, il remplace la perte standard par une **perte de Dice**, qui optimise directement le chevauchement entre le masque prédit et la vérité terrain, ce qui est plus adapté aux situations où les voxels d’intérêt sont minoritaires, comme c’est souvent le cas en imagerie pulmonaire. Ensuite, il intègre des connexions résiduelles dans chaque bloc, ce qui stabilise l’entraînement des réseaux profonds en limitant la disparition du gradient.

Architectures pour la capture du contexte global

TransUNet : Les convolutions ont un champ réceptif local, elles voient ce qui est proche mais pas ce qui est loin. C’est une limite quand il faut délimiter des structures bilatérales, ou faire le lien entre des régions éloignées d’un même volume. TransUNet [32] répond à ce problème en intégrant un *Vision Transformer* au goulot d’étranglement du U-Net. Le Transformer découpe les cartes de caractéristiques en *patches* et calcule des relations d’attention entre tous les patches en même temps, quelle que soit leur distance. Le décodeur combine ensuite ces représentations globales avec les cartes CNN haute résolution issues des *skip connections* pour localiser précisément les contours. Ces architectures hybrides sont aujourd’hui parmi les plus performantes sur les benchmarks de segmentation médicale, mais elles demandent plus de données et un coût de calcul plus élevé.

Res2Net : Il aborde le problème différemment, non pas en modifiant la structure globale du réseau, mais en repensant le bloc convolutionnel de base. L’idée est de diviser les canaux d’entrée en sous-groupes traités de façon hiérarchique, de manière à extraire des représentations à plusieurs échelles au sein d’un même bloc. Par rapport aux approches classiques qui représentent le contexte multi-échelle couche par couche, Res2Net élargit la plage des champs réceptifs sans augmenter significativement le nombre de paramètres [33]. C’est particulièrement utile pour la segmentation pulmonaire, où lobules, fissures et vaisseaux coexistent à des échelles très différentes.

Limites communes et verrous ouverts

Ces avancées ne résolvent pas tout. Plusieurs problèmes restent ouverts et concernent l'ensemble de ces variantes. Parmi eux, nous avons :

En premier lieu la **dépendance aux annotations** : Annoter un volume CT requiert beaucoup de temps et d'effort de la part des experts, parfois plusieurs heures par patient pour une segmentation lobaire complète. La rareté de données annotées de qualité reste le principal frein à la généralisation des modèles.

Le deuxième est la **fragilité au changement de domaine** : Un modèle entraîné sur un protocole d'acquisition donné peut perdre une grande partie de ses performances sur des données issues d'un autre équipement ou d'un autre hôpital, un phénomène appelé *distribution shift* [25].

Le troisième concerne **les pathologies sévères** : Les pneumonies, fibroses ou épanchements modifient la texture et la densité du parenchyme pulmonaire. Ces cas s'éloignent de la distribution d'entraînement, et ce sont précisément ceux où une segmentation précise est la plus critique cliniquement [24].

Face à ces limites, les pistes actuelles incluent l'apprentissage semi-supervisé, la *domain adaptation*, et les modèles de fondation comme MedSAM, conçus pour être pré-entraînés sur des données massives puis affinés sur chaque tâche spécifique [25].

2.4.4 Stratégies de génération des annotations face à la pénurie de données

En imagerie médicale, le principal problème pour entraîner des modèles de segmentation reste le manque d'annotations de qualité. Produire des masques précis demande beaucoup de temps et nécessite généralement l'intervention d'experts médicaux [34]. Plusieurs approches existent donc pour générer ces annotations.

L'**annotation manuelle** reste la méthode de référence. Elle consiste à délimiter les structures voxel par voxel avec des logiciels comme 3D Slicer ou ITK-SNAP. Cette approche donne des résultats précis, mais elle est très longue et difficile à appliquer sur de grands volumes de données. Certaines études estiment qu'une annotation complète peut prendre près d'une heure pour un seul volume [34] mais les résultats peuvent aussi varier d'un expert à un autre.

Les **méthodes semi-automatiques** utilisent des techniques classiques de traitement d'image comme le seuillage, la croissance de régions ou les modèles déformables pour générer une première segmentation [35]. L'utilisateur doit ensuite corriger ou valider le résultat. Cela réduit le temps de travail, mais l'expert reste toujours présent dans le processus.

Les approches de **pseudo-labellisation** et d'**apprentissage semi-supervisé** utilisent un modèle déjà entraîné pour produire automatiquement des masques sur des données non annotées [36, 37]. Ces méthodes permettent d'exploiter plus de données, mais elles dépendent fortement de la qualité du premier modèle utilisé. Les erreurs présentes dans les labels générés peuvent être réappries et amplifiées par les modèles suivants [38].

Enfin, les **méthodes algorithmiques déterministes** reposent uniquement sur du traitement d'image classique, sans apprentissage profond ni intervention humaine. En segmentation pulmonaire sur scanner CT, elles exploitent principalement les différences de densité sur l'échelle Hounsfield entre le parenchyme pulmonaire et les tissus environnants.

Les poumons aérés possèdent généralement des valeurs très faibles, contrairement aux tissus mous qui présentent des valeurs plus élevées [39]. Un seuillage adapté, combiné à des opérations de morphologie mathématique, permet ainsi d’obtenir des masques propres et reproductibles [40].

Positionnement du travail

Dans ce projet, les données utilisées ne contenaient aucun masque de segmentation préexistant. Nous avons donc choisi une génération entièrement automatique basée sur un seuillage déterministe des valeurs Hounsfield, suivi de plusieurs post-traitements morphologiques. Aucune correction manuelle ni aucun modèle d’apprentissage profond n’a été utilisé.

Ce choix permet d’obtenir des annotations reproductibles et indépendantes de toute subjectivité humaine. Il évite également toute dépendance à un modèle tiers, ce qui réduit le risque de biais circulaire lors de l’évaluation des modèles entraînés [25].

2.5 Recosntruction 3D surfacique

Une fois la segmentation pulmonaire obtenue, l’étape suivante consiste à reconstruire une surface 3D à partir du masque de prédiction. C’est là qu’intervient l’algorithme *Marching Cubes*, proposé par Lorensen et Cline en 1987 [41], qui reste aujourd’hui la méthode de référence pour extraire une isosurface à partir d’un champ scalaire volumétrique.

2.5.1 Principe de fonctionnement

Le principe repose sur un parcours du volume voxel par voxel, en analysant à chaque étape un cube élémentaire formé par huit voxels adjacents. Pour chaque cube, on détermine si ses sommets se situent à l’intérieur ou à l’extérieur de la forme étudiée en comparant leur valeur à un seuil défini (l’*isovalue*). Comme chaque sommet n’a que deux états possibles, un cube peut présenter $2^8 = 256$ configurations théoriques. Toutefois, en exploitant les propriétés de symétrie et de complémentarité, ces cas sont réduits à 15 combinaisons de base, illustrées dans la figure 2.6. Ces configurations sont répertoriées dans une table de correspondance (*lookup table*) [41] qui dicte la topologie exacte des triangles à générer pour approximer localement la surface.

Pour éviter un effet de crénelage, la position exacte des sommets des triangles le long des arêtes n’est pas fixe elle est calculée par interpolation linéaire entre les valeurs scalaires des deux extrémités. Cette approche permet de lisser le maillage et d’épouser fidèlement la géométrie de l’anatomie segmentée, sans subir la rigidité de la grille de voxels. En appliquant ce traitement à l’ensemble des cubes du volume, on reconstruit un maillage triangulaire continu de la surface pulmonaire [42].

Cet algorithme s’avère idéal pour l’imagerie médicale. Outre sa rapidité et sa forte propension à la parallélisation, il génère une surface directement exploitable pour la visualisation 3D ou l’extraction de métriques volumétriques [42].




FIGURE 2.6 – Les 15 configurations uniques du Marching Cubes [6]

2.5.2 Variantes et améliorations

La version originale de Lorensen et Cline souffre d'un problème connu : la table de 15 cas est incomplète. Dans certaines configurations, les choix de triangulation sur les faces d'un cube ne sont pas compatibles avec ceux du cube voisin, ce qui crée des *trous* ou des incohérences topologiques dans le maillage final [43].

Plusieurs travaux ont cherché à corriger ce problème. Chernyaev, dès 1995, a montré qu'il existe en réalité 33 configurations topologiquement distinctes et non 15, en résolvant les ambiguïtés sur les faces et à l'intérieur des cubes. Lewiner et al. [43] ont ensuite proposé une implémentation complète et vérifiée de cette *Marching Cubes 33*, garantissant que le maillage produit est une variété (*manifold mesh*) sans fissures ni incohérences topologiques pour n'importe quelle donnée d'entrée. C'est cette variante qui est aujourd'hui la plus utilisée dans les applications nécessitant une reconstruction géométriquement fiable.

Une autre direction est celle des *Dual Marching Cubes*, proposée par Grosso et Zint [44]. Plutôt que de trianguler directement à l'intérieur de chaque cube, cette approche calcule le dual des polygones d'isosurface, ce qui produit un maillage composé uniquement de quadrilatères (*quad mesh*). L'avantage est double : les sommets sont positionnés directement sur la surface reconstruite avec une plus grande précision, et le maillage obtenu est par construction cohérent entre cubes voisins, sans nécessiter de table de correspondance pour les cas ambigus. En contrepartie, le traitement est plus coûteux et l'implémentation plus complexe.

Dans le cadre de ce travail, c'est la variante de Lewiner et al. qui est retenue, car elle offre le meilleur compromis entre correction topologique garantie et efficacité d'exécution, deux critères essentiels pour la reconstruction de volumes pulmonaires à partir de masques de segmentation.

2.6 Reconstruction volumique

La reconstruction volumique d'organes à partir d'images médicales se situe à l'intersection de la géométrie algorithmique, de l'analyse biomédicale et de la simulation numérique. L'objectif est de produire, à partir d'un masque de segmentation 3D ou d'un maillage surfacique, une représentation interne du volume anatomique exploitable par des méthodes de calcul, en particulier par la méthode des éléments finis (FEM). Cette approche numérique consiste à discrétiser une structure complexe en une multitude de petits sous-domaines géométriques simples (les éléments) afin de simuler son comportement physique, mécanique ou thermique sous l'effet de contraintes extérieures. Cette

section passe en revue les principales approches théoriques et algorithmiques de cette chaîne de traitement : décomposition topologique, représentation géométrique, génération volumique et validation du maillage produit.

2.6.1 Décomposition topologique des maillages surfaciques

Composantes connexes

Un maillage triangulaire peut être représenté sous forme de graphe, où chaque nœud correspond à un triangle et où deux nœuds sont reliés lorsqu'ils partagent une arête géométrique. La décomposition en composantes connexes de ce graphe permet d'identifier les différentes sous-structures géométriquement disjointes présentes dans le maillage. Une composante connexe correspond ainsi à un ensemble maximal d'éléments reliés entre eux par un chemin continu.

Extraction des composantes connexes et Union-Find

L'identification des composantes connexes peut être modélisée comme un problème de graphe. Chaque voxel est considéré comme un nœud, et une arête relie deux nœuds s'ils sont adjacents selon la connexité choisie (6-connexité ou 26-connexité).

Pour résoudre ce problème de manière efficace, on emploie la structure de données *Union-Find* (Disjoint-Set Union, DSU), présentée par [45]. Cette structure maintient une partition d'un ensemble et supporte deux opérations principales :

- **Find**(x) : retourne le représentant canonique de la classe contenant l'élément x (ici, un voxel spécifique), en mettant à jour les chemins (compression de chemin) pour accélérer les futures requêtes.
- **Union**(x, y) : fusionne les classes d'équivalence de deux éléments x et y (deux voxels adjacents) en une seule, en unissant leurs représentants respectifs.

Tarjan a montré seulement avec les optimisations de compression de chemin et d'union par rang, la complexité amortie devient quasi-linéaire : $O(n \cdot \alpha(n))$, où α est la fonction inverse d'Ackermann, dont la valeur reste inférieure à 5 pour toute entrée pratique [45]. Pour la segmentation biomédicale, cette efficacité est cruciale, car les volumes d'imagerie médicale contiennent souvent des millions de voxels.

Autres méthodes de partitionnement géométrique

Lorsque les structures anatomiques à séparer ne sont pas géométriquement disjointes, par exemple en présence d'un pont surfacique dû à un artefact de segmentation, des méthodes de partitionnement plus élaborées sont nécessaires.

Le **partitionnement par coupe minimale** (*Graph Cuts*) s'appuie sur le théorème flot-max/coupe-min pour identifier, dans le graphe dual du maillage, la frontière de coupe minimisant une fonction d'énergie géométrique [46]. Cette approche est particulièrement adaptée aux cas où les composantes partagent une zone de contact étroite.

Le **partitionnement spectral** exploite les vecteurs propres de la matrice laplacienne du maillage pour projeter la géométrie dans un espace de faible dimension, où les sous-structures apparaissent comme des clusters bien séparés [47]. Ces méthodes sont plus robustes face aux variations morphologiques complexes, au prix d'un coût computationnel plus élevé.

Identification anatomique par analyse spatiale

Une fois les composantes connexes extraites, il reste à identifier laquelle correspond à quelle structure anatomique. Lorsque plusieurs composantes de taille comparable sont présentes, une heuristique géométrique robuste s'impose pour éviter annotation manuelle.

Pour le cas du poumon bilatéral, une approche éprouvée consiste à exploiter la symétrie anatomique et la convention d'orientation médicale DICOM [48]. La convention LPS (Left-Posterior-Superior) définit trois axes :

- L (Left) : l'axe X croît vers la gauche du patient ;
- P (Posterior) : l'axe Y croît vers l'arrière ;
- S (Superior) : l'axe Z croît vers le haut.

Le centroïde d'une composante connexe, défini comme la moyenne arithmétique des coordonnées de ses sommets, l'extraction de la seule coordonnée X du centroïde suffit pour une identification correcte et la composante ayant la plus grande coordonnée X est le poumon gauche, celle avec la plus petite est le poumon droit. Cette heuristique est sans paramètre et s'appuie directement sur la sémantique de l'espace DICOM, garantissant une identification robuste à condition que les données CT aient été réorientées en amont du pipeline.

D'autres approches reposent sur le **recalage sur atlas anatomique** [49]. Cette méthode consiste à aligner l'image du patient sur un atlas préalablement labellisé à l'aide d'une transformation géométrique (rigide, affine ou déformable). Les étiquettes anatomiques de l'atlas sont ensuite propagées sur l'image du patient via la transformation inverse.

Enfin, les architectures d'apprentissage profond, et notamment **nnU-Net** [50], permettent aujourd'hui de générer directement des masques multi-classes (poumon gauche, poumon droit, lobes pulmonaires) à partir de l'image scanner. Ces méthodes offrent généralement une bonne précision sans nécessiter de post-traitement topologique lourd, mais elles requièrent un entraînement supervisé sur une base de données annotées conséquente.

2.6.2 Représentation géométrique : la Boundary Representation

Principe

La *Boundary Representation* (B-Rep) est le modèle géométrique standard en conception assistée par ordinateur et en simulation numérique [51]. Elle décrit un solide exclusivement par sa frontière, organisée en une hiérarchie de quatre entités topologiques majeures, chacune adossée à un support géométrique :

1. **Sommets** (*Vertices*) : points de repère dans $\mathbb{R}^3$ représentant les intersections d'arêtes.
2. **Arêtes** (*Edges*) : segments topologiques reliant deux sommets, portés par une courbe géométrique sous-jacente (segment de droite, B-spline, NURBS).
3. **Faces** (*Faces*) : portions de surfaces délimitées par des boucles d'arêtes (*wires*), portées par une surface géométrique sous-jacente.
4. **Coques / Volumes** (*Shells / Solids*) : enveloppes fermées de faces délimitant un domaine solide tridimensionnel connexe.

Cette hiérarchie sépare explicitement la topologie (les relations d'adjacence) de la géométrie (la forme intrinsèque des courbes et surfaces), ce qui garantit la cohérence du modèle lors de modifications ultérieures. Les noyaux géométriques industriels tels

qu’OpenCASCADE [52] et ACIS implémentent ce modèle et constituent la base de nombreux outils de CAO et de simulation.

Construction d’une représentation B-Rep à partir d’un maillage triangulaire

La conversion d’un maillage STL discret en une B-Rep exploitable est une étape non triviale. L’approche générale consiste à classer les arêtes du maillage en arêtes vives (séparant deux patches de courbures distinctes) et en arêtes lisses (appartenant à un patch continu), à partir de l’angle entre les normales des triangles adjacents. Sur cette base, les triangles sont regroupés en surfaces, les surfaces en boucles fermées, et le volume intérieur est instancié. La qualité de la B-Rep produite conditionne directement la robustesse des algorithmes de tétraédrisation appliqués en aval.

2.6.3 Algorithmes de génération de maillages volumiques tétraédriques

La transformation d’un domaine fermé (défini par une surface B-Rep) en un maillage composé de tétraèdres remplissant tout le volume est un problème classique et central en géométrie algorithmique. Trois grandes familles de méthodes dominent la littérature.

Méthode du front avançant

La méthode dite *Advancing Front* (AF), introduite par Löhner et Parikh [53] puis étendue par George et al. [54], construit le maillage de manière progressive, en partant de la surface vers l’intérieur du volume.

On initialise un *front actif* sur la surface du modèle. À chaque étape, l’algorithme sélectionne une face du front, place un nouveau sommet à l’intérieur du domaine et forme un nouveau tétraèdre. Les nouvelles faces créées rejoignent le front. Lorsque deux faces coïncident, elles s’annulent mutuellement. L’algorithme s’arrête lorsque le front est entièrement refermé.

Son principal avantage est de respecter très fidèlement la géométrie de la surface d’entrée, ce qui est particulièrement intéressant pour les structures anatomiques complexes et courbées [55]. En revanche, la convergence peut parfois poser problème au centre du volume lorsque les fronts se rejoignent dans des configurations défavorables.

Triangulation de Delaunay contrainte

Les méthodes de Delaunay reposent sur une propriété géométrique forte appelée « propriété de la sphère vide », selon laquelle aucun sommet du maillage ne doit se trouver à l’intérieur de la sphère circonscrite à un tétraèdre. Cette règle permet de maximiser les angles des tétraèdres et de produire des éléments globalement bien proportionnés et stables.

Dans sa version contrainte (**Constrained Delaunay Tetrahedralization**), l’algorithme doit respecter strictement la surface d’entrée (par exemple l’enveloppe du poumon) qui devient la frontière du maillage volumique [56].

Cependant, respecter la surface ne suffit pas toujours à garantir une bonne qualité partout. Des algorithmes de raffinement, initialement proposés par Ruppert en 2D [57] puis étendus en 3D par Shewchuk [58], permettent d’améliorer le maillage en insérant

progressivement des points supplémentaires appelés **Steiner points**. Le logiciel **TetGen** [56] est aujourd’hui la référence pour cette approche.

Malgré ces raffinements, les méthodes de Delaunay ont un défaut bien connu, elles génèrent fréquemment des tétraèdres dégénérés appelés **slivers**. Il s’agit de tétraèdres quasi-plans dont le volume est presque nul. Ces éléments sont très néfastes pour les simulations numériques et nécessitent souvent un post-traitement spécifique pour être corrigés [59].

Méthodes octree et voxeliques

Ces approches commencent par subdiviser l’espace à l’aide d’une grille régulière ou d’un arbre octaïdre (octree). Elles adaptent ensuite les cellules qui intersectent la surface pour coller au mieux à la géométrie anatomique.

Ces méthodes sont très robustes, même en présence de surfaces imparfaites ou bruitées. Leur principal inconvénient est la création d’artefacts en « escalier » près de la surface, qui nécessitent des étapes de lissage supplémentaires. Cela peut parfois réduire la fidélité géométrique aux parois anatomiques [55].

2.6.4 Optimisation de la qualité des maillages

Un maillage tétraédrique généré automatiquement à partir d’images médicales contient souvent des éléments de mauvaise qualité comme des tétraèdres quasi-plats (slivers), arêtes trop courtes ou trop longues, et angles dégradés. Ces défauts nuisent fortement à la précision et à la stabilité des simulations par éléments finis (FEM), car la qualité de chaque élément influence directement le conditionnement de la matrice de rigidité [58].

Pour remédier à ces problèmes, les méthodes d’optimisation se divisent en deux catégories complémentaires, généralement appliquées de manière itérative jusqu’à atteindre un critère de qualité global satisfaisant.

Optimisation géométrique : lissage de nœuds

Le lissage consiste à déplacer les nœuds du maillage sans modifier sa connectivité. La méthode la plus classique est le **lissage de Laplace**, qui repositionne chaque nœud vers le barycentre de ses voisins. Cette approche améliore l’uniformité locale du maillage, mais elle ne garantit pas toujours une optimisation optimale des métriques de qualité.

C’est pourquoi des méthodes plus avancées ont été développées, telles que l’Optimal Delaunay Triangulation (ODT) ou GETMe, qui minimisent explicitement une fonction de qualité. Ces variantes offrent de meilleurs résultats, au prix toutefois d’un coût computationnel plus élevé [60].

Optimisation topologique : reconnexion locale

Lorsque le simple déplacement des nœuds n’est plus suffisant, on modifie directement la *connectivité* du maillage grâce à des opérations locales [61, 62].

Permutation d’arêtes (edge swapping) : Une arête partagée par plusieurs tétraèdres est supprimée et remplacée par une nouvelle configuration impliquant les mêmes nœuds. En 3D, les deux opérations fondamentales sont :

- le **flip 2-3** : deux tétraèdres partageant une face sont remplacés par trois tétraèdres partageant une arête.
- le **flip 3-2** : opération inverse qui réduit le nombre d'éléments.

Des variantes plus générales, comme l'**edge removal**, permettent de traiter des configurations complexes. Ces techniques constituent le cœur des optimiseurs performants tels que ceux proposés par Klingner et Shewchuk [62].

Contraction d'arêtes (edge collapsing) : Deux nœuds reliés par une arête sont fusionnés en un seul. Cette opération supprime les tétraèdres contenant cette arête et réduit localement la densité du maillage. Elle est particulièrement utile pour éliminer les slivers et les arêtes trop courtes. Une vérification de validité (pour éviter l'inversion des éléments) et un critère de qualité minimale sont toujours appliqués avant d'accepter la contraction [61].

Bilan et pipeline d'optimisation : En pratique, ces opérations sont combinées dans un pipeline itératif : *lissage* $\rightarrow$ *permutation d'arêtes* $\rightarrow$ *contraction d'arêtes*, répété jusqu'à convergence.

Le logiciel Gmsh propose ce type de pipeline via les algorithmes **Netgen** et **Mmg3D**, qui alternent lissage ODT et reconnexion locale [60, 63]. Comme l'ont montré Freitag et Gooch [61], la combinaison de l'optimisation géométrique et topologique donne systématiquement de meilleurs résultats que chacune des approches utilisée seule.

Dans le cadre de ce travail, l'algorithme **Frontal-Delaunay** 3D de Gmsh est retenu pour la génération du maillage volumique, car il offre le meilleur compromis entre conformité géométrique surfacique et qualité des éléments intérieurs, deux propriétés essentielles pour la discrétisation fidèle de surfaces anatomiques complexes telles que les poumons.

Pour l'optimisation, un pipeline combinant lissage de Laplace et reconnexion topologique locale via Netgen est adopté, conformément aux recommandations de la littérature [61], qui montrent que l'association des deux approches conduit généralement à de meilleurs résultats que chacune utilisée isolément.

2.6.5 Critères de qualité pour la simulation par éléments finis

La précision et la stabilité d'une simulation par éléments finis (FEM) dépendent fortement de la qualité géométrique de chaque tétraèdre. La bibliothèque *Verdict* [64], développée au Sandia National Laboratories, est une référence industrielle pour évaluer quantitativement cette qualité à travers trois familles de critères complémentaires.

Le premier critère est la **fidélité volumique globale** : l'erreur relative entre le volume tétraédrique et le volume de la surface de référence ne doit pas dépasser 5 % pour les tissus mous en imagerie médicale [65].

Le second critère est le **rapport de forme** (*Aspect Ratio*) $\beta = R/3r$, où R est le rayon de la sphère circonscrite et r celui de la sphère inscrite. La valeur idéale $\beta = 1$ correspond à un tétraèdre régulier ; des valeurs élevées dégradent le conditionnement de la matrice de rigidité et augmentent les erreurs numériques [58, 64]. La grande majorité des éléments d'un maillage acceptable doit satisfaire $\beta < 3$ [66].

Le troisième critère concerne les **éléments sliver** : des tétraèdres dont les quatre sommets sont quasi coplanaires, présentant un volume proche de zéro malgré des arêtes

de longueur normale. Leur présence peut déstabiliser les solveurs numériques [59]. Ils sont caractérisés par un volume normalisé $V_{\text{norm}} = V_T/\bar{\ell}^3 < 10^{-3}$, seuil en deçà duquel un élément est considéré comme dégénéré [64].

Dans la suite de ce travail, ces trois critères sont utilisés conjointement pour évaluer la qualité des reconstructions volumiques générées.

2.7 Simulation des mouvements respiratoires

Les mouvements respiratoires provoquent des déformations cycliques des organes thoraciques qu'il est essentiel de modéliser dans les jumeaux numériques spécifiques au patient, en particulier pour des applications telles que la planification de la ventilation mécanique et la recherche en pneumologie [67].

2.7.1 Modèles de mouvements respiratoires

La littérature sur la modélisation des mouvements respiratoires peut être classée en trois catégories en fonction de leur fidélité mécanique et de leurs exigences en matière de données.

Modèles à compartiment unique. Au niveau le plus simple, les modèles à compartiment unique sont ajustés aux signaux physiologiques mesurés (pression, volume et débit d'air) afin d'estimer deux paramètres cliniques clés : l'élasticité du poumon (compliance) et sa résistance au flux d'air (résistance). Des modèles plus complexes étendent cette approche en intégrant la structure ramifiée des voies respiratoires, mais les deux approches partagent une limitation fondamentale : elles ne peuvent pas rendre compte de l'interaction locale entre la déformation des tissus et le débit d'air à l'intérieur du poumon [67].

Modèles basés sur l'image et spécifiques au patient. À partir d'images de tomodensitométrie (CT) acquises en fin d'expiration, les géométries spécifiques au patient peuvent être segmentées et discrétisées en maillages d'éléments finis. La configuration de référence est généralement supposée être exempte de contraintes, bien que les poumons réels au repos supportent des contraintes résiduelles causées par la pression transpulmonaire nécessaire pour éviter l'affaissement alvéolaire [67].

Modèles biomécaniques basés sur la physique. Ces modèles, les plus fidèles à la réalité physique, traitent le poumon comme une structure déformable dans laquelle l'air et les tissus interagissent mécaniquement. Ils décrivent le comportement mécanique des tissus pulmonaires et permettent de simuler des procédures cliniquement pertinentes telles que la ventilation mécanique, en produisant des distributions tridimensionnelles de la variation de volume, de la pression alvéolaire et des contraintes internes au cours du cycle respiratoire [67].

2.8 Jumeau numérique : définitions et applications médicales

2.8.1 Fondements théoriques et architecture du Jumeau Numérique

Le jumeau numérique (JN) est une réplique virtuelle haute fidélité d'une entité réelle, capable de reproduire son comportement durant tout son cycle de vie. Contrairement à une simulation classique, il repose sur un échange bidirectionnel : les données du monde réel alimentent en continu le modèle virtuel pour maintenir une synchronisation dynamique [68].

Cette interaction transforme le modèle en un système proactif. Grâce à une boucle de rétroaction constante entre le physique et le virtuel, le jumeau numérique ne se limite pas à décrire l'état actuel, mais permet d'anticiper et de prescrire des interventions futures [68].

2.8.2 Échelles et domaines d'application en santé :

Dans le secteur médical, les jumeaux numériques sont déployés à plusieurs niveaux physiologiques, de l'échelle cellulaire à l'organisme entier [69]. Leurs applications cliniques se concentrent aujourd'hui sur plusieurs spécialités clés :

- Cardiologie : La modélisation cardiaque basée sur des cohortes de grande ampleur (plus de 3 400 patients) a démontré une efficacité concrète. L'utilisation de modèles spécifiques au patient a permis de réduire le taux de récurrence d'arythmies, telles que la fibrillation atriale, de plus de 13% [69].
- Neurologie : L'intégration de l'intelligence artificielle aux données patients permet d'atteindre une précision prédictive de 97% dans le suivi des maladies neurodégénératives [69].
- Hépatologie et Métabolisme : Des modèles hépatiques numériques parviennent à simuler les réponses de l'organe avec une résolution temporelle de l'ordre de la sous-milliseconde, facilitant la prédiction des réactions métaboliques [69].
- Oncologie et Pneumologie : L'utilisation d'algorithmes d'apprentissage statistique et de modèles physiques permet une personnalisation fine des protocoles, notamment pour l'optimisation des doses en radiothérapie ou le réglage de la ventilation pulmonaire [69].

2.9 Conclusion

L'intelligence artificielle, et en particulier l'apprentissage profond, a profondément transformé la segmentation d'images médicales. Parmi les différentes approches, les architectures de type U-Net restent une solution de référence en raison de leur efficacité et de leur simplicité. Les approches récentes, telles que les transformers, les modèles de diffusion et les modèles de fondation, offrent des perspectives prometteuses, mais leur complexité limite encore leur adoption dans certains contextes. Dans ce travail, le choix d'un modèle U-Net se justifie par un compromis optimal entre performance, coût de calcul et disponibilité des données, ce qui en fait une approche adaptée à la segmentation

pulmonaire à partir d'images CT. Le chapitre suivant présente la méthode proposée pour la segmentation pulmonaire en utilisant le modèle U-Net.

Chapitre 3

Méthode proposée

3.1 Introduction

Ce chapitre présente le pipeline mis en place pour la segmentation pulmonaire, depuis la collecte et le prétraitement des données jusqu’à la reconstruction tridimensionnelle des maillages. Nous commençons par décrire les trois ensembles de données utilisés ainsi que les étapes de traitement appliquées pour les rendre exploitables. Nous présentons ensuite la méthode de génération automatique des masques pulmonaires par techniques classiques de bio-imagerie, puis l’architecture et l’entraînement du réseau U-Net 2D développé pour la segmentation. Enfin, nous détaillons le pipeline de reconstruction 3D, de l’extraction de surface par l’algorithme des Marching Cubes jusqu’à la simplification du maillage final.

3.2 Traitement des données

3.2.1 Dataset LIDC-IDRI

Le dataset principal utilisé pour ce projet est le LIDC-IDRI, disponible sur le site officiel du TCIA, une large collection de scanners CT de 1012 patients, comprenant une série de scanners CT, des annotations de nodules en format XML ainsi que des radiographies thoraciques [70]. Nous avons choisi ce dataset pour de nombreuses raisons techniques et pratiques. Les données ont été initialement collectées pour des études sur les nodules et les tumeurs, fournissant des annotations, des tailles et des localisations de nodules. Pourtant, la nature diverse des données, avec des poumons présentant différents états de santé, des tailles et formes de nodules variées, offre à la fois une diversité morphologique et un volume suffisant pour les besoins de l’entraînement. Il est également important de noter que bien que le dataset soit composé de poumons présentant des nodules et des anomalies, la géométrie et la forme primaires des poumons sont généralement préservées et n’affectent pas significativement la qualité des informations requises pour les besoins de ce projet, ce qui en fait non seulement un dataset bien adapté à cette tâche particulière, mais aussi un dataset très largement utilisé dans des études similaires.

3.2.2 Dataset LUNA16

L’ensemble de données Luna 16 est un sous-ensemble de l’ensemble de données LIDC-IDRI, qui comprend 888 volumes de tomodensitométrie avec annotations pulmonaires obtenues à l’aide d’une méthode de segmentation automatisée. Il a été utilisé pour la

compétition LUNA16 de 2016 consacrée à la recherche sur le cancer du poumon, disponible sur Zenodo sur deux parties [71, 72]. Cet ensemble de données a été choisi pour ce projet principalement afin de valider et d'évaluer de manière comparative le modèle U-Net que nous avons développé.

3.2.3 Ensemble de données annotées par des radiologues

La validation externe a été réalisée à l'aide de l'ensemble de données HuoMa disponible sur Zenodo [73]. Cet ensemble de données contient 20 tomodensitométries thoraciques liées à la COVID-19, réalisées sur différents patients et dans divers environnements d'imagerie.

L'un des principaux avantages de cet ensemble de données réside dans la qualité de ses annotations. Les masques pulmonaires ont été délimités manuellement par deux radiologues experts, puis validés par un radiologue chevronné, garantissant ainsi des masques de segmentation de référence hautement fiables et cliniquement précis.

Contrairement à LUNA16, qui s'appuie sur des annotations générées automatiquement, HuoMa fournit des masques entièrement annotés par des experts ainsi que des acquisitions de tomodensitométrie indépendantes. Par conséquent, il permet une évaluation plus rigoureuse et cliniquement plus réaliste de la robustesse de la segmentation et de la généralisation entre ensembles de données.

3.2.4 Format des données

Pour les besoins de cette étude, il convient de préciser certains détails concernant le dataset utilisé. Le dataset, comme mentionné précédemment, est constitué de scanners CT pulmonaires, organisés en dossiers contenant une série de coupes 2D. Les scanners CT sont sauvegardés au format DICOM, un format principalement dédié à l'imagerie médicale, qui se distingue par sa capacité à capturer des informations sous-jacentes que les formats d'image classiques ne permettent pas, comme les métadonnées intégrées concernant les informations du patient, les paramètres d'acquisition, ainsi que les paramètres nécessaires à la conversion des intensités brutes des pixels en valeurs d'Unités Hounsfield calibrées [74]. L'unité Hounsfield est une unité de mesure de densité radiologique utilisée pour l'interprétation des images CT, elle nous permet d'identifier différents composants biologiques et physiques comme les fluides, les tissus et l'air, chacun correspondant à une plage spécifique de valeurs HU [75].

Les fichiers DICOM, cependant, ne sont pas directement exploitables dans leur forme originale en raison de la manière dont ils sont organisés. En pratique, lorsqu'on travaille avec de l'imagerie 3D, un format plus pratique est le format NIfTI, qui transforme les coupes DICOM 2D en un volume 3D stocké dans un seul fichier plutôt qu'en plusieurs fichiers séparés. Cela est particulièrement pratique lors du travail avec un modèle d'apprentissage automatique, car cela permet de traiter l'ensemble du scanner volumétrique comme un seul fichier plutôt qu'une série de coupes indépendantes, ce qui simplifie le chargement des données.

Il fournit également les informations d'espacement des voxels encodées dans la matrice affine [76], qui interviennent dans certaines des opérations morphologiques tridimensionnelles lors de la génération des masques, comme présenté dans la section 3.2.6.

3.2.5 Filtrage et Prétraitement des données

Le premier traitement effectué après la collecte des données était l'extraction et l'organisation des scanners CT. Dans le LIDC-IDRI, chaque dossier patient contient deux séries DICOM, une série de scanner CT correspondant au volume des poumons, et une série de radiographie thoracique. Nous sélectionnons la série correcte en vérifiant le tag d'orientation de l'image dans l'en-tête DICOM, la vérification de l'orientation axiale confirme que la série sélectionnée est constituée de coupes CT axiales plutôt que d'images radiographiques thoraciques.

Après avoir récupéré la série correcte, le nettoyage et l'organisation des données viennent ensuite. L'étape suivante consiste à trier les coupes selon leur position pour s'assurer qu'il n'y a pas d'incohérence dans notre volume lors de leur empilement. Nous utilisons la fonction prédéfinie **ImagePositionPatient** qui fournit les coordonnées X, Y, Z du premier pixel de chaque coupe dans l'espace patient, ce qui nous permet de trier les coupes par leur position physique réelle plutôt que par ordre de nom de fichier.

Certains patients ont été exclus en raison d'une orientation invalide (plan non axial) ou d'un nombre insuffisant de coupes (< 20), ramenant le nombre total des patients acceptés à 996 parmi les 1012 patients initiaux.

L'étape suivante est la conversion en unités Hounsfield, rendue possible grâce aux paramètres intégrés dans les fichiers DICOM comme mentionné précédemment.

Enfin, nous calculons la matrice affine pour enregistrer la position correcte et la taille de chaque voxel, et nous convertissons au format NIfTI pour obtenir notre volume 3D.

La base de données LIDC-IDRI ne dispose pas de masques pulmonaires ; c'est pourquoi la première étape de notre pipeline de segmentation a consisté à générer des masques pulmonaires qui serviraient ensuite de référence pour l'entraînement de notre réseau U-Net, afin de construire un modèle robuste.

3.2.6 Génération des masques

Méthode de segmentation

La méthode de segmentation utilisée pour la génération de masques repose sur des techniques classiques de segmentation en bio-imagerie ; la figure 3.1. illustre notre pipeline de segmentation.




FIGURE 3.1 – Diagramme illustratif résumant le pipeline de génération de masques mis en œuvre à l'aide de techniques classiques de bio-imagerie

Seuillage par intensité et suppression de l'air de fond

Nous avons utilisé une méthode de seuillage HU pour générer des masques pulmonaires primaires, qui capture approximativement la forme des poumons. Les poumons présentent des niveaux HU relativement faibles [-700 à -600] par rapport aux muscles et aux tissus mous, résultat de la forte concentration d'air dont la valeur HU est d'approximativement -1000. Cependant, le seuil doit être légèrement plus élevé, car les niveaux HU au sein des poumons peuvent augmenter selon l'état de santé des patients et leur état respiratoire [77]. L'étude de Kemerink et al. suggère un seuil entre -400 et -200 [77], ce qui nous permet de capturer plus d'informations sur la région des poumons, mais la présence de vaisseaux, de voies respiratoires et d'autres composants internes la rend de plus en plus susceptible au bruit [24]. Pour cette raison, nous avons choisi un seuil de -400 HU, une valeur couramment utilisée dans les applications de segmentation pulmonaire. Nous avons ensuite supprimé l'air extérieur incorrectement classifié en raison de son faible niveau HU, en éliminant toutes les régions de premier plan qui touchent les bordures de l'image

[40, 79].

Remplissage morphologique des trous

Après avoir obtenu une approximation de la forme des poumons, il est encore nécessaire d'éliminer les artefacts et les trous présents à l'intérieur des poumons. Nous effectuons pour cela une opération de reconstruction géodésique qui identifie les régions fermées à l'intérieur des poumons et les reclasse en pixels de premier plan [78].

Le processus commence par l'inversion des valeurs de pixels du masque, ce qui isole les trous à l'intérieur des poumons. Ensuite, nous marquons les régions situées à l'extérieur des limites pulmonaires, ce qui nous permet d'identifier les vrais pixels d'arrière-plan. Les régions fermées à l'intérieur des poumons restent alors inaccessibles depuis les bordures. Puis nous inversons à nouveau l'image, la zone marquée redevient arrière-plan tandis que les trous intérieurs restent en premier plan, complétant ainsi le masque pulmonaire.

Séparation des régions pulmonaires

L'étape suivante consistait à assurer une délimitation correcte des régions pulmonaires. L'un des défis rencontrés était la fusion des régions pulmonaires lorsqu'elles sont suffisamment proches. Pour résoudre ce problème, nous avons effectué une analyse des composantes connexes, où chaque région détectée dans chaque coupe se voit attribuer une étiquette unique [40]. Si plus de deux régions sont identifiées, nous pouvons au moins distinguer les deux moitiés pulmonaires, mais si une seule région est détectée, des étapes d'analyse supplémentaires sont nécessaires pour éviter la fusion.

Une analyse d'intensité est alors effectuée, où nous comptons les pixels de premier plan par colonne sur le masque binaire. Un nombre élevé de pixels par colonne indique que nous sommes dans la région pulmonaire, tandis qu'un nombre faible peut indiquer que nous sommes aux bords de l'image ou au niveau de l'espace médiastinal entre les deux régions qui se sont incorrectement connectées.

Maintenant que nous avons une meilleure compréhension de la façon d'identifier le médiastin, nous devons savoir où le localiser. Comme mentionné précédemment, une faible densité de pixels par colonne peut indiquer le médiastin ainsi que les bords latéraux de l'image. Pour isoler la zone d'intérêt, nous limitons la recherche à environ 60% de la largeur de l'image, ce qui nous place dans la zone où le médiastin est anatomiquement attendu. Nous effectuons ensuite une séparation par détection de vallée pour séparer les poumons droit et gauche.

Lorsque nous obtenons les deux parties séparées, nous appliquons une fermeture morphologique individuellement sur chacune pour nous assurer qu'aucune information pulmonaire n'est perdue après la séparation [78, 40]. Pour cette tâche, nous utilisons une fermeture morphologique agressive avec un rayon de dilatation de 5, afin de combler les espaces manquants et d'assurer qu'aucun tissu pulmonaire n'est perdu. Cette fermeture agressive est justifiée car chaque partie est traitée indépendamment [40], ce qui évite tout risque de fusion entre les deux régions. Les deux parties sont ensuite recombinaisonnées et une fermeture morphologique légère avec un rayon de dilatation de 2 est appliquée pour lisser les artefacts de bord introduits lors de la recombinaison.

Raffinement tridimensionnel Suite au traitement par coupe, une analyse des composantes connexes tridimensionnelle est appliquée sur le volume complet, où chaque région connectée se voit attribuer une étiquette unique. Seules les régions dont la position

spatiale correspond aux limites anatomiquement attendues sont conservées, les autres, comme le gaz sous-diaphragmatique, l'air intestinal et les artefacts de bord, sont rejetées [40]. Une fermeture morphologique volumétrique utilisant un élément structurant sphérique est ensuite appliquée pour combler les discontinuités mineures entre les coupes et assurer des contours spatialement cohérents sur les trois axes [78].

3.2.7 Rééchantillonnage Isotropique

Le rééchantillonnage est l'une des étapes de prétraitement les plus importantes de notre pipeline, car il affecte directement la compréhension par le U-Net de l'échelle spatiale réelle, un facteur particulièrement important pour la précision de l'étape de reconstruction 3D. Les scanners CT sont intrinsèquement anisotropes, la résolution dans le plan des axes X et Y étant généralement supérieure à celle de l'axe Z, qui correspond à l'épaisseur des coupes. Cette incohérence spatiale signifie que les structures apparaissent de tailles différentes selon l'axe considéré, ce qui affecte à la fois la précision de la segmentation du U-Net et la correction physique de la reconstruction 3D. Le rééchantillonnage isotropique standardise l'espacement des voxels sur les trois axes à une valeur uniforme par interpolation, garantissant que chaque voxel représente la même dimension physique dans toutes les directions et que les données volumétriques transmises au réseau sont spatialement cohérentes [80].

3.2.8 Écrêtage HU et Normalisation d'Intensité

Après la génération des masques pulmonaires, des étapes de normalisation sont nécessaires pour préparer les données à l'entraînement du réseau de neurones. Étant donné que notre objectif principal pour la prochaine étape est une tâche de segmentation, nous effectuons une normalisation de l'intensité, qui est essentielle pour garantir des résultats d'entraînement cohérents avec U-Net [81].

Avant la normalisation, nous appliquons d'abord un écrêtage HU, limitant la plage HU à $[-1000, 200]$, un intervalle qui capture les niveaux HU pertinents pour le tissu pulmonaire tout en éliminant les valeurs d'intensité non pertinentes des structures situées en dehors de cette plage. Nous appliquons ensuite une normalisation min-max, en mettant à l'échelle les valeurs écrêtées dans l'intervalle $[0, 1]$, une norme utilisée dans de nombreuses études [81, 82].

3.3 Segmentation pulmonaire

3.3.1 Le réseau U-Net 2D

La prochaine étape de notre pipeline de jumeau numérique consiste à construire un modèle robuste et généralisé pour la segmentation pulmonaire, ce qui nous amène à notre modèle d'apprentissage profond. Il existe dans la littérature de nombreux modèles d'apprentissage profond dédiés à cette tâche, mais la méthode la plus courante est l'architecture U-Net [5]. L'architecture U-Net repose sur des principes uniques qui en font un outil efficace pour l'imagerie médicale.

Le réseau U-Net présente une structure en forme de U, avec un chemin d'encodeur descendant, où à chaque niveau du chemin d'encodeur, un sous-échantillonnage des données est effectué, permettant au réseau d'apprendre les caractéristiques abstraites sous-

jacentes de la classe, et un chemin de décodeur, où un suréchantillonnage est effectué pour reconstruire les images segmentées. Une localisation précise de l’objet segmenté est rendue possible grâce à des connexions de saut à chaque niveau d’échantillonnage, qui fournissent un contexte spatial en plus de la segmentation apprise, permettant ainsi au réseau d’acquérir une localisation précise des objets et de leur forme [5].

Les diverses techniques d’augmentation des données appliquées aux images offrent une diversité des données même lorsque celles-ci sont limitées. Cela a rendu l’Unet particulièrement utile dans le domaine médical, même avec une diversité limitée de patients et des ressources diagnostiques restreintes [5, 83].

3.3.2 Gestion des données

Nous avons collecté des coupes axiales individuelles d’imagerie CT pour chaque patient, avec une limite maximale de 120 coupes par patient, afin de garantir que les données restaient gérables en termes de taille et de stockage, et de réduire le biais en faveur des patients présentant un nombre plus élevé de coupes (un nombre plus important de coupes par patient signifie que le réseau neuronal apprend davantage sur ce patient plutôt que sur les caractéristiques généralisées) [84]. Un ratio de 10 % de coupes vides a également été inclus afin que le réseau apprenne l’absence de tissu pulmonaire et ne génère pas de masque fantôme sur les coupes CT vides. Les volumes de tomodensitométrie ont été rééchantillonnés à $128 \times 128 \times 128$ voxels lors du prétraitement, puis des coupes axiales individuelles de 128×128 pixels ont été extraites de ces volumes pour l’entraînement de l’Unet. Cette résolution a été choisie pour trouver un équilibre entre la gestion de la mémoire, le niveau de détail spatial et un temps d’entraînement raisonnable, conformément aux pratiques utilisées dans l’entraînement de l’U-Net [85]. Ces données sont ensuite regroupées dans un seul fichier HDF5 afin d’accélérer le chargement pendant l’entraînement et de prendre en charge le grand nombre de coupes individuelles (106 000 fichiers).

La base de données a été divisée strictement par patient : 80 % pour l’entraînement (798 patients), 10 % pour la validation (99 patients), et 10 % pour les tests finaux (99 patients), ce qui constitue également une stratégie de division couramment utilisée [84, 85]. Les patients ont été affectés de manière aléatoire à chaque groupe à l’aide d’une graine fixe, et les listes d’identifiants de patients obtenues ont été enregistrées sous forme de fichier d’index des patients par groupe.

3.3.3 Augmentation des données

L’augmentation des données est un élément essentiel du prétraitement des données, car elle permet non seulement d’obtenir un ensemble de données plus large et plus diversifié, mais certaines techniques peuvent également être utilisées à des fins de régularisation et pour améliorer la robustesse du modèle.

Une augmentation agressive des données est appliquée à tous les échantillons d’apprentissage [83] à l’aide de la bibliothèque Albumentations [86], afin de garantir que l’apprentissage s’adapte au bruit et à la variation des données plutôt qu’à la mémorisation, à la localisation et aux indices texturaux, pour une meilleure généralisation.

Les étapes d’augmentation appliquées comprenaient une inversion horizontale et une rotation aléatoire dans une plage de $\pm 25^\circ$, simulant la variabilité réaliste du positionnement des patients [87]. Un flou gaussien et un bruit gaussien ont également été appliqués, ce qui constitue une augmentation de données standard en imagerie médicale [87]. Un

ajustement aléatoire de la luminosité et du contraste a également été effectué, simulant la variabilité du scanner en unités Hounsfield [83, 87].

Deux techniques de déformation ont été principalement appliquées pour améliorer la régularisation : la déformation élastique, une transformation non linéaire utilisée pour simuler la variation anatomique [5] ; et la distorsion de grille, qui est une déformation de maillage [86]. Un inversement vertical a également été mis en œuvre ; bien que controversé dans la segmentation pulmonaire, il a pu être utilisé comme technique de régularisation distorsive pour améliorer la robustesse.

Une autre transformation permettant d’améliorer la régularisation est Coarse Dropout [88], qui masque de manière aléatoire des régions rectangulaires de l’image d’entrée et du masque correspondant, forçant ainsi le modèle à s’appuyer sur le contexte anatomique global.

3.3.4 Architecture et apprentissage

Dans le cadre de ce projet, nous avons choisi de nous concentrer uniquement sur les modèles U-Net en 2D. Nous avons mis en œuvre la structure classique à quatre niveaux « encodeur-décodeur » avec des connexions de saut, en nous appuyant sur l’article de recherche de Ronneberger et al. publié en 2015 [5].

Afin d’obtenir un apprentissage plus stable, la normalisation par lots classique a été remplacée par une normalisation d’instance (*Instance Normalization*) avec paramètres affines apprenables. Ce choix est particulièrement adapté à l’imagerie médicale, où la grande taille des images impose souvent l’utilisation de petits batchs durant l’entraînement (ici une taille de 8). Dans ce contexte, la normalisation d’instance offre généralement une meilleure stabilité que la normalisation par lots [89].

Le suréchantillonnage est quant à lui assuré par des convolutions transposées, permettant au réseau d’apprendre directement la reconstruction spatiale des cartes de caractéristiques plutôt que d’utiliser une interpolation fixe. Le réseau débute avec 32 filtres et double progressivement le nombre de canaux à chaque niveau {32, 64, 128, 256} jusqu’à atteindre 512 filtres au niveau du bottleneck, avant de suivre une structure symétrique dans le décodeur.

3.3.5 Fonction de perte

La fonction de perte que nous avons choisie pour ce modèle est la « combo loss », introduite dans le travail de Taghanaki et al. [90] ; il s’agit d’une fonction de perte hybride qui combine l’entropie croisée binaire (BCE) et la perte de Dice.

$$L = \alpha \cdot L_{\text{BCE}} + (1 - \alpha) \cdot L_{\text{Dice}} \quad (3.1)$$

Pour ce projet, nous avons utilisé une version simplifiée de la formule dans laquelle nous avons utilisé les deux fonctions de perte à parts égales, avec $\alpha = 0,5$.

La perte combinée est un choix idéal pour la segmentation médicale, laquelle est confrontée au déséquilibre de classes, un phénomène courant en imagerie médicale [90, 91]. Ce déséquilibre se caractérise par la prédominance d’une classe sur une autre dans une image ; on peut l’observer par la présence de coupes vides ou de coupes capturant une très petite partie de la région pulmonaire, ce qui rend la détection et l’apprentissage difficiles pour un modèle.

Cette combinaison produit une fonction de perte tenant compte des bordures qui favorise les détails plus fins, ce qui améliore la précision de la segmentation [92], car la perte de Dice adoucit gère le déséquilibre des classes [90, 93] et optimise le chevauchement régional, tandis que la perte d’entropie croisée effectue une classification binaire au niveau des pixels [93] et améliore la calibration du modèle en produisant des probabilités prédites plus précises [91].

3.3.6 Métriques d’évaluation

Le modèle est évalué en utilisant quatre métriques calculées par lot sur les ensembles de validation et de test complets [94]. Toutes les métriques sont dérivées de la matrice de confusion du masque prédit binaire par rapport à la vérité terrain, basées sur les vrais positifs (TP), faux positifs (FP), vrais négatifs (TN) et faux négatifs (FN).

La métrique principale est le coefficient de similarité Dice, qui mesure le chevauchement entre le masque prédit et la vérité terrain, et est la métrique la plus largement utilisée pour l’évaluation de la segmentation d’images médicales en raison de sa robustesse au déséquilibre de classes [94] :

$$\text{DICE} = \frac{2\text{TP}}{2\text{TP} + \text{FP} + \text{FN}} \quad (3.2)$$

L’Intersection over Union (IoU), également connue sous le nom d’indice de Jaccard, est également calculée aux côtés du Dice comme mesure de chevauchement complémentaire, car elle pénalise la sur- et sous-segmentation plus strictement [94] :

$$\text{IoU} = \frac{\text{TP}}{\text{TP} + \text{FP} + \text{FN}} \quad (3.3)$$

La sensibilité et la spécificité sont également suivies pour évaluer séparément la capacité du modèle à détecter correctement le tissu pulmonaire et à rejeter correctement l’arrière-plan, respectivement [94] :

$$\text{Sensibilité} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (3.4)$$

$$\text{Spécificité} = \frac{\text{TN}}{\text{TN} + \text{FP}} \quad (3.5)$$

3.4 Reconstruction 3D surfacique

Passer de masques de segmentation 2D à un maillage 3D exploitable reste une étape délicate. Les prédictions réalisées coupe par coupe par le réseau ne produisent pas naturellement une surface continue, et certaines structures anatomiques, comme la trachée reliée aux poumons, compliquent davantage la reconstruction. Cette section présente les différents choix d’implémentation adoptés, depuis la reconstruction du volume jusqu’à l’export du maillage final, ainsi que les raisons ayant motivé ces choix en fonction de la littérature et des particularités des données LIDC-IDRI.

3.4.1 Aperçu du pipeline

Le pipeline se décompose en cinq étapes principales :

1. **Assemblage et correction d'orientation** du volume 3D à partir des prédictions 2D du U-Net.
2. **Suppression anatomique de la trachée**, qui demeure connectée aux poumons après la segmentation automatique.
3. **Extraction de surface** par l'algorithme des Marching Cubes, avec réordonnement des axes du volume en amont.
4. **Lissage** par filtre de Taubin pour éliminer l'effet d'escalier voxel.
5. **Simplification polygonale** par décimation quadrique (*QEM*).

Chaque étape produit un maillage intermédiaire permettant de suivre l'évolution des métriques géométriques tout au long du traitement, comme illustré dans la figure 3.2.




FIGURE 3.2 – Pipeline de reconstruction 3D surfacique : des logits U-Net au maillage pulmonaire final (.stl).

3.4.2 Préparation des données et gestion de l'espace métrique

Structure des données d'entrée

Les masques de segmentation sont générés par le U-Net et stockés dans un fichier HDF5, accompagné d'un index JSON permettant l'accès par patient sans chargement complet en mémoire.

Pour chaque patient, les coupes lung sont empilées selon l'axe Z afin de former un volume 3D (N_{coupes}, H, W). Une vérification de l'ordre des dimensions est effectuée pour garantir une reconstruction correcte.

L'espacement voxel est extrait des métadonnées NIfTI. Les données étant rééchantillonnées à 1 mm isotrope, les mesures sont directement exprimées en millimètres.

Stratégie de rééchantillonnage des prédictions

Le réseau U-Net produit des cartes de scores (logits) à la résolution d'entraînement 128×128 . Afin de les exploiter à la résolution native, un rééchantillonnage est nécessaire.

Deux stratégies sont possibles : soit seuillage à basse résolution suivi d'une interpolation au plus proche voisin, soit interpolation bilinéaire des logits vers la résolution native suivie du seuillage.

L'interpolation bilinéaire réalise une moyenne pondérée des quatre voisins les plus proches, produisant une transition continue des valeurs, tandis que le voisin le plus proche reproduit des valeurs discrètes sans lissage [95, 96].

L'approche retenue est l'interpolation bilinéaire des logits avant seuillage. Le caractère continu des scores permet de mieux préserver les variations aux frontières et d'obtenir des contours plus réguliers après seuillage [97].

À l'inverse, le seuillage préalable suivi d'une interpolation par voisin le plus proche introduit des artefacts en blocs de 128×128 , susceptibles d'être amplifiés lors de la reconstruction 3D par Marching Cubes [41].

3.4.3 Nettoyage anatomique : suppression de la trachée

La trachée constitue l'un des obstacles les plus récurrents dans la segmentation pulmonaire automatique. Bien qu'anatomiquement distincte des poumons, elle leur est reliée au niveau des bronches principales, et les réseaux entraînés sur des coupes thoraciques la segmentent souvent dans la même classe que le parenchyme pulmonaire. Sa présence dans le masque fusionne deux structures qui doivent rester séparées et perturbe les mesures volumétriques. L'approche retenue s'inspire des méthodes de post-traitement décrites dans la littérature [98, 99] et procède en quatre temps, comme décrit dans la figure 3.3.




FIGURE 3.3 – Pipeline de nettoyage anatomique : suppression de la trachée et séparation des poumons.

L'approche proposée s'inspire des méthodes décrites dans la littérature [98, 99, 100, 104, 103] et repose sur la combinaison de la détection anatomique, de la modélisation géométrique et d'opérations morphologiques ciblées..

Identification coupe par coupe

Sur chaque coupe axiale du volume, les composantes connexes 2D du masque binaire sont extraites afin d'identifier les différentes régions segmentées. Parmi celles-ci, la trachée est détectée selon deux critères anatomiques complémentaires.


Le premier critère est l'aire. La section transversale de la trachée étant nettement inférieure à celle des lobes pulmonaires, seules les régions dont l'aire est strictement

inférieure à 80 voxels sont retenues. Ce seuil, déterminé empiriquement, permet de cibler la lumière trachéale, notamment au niveau de la bifurcation bronchique où son diamètre est réduit.

Le second critère est la position centrale. La trachée étant située approximativement au centre du thorax, on impose que le barycentre de la région candidate se trouve à moins de 25% de la demi-largeur de l'image par rapport au centre horizontal, ce qui définit une zone centrale couvrant les 50% médiaux de l'axe transversal.

Les régions satisfaisant simultanément ces deux conditions sont supprimées du masque. Les coordonnées de leurs barycentres (z, c_y, c_x) sont conservées afin de reconstruire la trajectoire trachéale [99, 100].

La Figure 3.4 présente deux vues complémentaires de la trachée : 3.4a une représentation anatomique du thorax montrant la bifurcation bronchique et 3.4b une coupe axiale d'un masque CT segmenté avec la trachée détectée.



(a) Représentation anatomique de la trachée [1].

(b) Coupe axiale CT avec trachée détectée [99].

FIGURE 3.4 – Visualisation anatomique et radiologique de la trachée.

Modélisation de la trajectoire par régression linéaire

Les barycentres extraits à l'étape précédente forment un nuage de points (z, c_y, c_x) . Suivant le principe de suivi par centroïdes proposé dans la littérature [103, 98], une régression linéaire (polynôme de degré 1) est ajustée par la méthode des moindres carrés sur chaque composante.

On obtient alors les modèles suivants :

$$\hat{c}_x(z) = a_x z + b_x, \quad \hat{c}_y(z) = a_y z + b_y \quad (3.6)$$

où $z \in [z_{\min}, z_{\max}]$ désigne l'indice de coupe axiale, et où $\hat{c}_x(z)$ et $\hat{c}_y(z)$ représentent les positions estimées du centre de la trachée selon les axes horizontal et vertical à la coupe z . Les paramètres (a_x, b_x) et (a_y, b_y) sont les coefficients ajustés par moindres carrés à partir des centroïdes détectés.

Ce modèle remplit deux objectifs complémentaires. D'une part, il permet de régulariser les positions brutes obtenues coupe par coupe, susceptibles de présenter des fluctuations dues aux imperfections locales de segmentation. D'autre part, il définit une trajectoire lissée utilisée pour la suppression radiale, limitée à l'intervalle $[z_{\min}, z_{\max}]$, correspondant aux coupes où des centroïdes ont été effectivement détectés.

Cette contrainte empêche toute extrapolation en dehors de la zone observée et évite d'appliquer une suppression sur des régions où la trachée n'est pas présente. Enfin, la

validité du modèle est conditionnée par un nombre suffisant de points (au moins trois centroïdes), garantissant la robustesse de l’ajustement linéaire.

Suppression radiale le long de la trajectoire

Sur chaque coupe de la plage détectée ($z_{\min}$ à $z_{\max}$), un disque de rayon $r_{\text{trach}} = 17$ voxels centré sur la position prédite ($\hat{c}_y(z)$, $\hat{c}_x(z)$) est appliqué pour supprimer les voxels résiduels. Avec un espacement isotrope de 1 mm, ce rayon correspond à 17 mm.

Ce rayon est volontairement plus grand que le rayon anatomique interne moyen de la trachée chez l’adulte (environ 7.75 mm pour un diamètre moyen de 15.5 ± 2.1 mm [106]). Ce choix est justifié par le fait que l’étape 1 a déjà supprimé la quasi-totalité de la lumière trachéale, c’est-à-dire la partie interne de la trachée.

L’étape 3 sert donc uniquement à éliminer les résidus de voxels situés autour de la trajectoire estimée, notamment les connexions mal segmentées entre la trachée et les structures pulmonaires.

Un rayon plus faible pourrait laisser persister des artefacts, notamment au niveau de la bifurcation carénale, où la trachée se divise en deux bronches et présente un diamètre plus important. Contrairement à une érosion morphologique globale, qui agit uniformément sur l’ensemble du volume segmenté, cette méthode cible spécifiquement la région trachéale en s’appuyant sur des considérations anatomiques, ce qui limite les altérations des structures pulmonaires adjacentes [100].

Séparation morphologique des lobes

Après suppression de la trachée, les deux poumons peuvent rester partiellement connectés par de fines structures résiduelles au niveau du médiastin [104]. Afin de les dissocier, une érosion morphologique 3D itérative est appliquée, méthode largement utilisée pour la séparation pulmonaire dans la littérature [104, 105]. Un élément structurant sphérique de rayon 4 voxels a été retenu après validation empirique.

Le nombre d’itérations d’érosion est ajusté automatiquement en fonction du volume pulmonaire. Une heuristique basée sur le nombre total de voxels segmentés est utilisée afin d’équilibrer séparation efficace et préservation géométrique.

Après expérimentation sur différents volumes, un facteur de normalisation de 20 000 voxels a été retenu comme compromis stable. Le nombre d’itérations est défini par l’équation 3.7

$$n_{\text{iter}} = \text{clip}\left(\left\lfloor \frac{V_{\text{vox}}}{20\,000} \right\rfloor, 1, 2\right) \quad (3.7)$$

où V_{vox} représente le nombre de voxels actifs après suppression de la trachée. Cette formulation limite le nombre d’itérations entre 1 et 2 : une itération est suffisante pour les volumes modestes ($V_{\text{vox}} < 40\,000$), tandis que deux itérations sont appliquées pour les volumes plus importants présentant des connexions interlobaires plus épaisses.

L’érosion permet de rompre les connexions résiduelles, puis une analyse en composantes connexes 3D est effectuée pour identifier les groupes de voxels connectés.

Les deux plus grandes composantes sont conservées, sous la contrainte que chaque composante représente au moins 3 % du volume de la plus grande composante.

Ce seuil est volontairement conservateur : il reste largement inférieur à l’asymétrie anatomique normale (environ 55 % pour le poumon droit contre 45 % pour le gauche [106]). Il permet ainsi de préserver les deux poumons même en cas de déséquilibre pathologique, tout en éliminant les petites composantes résiduelles isolées.

3.4.4 Extraction de la surface par l’algorithme des Marching Cubes

Réordonnancement des axes et espacement anisotrope

Avant l’application de l’algorithme des Marching Cubes, le volume initialement organisé selon la convention (Z, H, W) , est réordonné en (H, W, Z) afin de respecter l’organisation des axes attendue par l’implémentation utilisée. Les espacements voxel sont réorganisés de manière cohérente et le triplet (s_H, s_W, s_Z) est fourni directement à l’algorithme. Les coordonnées des sommets du maillage sont ainsi obtenues directement en millimètres, sans transformation supplémentaire. Cette étape garantit une correspondance correcte entre le maillage reconstruit et l’anatomie du patient.

Un padding de deux voxels nuls est ensuite ajouté sur l’ensemble des faces du volume avant l’extraction de l’isosurface. Cette extension du domaine permet à la surface reconstruite de se fermer correctement au voisinage des frontières du volume. Lorsque le masque segmenté atteint directement les limites du domaine, l’algorithme peut produire des ouvertures sur la surface extraite, ce qui compromet la qualité topologique du maillage et peut perturber les étapes ultérieures de lissage ainsi que les calculs géométriques et volumétriques.

Paramétrage de l’isosurface

Le fonctionnement détaillé de l’algorithme des Marching Cubes ainsi que la justification du choix de la variante de Lewiner et al. ont été présentés dans l’état de l’art. Pour rappel, le volume est décomposé en cellules cubiques élémentaires. Pour chacune d’elles, une table de correspondance précalculée détermine la triangulation locale à partir de l’état de ses huit sommets. L’assemblage des triangles générés sur l’ensemble du volume permet ainsi d’obtenir une surface polygonale fermée et continue.

S’agissant d’un masque binaire, l’isovaleur (seuil d’extraction) est fixée à 0,5, point médian exact entre le fond (0) et le parenchyme pulmonaire (1), garantissant une isosurface alignée sur la frontière réelle de la segmentation [41].

La variante de Lewiner et al. a été retenue car elle résout les 33 cas topologiquement ambigus de l’algorithme original, susceptibles de générer des trous ou des surfaces non-manifold [43].

L’option `allow_degenerate=False` est également activée afin d’éliminer les triangles dégénérés, c’est-à-dire ceux dont les trois sommets sont colinéaires. La présence de tels triangles peut dégrader la qualité géométrique du maillage et perturber le calcul des normales.

Ces précautions permettent d’obtenir un maillage fermé, cohérent sur le plan topologique et suffisamment régulier pour les traitements ultérieurs. Elles contribuent également à garantir la fiabilité des calculs géométriques et volumétriques réalisés sur le modèle reconstruit.

3.4.5 Lissage par filtre de Taubin

Le maillage brut issu du Marching Cubes présente un artefact caractéristique lié à la discrétisation en voxels, les surfaces orthogonales des faces de voxel restent visibles sous forme d’un effet d’escalier. La solution la plus immédiate est le lissage laplacien,

qui déplace chaque sommet vers le barycentre de ses voisins. Cependant, ce filtre provoque un rétrécissement progressif et systématique du modèle, ce qui fausse les mesures volumétriques ultérieures.

Le filtre de Taubin [101] résout ce problème en couplant deux passes antagonistes. La première passe (facteur $\lambda = 0,5$) rapproche chaque sommet de son voisinage immédiat, atténuant les hautes fréquences spatiales. La seconde passe (facteur $\mu = -0,53$) contrebalance le rétrécissement introduit par la première. La condition théorique de préservation volumique $0 < \lambda < 1/|\mu|$ est respectée : $0 < 0,5 < 1/0,53 \approx 1,887$.

On applique ce filtre sur 20 itérations sur le maillage complet avant décimation, ce qui constitue un compromis entre atténuation suffisante de l'effet d'escalier voxel et préservation des détails anatomiques fins comme les scissures interlobaires.

3.4.6 Simplification polygonale par décimation quadrique (QEM)

Un maillage issu des Marching Cubes sur un volume pulmonaire de résolution 1 mm compte typiquement plusieurs centaines de milliers de faces. Un tel niveau de complexité est incompatible avec un usage interactif dans un navigateur Web ou une application embarquée, car les moteurs de rendu WebGL maintiennent généralement 60 images par seconde pour des maillages de l'ordre de 100 000 triangles sur un équipement standard [107], avec des performances encore plus limitées sur les appareils mobiles.

L'algorithme de décimation par métriques quadriques (QEM) de Garland et Heckbert [102] procède par contractions successives d'arêtes. À chaque étape, l'arête dont la suppression minimise une erreur quadratique mesurant l'écart entre la surface résultante et la surface originale est contractée en un unique sommet optimal. Cet algorithme est particulièrement bien adapté aux structures anatomiques, parce qu'il préserve mieux les zones de forte courbure (bords interlobaires, reliefs bronchiques) qu'un sous-échantillonnage uniforme.

La décimation est appliquée sur le maillage lissé post-Taubin, avec une cible fixée à 60 000 faces, seuil retenu car il s'inscrit dans les standards de complexité géométrique des logiciels de visualisation 3D interactive.

Métriques d'évaluation de l'erreur géométrique

L'erreur géométrique introduite par la réduction est quantifiée par les métriques HD95 et MSD, calculées par comparaison entre le maillage lissé pré-décimation (étape 03, lissage de Taubin) et le maillage final décimé par QEM (étape 04). Les deux surfaces sont représentées par un échantillon de 10 000 points tirés aléatoirement selon une distribution uniforme sur leur surface, afin de permettre un calcul efficace des distances entre surfaces.

Soient A et B les nuages de points échantillonnés respectivement sur le maillage pulmonaire lissé et sur le maillage réduit, $d_{A \rightarrow B}(i)$ la distance euclidienne du point $i \in A$ à son plus proche voisin dans B , et symétriquement $d_{B \rightarrow A}(i)$ pour $i \in B$. HD95 est la distance de Hausdorff au 95^e percentile, où P_{95} désigne le 95^e percentile d'un ensemble de distances unidirectionnelles [108, 109].

$$\text{HD95} = \max(P_{95}(d_{A \rightarrow B}), P_{95}(d_{B \rightarrow A})) \quad (3.8)$$

MSD (Mean Surface Distance) correspond à la moyenne des distances bidirectionnelles, où N désigne le nombre de points dans chaque nuage [110, 111].

$$\text{MSD} = \frac{1}{2N} \sum_{i=1}^N (d_{A \rightarrow B}(i) + d_{B \rightarrow A}(i)) \quad (3.9)$$

Le HD95 permet de quantifier les erreurs locales maximales sur le contour pulmonaire ; contrairement à la distance de Hausdorff standard (100^e percentile), qui est extrêmement sensible aux artefacts résiduels de surface, l'utilisation du 95^e percentile permet d'ignorer les déviations isolées pour se concentrer sur les écarts structurels significatifs de la géométrie pulmonaire. Le MSD donne quant à lui une mesure globale de la fidélité surfacique moyenne du maillage réduit par rapport au maillage lissé de référence. Ces deux indicateurs sont donc hautement complémentaires, un MSD très faible associé à un HD95 élevé révélerait une surface pulmonaire globalement fidèle mais présentant un défaut localisé important, tandis que leur progression conjointe et proportionnelle témoigne d'une dégradation homogène et uniforme de la surface après décimation QEM.

L'ensemble de ces métriques (HD95, MSD, score qualité, nombre de faces et sommets, volume en mL, surface en cm², taille de fichier et temps d'exécution) est sauvegardé dans un fichier JSON structuré par étape pour chaque patient, permettant une comparaison systématique de l'impact de chaque traitement sur la géométrie du maillage final.

3.5 Reconstruction volumique

Après avoir obtenu un maillage surfacique unique représentant les deux poumons, il est nécessaire de le décomposer en deux modèles indépendants, l'un pour le poumon droit et l'un pour le poumon gauche. Cette séparation est indispensable pour des simulations biomécaniques réalistes, car chaque poumon possède sa propre cinématique respiratoire. Une fois séparés, chaque maillage surfacique est transformé en un maillage volumique tétraédrique, support des simulations par éléments finis (FEM).

3.5.1 Extraction des composantes connexes

L'extraction des composantes connexes du maillage triangulaire est une étape essentielle permettant d'identifier les différentes surfaces ou objets distincts présents dans le modèle. Cette opération repose sur la fonction `connected_components` du module `scipy.sparse.csgraph`, utilisée en interne par la bibliothèque Trimesh [112].

La méthode se déroule en deux étapes principales :

1. **Construction du graphe dual du maillage**

Chaque triangle du maillage est représenté par un nœud du graphe. Deux nœuds sont reliés par une arête si les triangles correspondants partagent une arête géométrique commune. Ce graphe, appelé *face adjacency graph*, modélise les relations topologiques de voisinage entre les triangles.

2. **Identification des composantes connexes via Union-Find**

La détection des composantes connexes est réalisée à l'aide de la structure de données *Union-Find* (ou Disjoint-Set Union). Initialement chaque triangle est placé dans son propre ensemble, puis pour chaque paire de triangles adjacents dans le graphe dual une opération *Union* fusionne leurs ensembles respectifs.

L'opération *Find*, optimisée par compression de chemin et union par rang, permet ensuite de déterminer efficacement le représentant de l'ensemble auquel appartient chaque triangle. Cette approche garantit une complexité temporelle amortie quasi-linéaire en $O(n \cdot \alpha(n))$, où n est le nombre de triangles et $\alpha(n)$ désigne la fonction inverse d'Ackermann [45], une fonction qui croît extrêmement lentement.

Cette méthode permet d'extraire de manière robuste et efficace les différentes parties connexes du maillage, même dans le cas de modèles complexes ou comportant de nombreuses îles topologiques.

3.5.2 Identification anatomique par centroïde

Après avoir extrait les composantes connexes, il reste à déterminer laquelle correspond au poumon droit et laquelle correspond au poumon gauche. Cette identification est réalisée automatiquement par analyse de la position spatiale de chaque composante, sans annotation manuelle.

Pour chaque composante extraite, nous calculons son centroïde (point central) comme montré dans l'équation 3.10 qui est défini comme la moyenne arithmétique des coordonnées de ses N sommets :

$$\mathbf{C} = \frac{1}{N} \sum_{i=1}^N \begin{pmatrix} x_i \\ y_i \\ z_i \end{pmatrix} \quad (3.10)$$

où (x_i, y_i, z_i) désignent les coordonnées du i -ème sommet du maillage. Cette quantité est calculée directement par la bibliothèque Trimesh [112].

Dans notre implémentation, nous utilisons uniquement la coordonnée X du centroïde pour prendre la décision. Selon la convention d'orientation médicale LPS (Left-Posterior-Superior), couramment utilisée dans les données DICOM [48] :

L'axe X augmente vers la gauche du patient, de sorte que le poumon dont le centroïde présente la plus grande valeur en X est identifié comme le poumon gauche, et celui dont la valeur est la plus faible comme le poumon droit.

Cette heuristique géométrique est sans paramètre et s'appuie directement sur la sémantique de l'espace LPS, garantissant une identification correcte dès lors que les données CT sont réorientées en amont du pipeline.

Correction topologique des maillages surfaciques

Si le maillage n'est pas étanche (*non-watertight*), les arêtes de bord libres sont identifiées et les trous résiduels sont comblés par interpolation locale de la surface [112]. L'étanchéité est une condition nécessaire pour délimiter un volume fini et permettre l'application des algorithmes de maillage volumique sur un domaine fermé. Dans un contexte anatomique, cette étape est conservée comme mesure de sécurité car les structures pulmonaires pathologiques (notamment la présence éventuelle de tumeurs ou d'anomalies morphologiques) peuvent induire des irrégularités locales de surface susceptibles de compromettre la continuité du maillage.

3.5.3 Préparation topologique et représentation géométrique

Avant toute étape de tétraédrisation, la génération d'un maillage volumétrique requiert une représentation géométrique continue et orientée du domaine. Les maillages surfaciques issus de la segmentation sont au format STL et décrivent uniquement une géométrie triangulée, sans topologie explicite ni organisation hiérarchique entre courbes, surfaces et volumes, et sans garantie d'orientation cohérente des normales. Gmsh reconstitue cette structure au moyen de deux opérations successives [60].

Classification des surfaces (`classifySurfaces`). L'appel à `classifySurfaces` analyse l'angle dièdre entre les normales de chaque paire de triangles adjacents, lorsque cet angle dépasse le seuil fixé, l'arête commune est déclarée *arête vive* et devient une frontière entre deux patches géométriques distincts ; dans le cas contraire, les deux triangles sont fusionnés en une surface lisse continue.

Dans notre implémentation, le seuil est fixé à π rad, ce qui désactive toute détection d'arête vive et traite l'intégralité du maillage triangulaire comme une surface unique. Ce choix est justifié par la nature des surfaces pulmonaires, dépourvues d'arêtes géométriques franches, et par la nécessité d'éviter une fragmentation artificielle en patches qui perturberait la construction de la topologie BRep.

Construction de la géométrie BRep (`createGeometry`). À partir de cette classification, la fonction `createGeometry` construit une représentation par les bords (BRep) [51, 113] en plusieurs étapes. Les sommets du maillage surfacique sont d'abord enregistrés comme points gmsh via `addPoint`. Les arêtes reliant ces points sont ensuite créées par `addLine`, puis regroupées en boucles fermées (`addCurveLoop`) définissant chaque face polygonale. Chaque boucle donne lieu à une surface plane (`addPlaneSurface`), et l'ensemble des surfaces est assemblé en une `SurfaceLoop` fermée. Enfin, `addVolume` encapsule cette enveloppe pour créer le volume intérieur sur lequel l'algorithme de tétraédrisation sera appliqué.

3.5.4 Algorithme de génération volumétrique

Méthode Frontal-Delaunay 3D.

Le maillage tétraédrique est généré par l'algorithme **Frontal-Delaunay 3D** de Gmsh (`Mesh.Algorithm3D = 4`), qui combine deux stratégies complémentaires [60] :

1. **Méthode des fronts avancants (*Advancing Front Method*, AFM)**

Introduite par Löhrner et Parikh [53], elle propage un front depuis la surface de la BRep vers l'intérieur du domaine en insérant successivement des tétraèdres dont les faces appartiennent au front courant. Cette approche garantit que les éléments de bord respectent fidèlement la géométrie surfacique, propriété essentielle pour préserver les détails anatomiques fins, notamment au niveau des scissures interlobaires.

2. **Méthode de raffinement de Delaunay**

Cette méthode [59] consiste à insérer des *points de Steiner* à l'intérieur du domaine. Il s'agit de sommets supplémentaires créés par l'algorithme et ne faisant pas partie de la géométrie d'entrée. Ces points sont insérés de manière stratégique

afin de respecter le critère de la *sphère vide*, selon lequel aucun sommet ne doit se trouver à l'intérieur de la sphère circonscrite à un tétraèdre.

Cette insertion permet de minimiser les angles diédraux trop aigus et d'améliorer le conditionnement numérique des éléments intérieurs du maillage.

L'algorithme *Frontal-Delaunay* exploite ainsi la complémentarité entre l'**approche frontale**, qui assure une bonne conformité géométrique au voisinage de la surface, et le **raffinement de Delaunay**, qui améliore la qualité des tétraèdres dans le volume intérieur.

Paramètres de discrétisation

La taille caractéristique h d'un élément tétraédrique correspond au diamètre de sa *sphère circonscrite* (sphère passant par ses quatre sommets). Elle constitue le paramètre de contrôle principal de la résolution spatiale du maillage. Cette sphère joue un rôle central dans les algorithmes de type Delaunay, car elle intervient directement dans le critère de *sphère vide* : un tétraèdre est considéré comme valide si aucun autre sommet du maillage ne se trouve à l'intérieur de sa sphère circonscrite [59].

Gmsh contrôle la génération du maillage à l'aide de deux bornes globales : une taille minimale $h_{\min}$, en dessous de laquelle aucun élément n'est créé, et une taille maximale $h_{\max}$, qui fixe la résolution cible sur l'ensemble du domaine. Le choix $h_{\min} < h_{\max}$ procure à l'algorithme une flexibilité locale tout en évitant la création d'éléments excessivement petits, qui dégraderait le conditionnement numérique du système linéaire associé à la simulation par éléments finis [114].

Dans notre cas, la taille cible est fixée à $h_{\text{cible}} = 7,0 \text{ mm}$. Les bornes utilisées sont définies comme suit :

$$h_{\min} = 0,8 \times h_{\text{cible}} = 5,6 \text{ mm}, \quad (3.11)$$

$$h_{\max} = h_{\text{cible}} = 7,0 \text{ mm}. \quad (3.12)$$

Le ratio $h_{\min}/h_{\max} = 0,8$ a été déterminé empiriquement. Un ratio trop faible ($\leq 0,5$) induit une forte variabilité des tailles d'éléments voisins, ce qui dégrade les métriques de qualité, notamment l'aspect ratio, aux interfaces. À l'inverse, un ratio égal à 1 impose une taille strictement uniforme, contraignant excessivement l'algorithme Frontal-Delaunay et augmentant le taux de rejet des points de Steiner en frontière [59, 55]. Le choix de 0,8 constitue ainsi un compromis entre uniformité et flexibilité du maillage, favorisant la convergence de l'optimisation Netgen sans dégradation géométrique.

Le choix $h_{\text{cible}} = 7,0 \text{ mm}$ s'inscrit dans la gamme généralement utilisée pour les maillages éléments finis pulmonaires à l'échelle de l'organe entier, typiquement comprise entre 3 et 10 mm [65, ?]. Le nombre d'éléments suit la loi $N \propto V/h^3$ [55], ce qui implique qu'une réduction de h d'un facteur deux augmente le nombre d'éléments d'un facteur huit, rendant rapidement les simulations mécaniques à l'échelle de l'organe très coûteuses. De plus, les incertitudes de segmentation étant de l'ordre du millimètre [115], un raffinement submillimétrique n'apporterait qu'un gain limité en précision. Ainsi, $h = 7,0 \text{ mm}$ représente un compromis entre précision géométrique, robustesse numérique et coût computationnel, validé expérimentalement dans cette étude.

Les heuristiques automatiques de Gmsh (`CharacteristicLengthFromCurvature`, `CharacteristicLengthFromBoundary`) sont désactivées afin d'éviter un raffinement local non contrôlé basé sur la géométrie de la B-Rep.

3.5.5 Optimisation du maillage.

Deux passes d'optimisation sont appliquées successivement après la génération. La première consiste en un lissage de Laplace intégré à Gmsh [60], exécuté sur plusieurs itérations (`Mesh.Smoothing = 5`). À chaque itération, chaque nœud intérieur est repositionné vers le barycentre de ses voisins immédiats, ce qui permet de réduire les distorsions locales sans modifier la connectivité du maillage. Cette étape est donc purement géométrique, puisqu'elle n'affecte ni le nombre d'éléments ni leur topologie.

Le nombre d'itérations a été fixé à 5 à l'issue de tests empiriques, ce qui a permis d'obtenir un compromis satisfaisant entre amélioration de la qualité géométrique et coût de calcul.

La seconde passe fait appel au moteur Netgen (`Mesh.OptimizeNetgen = 1`) [63]. Contrairement au lissage de Laplacien qui ne déplace que les nœuds, Netgen applique des *opérations topologiques locales* qui modifient la connectivité elle-même. Ces opérations comprennent notamment :

- Les *permutations d'arêtes* (*edge swaps*) : une arête partagée par plusieurs tétraèdres est supprimée et recrée dans une configuration différente qui améliore la qualité des éléments environnants [61].
- Les *contractions de nœuds* : deux nœuds proches sont fusionnés en un seul, supprimant les tétraèdres dégénérés trop petits qui se seraient formés dans une région localement surpeuplée [63].

Ces deux étapes sont complémentaires : le lissage de Laplace corrige la position des nœuds dans une connectivité donnée, tandis que l'optimisation Netgen améliore directement la structure du maillage lorsque les ajustements géométriques seuls sont insuffisants.

3.5.6 Validation du maillage volumique par critères FEM

Un maillage volumique généré automatiquement peut contenir des éléments géométriquement dégénérés susceptibles d'altérer la précision numérique et la stabilité des simulations par éléments finis. Afin de garantir son adéquation à des applications biomédicales, une validation quantitative est effectuée à travers trois familles de critères complémentaires, inspirées de la bibliothèque de référence Verdict [64]. Ces critères évaluent respectivement la fidélité géométrique globale, la qualité de forme des éléments et la détection de configurations dégénérées.

Conservation du volume : cohérence géométrique globale

Le premier critère vise à vérifier que le processus de discrétisation volumique conserve correctement la géométrie de l'objet d'origine. Cette étape est essentielle car toute erreur systématique de volume se répercute directement sur les propriétés physiques simulées (masse, diffusion, contraintes). Le volume d'un tétraèdre T de sommets $\mathbf{v}_0, \mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$ est donné par :

$$V_T = \frac{1}{6} |\det(\mathbf{v}_1 - \mathbf{v}_0, \mathbf{v}_2 - \mathbf{v}_0, \mathbf{v}_3 - \mathbf{v}_0)| \quad (3.13)$$

Le volume total du maillage volumique est ensuite obtenu par sommation $V_{\text{tet}} = \sum_i V_{T_i}$. Ce volume est comparé au volume surfacique de référence V_{surf} , estimé à partir

du maillage de surface via Trimesh [112]. L'erreur relative est définie par :

$$\varepsilon_V = \frac{|V_{\text{tet}} - V_{\text{surf}}|}{V_{\text{surf}}} \times 100 \quad (3.14)$$

Un seuil de 5 % est généralement considéré comme acceptable dans le contexte des organes mous en imagerie médicale [65]. Ce critère garantit donc la cohérence globale entre la géométrie surfacique initiale et sa discrétisation volumique.

Aspect Ratio : contrôle de la qualité de forme

Si la conservation du volume garantit une fidélité géométrique globale, elle ne suffit pas à assurer la qualité numérique du maillage. Des tétraèdres très allongés ou aplatis peuvent en effet dégrader significativement la précision et la stabilité de l'approximation par éléments finis. C'est pourquoi un second critère, l'*Aspect Ratio* β , est utilisé pour évaluer la forme des éléments. L'Aspect Ratio 3.15 mesure le degré d'élongation d'un tétraèdre et se définit comme le rapport entre le rayon de sa sphère circonscrite R et le triple du rayon de sa sphère inscrite r [58] :

$$\beta = \frac{R}{3r} \quad (3.15)$$

La sphère circonscrite passe par les quatre sommets du tétraèdre, tandis que la sphère inscrite est tangente à ses quatre faces. Le rapport β compare donc la taille du tétraèdre « vu de l'extérieur » à sa capacité à contenir une sphère en son centre. La valeur idéale $\beta = 1$ correspond à un tétraèdre régulier. Plus β augmente, plus l'élément devient déformé (allongé ou aplati), ce qui détériore le conditionnement des matrices élémentaires, réduit la précision des calculs numériques et peut entraîner des difficultés de convergence lors des simulations. Le rayon de la sphère inscrite est calculé par 3.16 :

$$r = \frac{3 V_T}{A_{\text{tot}}} \quad (3.16)$$

où V_T est le volume du tétraèdre et A_{tot} la somme des aires de ses quatre faces. Le rayon de la sphère circonscrite R est quant à lui obtenu à partir des coordonnées des sommets via une formulation vectorielle classique [58]. Selon la littérature [66], un maillage est généralement considéré comme acceptable pour des simulations lorsque la grande majorité des tétraèdres vérifient $\beta < 3$. Dans cette étude, nous avons retenu un critère plus strict : moins de 5 % des tétraèdres sont autorisés à dépasser ce seuil. Cette tolérance a été déterminée expérimentalement à partir de plusieurs essais de maillage. Ce choix constitue un compromis entre qualité numérique et coût de calcul. Il est suffisamment exigeant pour garantir des éléments de bonne qualité géométrique et des résultats de simulation fiables, tout en restant compatible avec la génération automatique du maillage par l'algorithme Frontal-Delaunay.

Détection des éléments *sliver*

Même lorsque les critères globaux de forme sont satisfaits, certains éléments peuvent présenter des configurations dégénérées difficiles à détecter via l'Aspect Ratio seul. C'est

notamment le cas des tétraèdres dits *sliver*, caractérisés par un volume quasi nul malgré des arêtes de longueurs comparables. La détection et l'élimination de ces éléments est une étape classique de la validation des maillages, comme le montrent par exemple les travaux d'optimisation de la qualité menés chez Sandia National Laboratories [116]. Ces éléments sont particulièrement problématiques car ils induisent un mauvais conditionnement de la matrice de rigidité et peuvent déstabiliser les solveurs numériques [59]. Pour les identifier, on introduit un volume normalisé :

$$V_{\text{norm}} = \frac{V_T}{\bar{\ell}^3} \quad (3.17)$$

où $\bar{\ell}$ désigne la longueur moyenne des arêtes du tétraèdre. Cette normalisation permet une mesure indépendante de l'échelle. Un tétraèdre régulier atteint une valeur $V_{\text{norm}} \approx 0,118$. Dans ce travail, un élément est considéré comme *sliver* si $V_{\text{norm}} < 10^{-3}$, conformément aux pratiques recommandées dans la littérature de maillage [64]. La qualité du maillage exige que la proportion de tels éléments reste inférieure à 1 %.

Verdict global : critère de conformité

Les trois critères précédents sont complémentaires et doivent être considérés simultanément afin d'évaluer la qualité globale du maillage. Le maillage est ainsi déclaré conforme à une utilisation en simulation FEM médicale si :

$$\text{Valide} \iff \varepsilon_V \leq 5 \% \wedge \text{AR}_{>3} < 5 \% \wedge \text{Slivers} < 1 \% \quad (3.18)$$

Cette combinaison permet d'assurer à la fois la fidélité géométrique globale, la qualité numérique des éléments et la robustesse face aux configurations dégénérées. Ensemble, ces critères constituent une base fiable pour la validation des maillages volumiques destinés à des simulations biomédicales par éléments finis.

3.6 Simulation respiratoire pulmonaire

Afin de rendre le modèle 3D du poumon développé opérationnel, nous avons mis en place une version simplifiée de la simulation respiratoire utilisant les mouvements pulmonaires fondamentaux dans le cadre du *framework* SOFA.

Pour cette tâche, nous avons adopté la **condition aux limites de déplacement** (DBC), qui est une simulation basée sur le déplacement géométrique des éléments finis. Nous avons conçu une approche heuristique estimant les déplacements nécessaires à partir de mesures physiologiques au niveau de la population et des propriétés géométriques du maillage.

Ce choix de conception a été adopté pour éviter l'utilisation de données CT dynamiques spécifiques au patient, qui seraient autrement nécessaires pour un champ de déplacement basé sur les données, afin de réduire la complexité du pipeline tout en restant physiologiquement correct.

3.6.1 Paramètres de déplacement

Comme indiqué dans la section consacrée à l'anatomie, le mouvement respiratoire pulmonaire est dominé par deux composantes principales : le déplacement **supérieur-**

inférieur (SI), induit par la contraction du diaphragme, et l'**expansion latérale**, induite par le mouvement de la cage thoracique.

Amplitude de déplacement supérieur-inférieur

L'amplitude fonctionnelle normale du diaphragme lors de la respiration normale est comprise entre 10 et 25 mm [117, 118]. L'amplitude réelle de déplacement supérieur-inférieur est toutefois influencée par de nombreux facteurs tels que l'âge, la taille, le sexe et l'état de santé ; il est donc assez difficile d'utiliser une valeur fixe pour tous, et c'est pourquoi nous avons choisi d'utiliser une valeur adaptative plutôt qu'une valeur fixe. Comme il s'agit d'une approximation, nous avons décidé d'utiliser un pourcentage de la hauteur totale du poumon pour estimer l'excursion du diaphragme, tout en veillant à ce que celle-ci reste dans la plage prévue et en produisant un changement de volume constant pendant la respiration courante.

Amplitude ventrale/latérale

L'amplitude latérale correspond aux déplacements ventraux de la surface de la cage thoracique lors d'une respiration normale ; elle est estimée entre 3 et 5 mm [119]. Étant donné que cette amplitude est relativement faible, nous avons jugé qu'il suffirait d'utiliser une valeur fixe, que nous avons fixée à 5 mm.

Il convient de noter que la composante latérale du mouvement respiratoire de la cage thoracique est légèrement plus faible (1 à 2 mm), car le déplacement dominant de la cage thoracique pendant l'inspiration est crânio-ventral plutôt que purement latéral [119] ; nous avons également fixé cette valeur à 2 mm.

Il convient de bien préciser que toutes ces valeurs ne sont que des estimations et ne reflètent pas nécessairement les valeurs réelles ; elles ont été choisies comme valeurs satisfaisantes car elles répondent aux contraintes utilisées pour les validations, à savoir : des valeurs s'inscrivant dans la plage prévue et des changements de volume cohérents pendant la respiration tidale.

3.6.2 Fonction de pondération

Comme décrit dans la section consacrée à l'anatomie, l'expansion pulmonaire n'est pas uniforme d'un point de vue anatomique. La partie supérieure du poumon est contrainte par la cage thoracique et les structures thoraciques, ne présentant pratiquement aucun mouvement à proximité de la trachée, tandis que l'expansion maximale se produit à la base. Pour modéliser cette contrainte physiologique, nous adoptons une approche basée sur des conditions aux limites de déplacement utilisant une **fonction de pondération** qui simule le comportement de la distribution de pression lors d'une respiration normale. Comme nous n'utilisons pas d'approche par éléments finis, cette approche heuristique agit comme une reproduction approximative du comportement normal de la distribution de pression, mais uniquement sur le plan géométrique.

On attribue à chaque nœud i du maillage un poids scalaire $w_i \in [0, 1]$ qui module l'amplitude de son déplacement :

$$w(z) = \frac{z - z_{\min}}{z_{\max} - z_{\min}} \quad (3.19)$$

où z_i est la coordonnée verticale du nœud i , et $z_{\min}$, $z_{\max}$ sont les limites inférieure et supérieure du maillage pulmonaire. Cela attribue $w = 1$ à la base du diaphragme (amplitude maximale) et $w = 0$ au sommet (aucun déplacement), comme le montre la figure 3.5.




FIGURE 3.5 – Illustration de la fonction de pondération $w(z)$ appliquée au maillage pulmonaire. En dessous, le poids croît linéairement de 0 à 1 jusqu'à la base du diaphragme, où le déplacement est maximal (condition aux limites DBC).

3.6.3 Courbe respiratoire

Le cycle respiratoire suit une courbe sinusoïdale d'inspiration/expiration, avec une durée d'inspiration de 1,3 s et une durée d'expiration de 2,6 s, ce qui donne une période de cycle de 3,9 s et une fréquence d'environ 15 respirations/min. Cela s'inscrit dans la fourchette normale bien établie de la respiration tidale chez l'adulte au repos, comprise entre 12 et 20 respirations par minute [120]. Le rapport inspiration/expiration de 1 :2 correspond à la valeur de référence clinique standard pour une respiration tidale normale [121, 122, 123].

3.6.4 Conclusion

Ce chapitre a présenté le pipeline complet mis en place pour la segmentation et la reconstruction tridimensionnelle de la structure externe des poumons. À partir d'un pré-traitement des images CT (conversion HU, rééchantillonnage isotropique et passage au format NIfTI), nous avons construit une approche hybride.

D'un côté, des méthodes classiques de bio-imagerie ont été utilisées pour générer des masques de référence fiables sur le dataset LIDC-IDRI. De l'autre, ces masques ont servi à entraîner une architecture d'apprentissage profond de type U-Net 2D, dont les performances ont été évaluées à l'aide de métriques standards (Dice, IoU, sensibilité, spécificité).

Les segmentations obtenues ont ensuite été exploitées dans un pipeline de reconstruction 3D surfacique et volumique. Celui-ci inclut une reconstruction de surface par Mar-

ching Cubes, suivie d'un lissage de Taubin et d'une décimation par QEM, afin d'obtenir une géométrie stable et exploitable. Cette représentation surfacique est ensuite convertie en maillage volumique tétraédrique, adapté aux simulations par éléments finis et aux analyses géométriques.

Une fois ce cadre méthodologique établi, il est désormais nécessaire de confronter ces choix aux résultats expérimentaux obtenus sur les données.

Chapitre 4

Résultats et discussion

4.1 Introduction

Dans cette section, nous présenterons les résultats obtenus tout au long du projet et en proposerons une analyse détaillée, tout en décrivant l’environnement de travail dans lequel ce projet a été réalisé.

Nous commencerons par présenter et analyser les résultats obtenu du modèle UNet 2D que nous avons implémenté, ainsi qu’à sa validation sur les deux ensembles de données externes : le premier est l’ensemble LUNA16, qui contient 888 tomodensitométries issues à l’origine de l’ensemble de données LIDC-IDRI ; nous avons également effectué la validation sur un autre ensemble de données comprenant 20 volumes de tomodensitométrie annotés par des radiologues.

Nous évaluerons ensuite la qualité de la reconstruction de surface 3D obtenue à travers l’algorithme de Marching Cubes et discuterons des différents paramètres que nous avons utilisés pour réaliser cette évaluation.

4.2 Environnement de travail et outils utilisés

Le projet a été mis en œuvre à l’aide d’une multitude de ressources locales et dans le cloud, ainsi que de divers logiciels ; nous présenterons donc dans la section suivante les outils matériels et logiciels utilisés tout au long du projet.

4.2.1 Ressources matérielles

- Ordinateur portable **Dell G3** équipé d’un processeur Intel Core i7-9750H cadencé à 2,60 GHz, de 16 Go de RAM et d’une carte graphique dédiée NVIDIA GeForce GTX 1660 Ti Max-Q avec 6 Go de mémoire vidéo (VRAM), fonctionnant sous un système d’exploitation Windows 64 bits.
- Ordinateur portable **Lenovo IdeaPad Gaming** équipé d’un processeur Intel Core i5-10300H cadencé à 2,50 GHz, de 16 Go de mémoire vive et d’une carte graphique dédiée NVIDIA GeForce GTX 1650 Ti dotée de 4 Go de mémoire vidéo, fonctionnant sous le système d’exploitation Windows 64 bits.
- **Google Colaboratory** (Colab) a été utilisé pour exploiter son GPU NVIDIA Tesla T4, offrant un environnement cloud gratuit permettant d’exécuter l’intégralité du pipeline sans infrastructure locale dédiée.

4.2.2 Ressources logicielles

- **NBIA Data Retriever** utilisé pour télécharger l'ensemble de données LIDC-IDRI depuis The Cancer Imaging Archive (TCIA).
- **Gmsh** [60] utilisé pour générer le maillage volumétrique tétraédrique à partir des maillages surfaciques STL, via son API Python et l'algorithme Frontal-Delaunay. Les fichiers produits au format `.msh` sont directement compatibles avec les solveurs éléments finis.
- **SOFA Framework** [124] (*Simulation Open Framework Architecture*), framework open source spécialisé dans la simulation physique de tissus mous, utilisé pour la simulation des maillages volumiques pulmonaires générés.
- **Hugging Face Hub** [125] utilisé pour accéder aux poids pré-entraînés du modèle U-Net et aux données LIDC-IDRI hébergées sur la plateforme.

4.2.3 Développement

- **Python** a été utilisé comme langage de programmation principal, accompagné de bibliothèques spécialisées parmi lesquelles **PyTorch** [126] pour l'inférence du réseau U-Net sur GPU, **Trimesh** [112] pour la reconstruction et le traitement des maillages 3D (Marching Cubes, lissage de Taubin, décimation QEM), et **SciPy** [127] pour les transformations morphologiques appliquées lors de la suppression de la trachée.
- **PyTorch** [126] : framework d'apprentissage profond utilisé pour l'entraînement et l'inférence du réseau U-Net.
- **NumPy** [128] : bibliothèque de calcul numérique utilisée pour la manipulation des volumes segmentés et le calcul des métriques géométriques.
- **SciPy** [127] : utilisée pour les transformations morphologiques sur les masques binaires, notamment via `distance_transform_edt` lors de la suppression de la trachée.
- **Hugging Face Hub** [125] utilisé comme plateforme centrale du projet : les données LIDC-IDRI prétraitées, les poids pré-entraînés du modèle U-Net ainsi que l'ensemble des résultats générés (maillages STL, fichiers de métriques JSON, maillages volumiques `.msh`) y sont hébergés et accessibles via la bibliothèque `huggingface_hub`.
- **Trimesh** [112] : bibliothèque de traitement de maillages 3D utilisée pour l'extraction de surface par Marching Cubes, le lissage de Taubin, la décimation QEM et la validation de la topologie watertight.

4.3 Paramètres d'entraînement

Le modèle s'entraîne en 70 époques au total, avec une taille de lot de 8, traitant 10 704 lots par époque, soit un total de 85 630 coupes d'entraînement provenant de 798 patients. L'ensemble de validation comprend 99 patients avec 10 736 coupes, et l'ensemble de test comprend 99 patients avec 10 454 coupes, sur un ensemble de données total de 106 820 coupes provenant de 996 patients. L'arrêt anticipé est appliqué après 20 époques sans amélioration, avec un compteur tolérant lors du redémarrage cosinus qui décrémente le compteur de deux.

4.4 Résultats de la méthode de segmentation proposée

L'Unet que nous avons mis en œuvre a été entraîné pendant un total de 39 époques avant un arrêt anticipé après 23 époques sans amélioration, ce qui fait de la 7^{ème} époque celle présentant le modèle le plus performant. Le graphique de la figure 4.1 présentant la courbe de perte montre un apprentissage stable avec une légère augmentation de la perte de validation au fur et à mesure de l'apprentissage, ce qui a été attribué à la forte sensibilité de la perte BCE aux erreurs plutôt qu'à des symptômes de sur apprentissage, comme le montrent les résultats Dice de la figure 4.2 qui sont restés stables avec une stagnation apparente, ce qui confirme la bonne qualité de l'apprentissage du modèle et le caractère approprié de l'arrêt anticipé.




FIGURE 4.1 – Un graphique illustrant la courbe de perte d'apprentissage et de validation tout au long de l'apprentissage




FIGURE 4.2 – Un graphique présentant les scores Dice globaux pour l'entraînement et la validation, ainsi que les scores Dice uniquement des coupes avec des poumons tout au long de l'entraînement

D'autres paramètres utilisés pour l'évaluation du modèle confirment également son bon comportement, et des résultats solides sont présentés dans le graphique IoU de la figure 4.3 qui montre un score élevé et stable, ce qui vaut également pour les scores de sensibilité et de spécificité illustrés dans leurs graphiques respectifs de la figure 4.4.




FIGURE 4.3 – Un graphique illustrant les scores de Jaccard (IoU) pour l’entraînement et la validation tout au long de la phase d’entraînement




FIGURE 4.4 – Un graphique illustrant les scores de sensibilité et de spécificité obtenus tout au long de la phase d’apprentissage

Le tableau 4.1 présente les résultats des paramètres de la 7e époque, avec un score Dice élevé de 0,90 et un IoU de 0,87, ce qui constitue des résultats particulièrement satisfaisants compte tenu de la complexité du modèle.

Best Validation Checkpoint	Valeur
Dice	0.9044
IoU	0.8722
Sensitivity	0.9417
Specificity	0.9878
Val Loss	0.0895
Train Dice	0.9070
Train Loss	0.0365
LR at best epoch	0.000091

TABLE 4.1 – Métriques d’évaluation du meilleur checkpoint de validation.

Le tableau 4.2 présente les résultats du modèle le plus performant sur l’ensemble de test, avec un score Dice de 0,93 et un IoU de 0,90, accompagnés d’une marge d’erreur

légèrement élevée, ce qui s’explique par la nature complexe des données du LIDC-IDRI combinée à la simplicité de l’architecture du modèle. C’est la conclusion que nous avons tirée des résultats obtenus lors de la validation, qui ont démontré la fiabilité du modèle sur des données externes.

Test Set Results	Valeur
Dice	0.9339 ± 0.1228
IoU	0.9043 ± 0.1435
Sensitivity	0.9477
Specificity	0.9940
Loss	0.0602

TABLE 4.2 – Métriques d’évaluation sur l’ensemble de test (validation interne).

4.5 Validation de la méthode de segmentation proposée

4.5.1 Validation sur LUNA16

Le tableau 4.3 présente les résultats de la validation de l’Unet sur l’ensemble de données complet LUNA16, avec un score Dice élevé de $0.9636 \pm 0,0538$ et une faible marge d’erreur, ainsi qu’un score IoU de $0,9329 \pm 0,0626$, ce qui constitue un résultat très satisfaisant pour la tâche de segmentation pulmonaire.

Metric	Mean	Std	Min	Max	Median
Dice	0.9636	0.0538	0.0156	0.9813	0.9695
IoU	0.9329	0.0626	0.0079	0.9633	0.9408
Precision	0.9674	0.0092	0.8720	0.9976	0.9687
Recall	0.9634	0.0645	0.0079	0.9848	0.9707
Sensitivity	0.9634	0.0645	0.0079	0.9848	0.9707
Specificity	0.9923	0.0034	0.9801	1.0000	0.9927
Vol Error (%)	1.4468	6.5978	0.0014	99.2121	0.6601

TABLE 4.3 – Résultats détaillés de la validation sur la base de données LUNA16.

Dans la figure 4.5 d’un cas tiré de lunsal16, avec un score Dice de 0,97, ce qui montre un chevauchement pratiquement identique des masques.




FIGURE 4.5 – Une illustration présentant les résultats de validation sur un patient à partir de LUNA16, avec un score DICE de 0,97; les zones vertes représentent le chevauchement entre le masque original et le masque prédit, les zones rouges correspondent aux faux positifs et les zones bleues aux faux négatifs

Il est important de noter que les scores Dice obtenus lors de la validation ont été supérieurs à ceux enregistrés lors des phases d'entraînement et de test. Cela s'explique par le fait que LUNA16 est un sous-ensemble de l'ensemble de données LIDC-IDRI, fournissant ainsi des données familières, ce qui pourrait expliquer cette précision de prédiction accrue. Cela nous a donc amenés à effectuer des tests sur un autre ensemble de données externe afin de consolider notre évaluation du modèle.

Il convient également de noter que l'examen des cas d'échec enregistrés a révélé qu'une écrasante majorité de ces « cas d'échec » correspondaient à des instances où l'Unet avait donné de meilleurs résultats que les annotations de LUNA16, comme le montre la figure 4.6 qui présente un faible score Dice de 0,63 en raison du masque d'origine de LUNA16 qui inclut l'air extérieur.



FIGURE 4.6 – Résultats du test de validation de l'Unet sur le dataset LUNA16 d'un cas d'échec avec un dice=0.63, les zones vertes représentent le chevauchement entre le masque original et le masque prédit, les zones rouges correspondent aux faux positifs et les zones bleues aux faux négatifs

4.5.2 Validation externe sur l'ensemble de données annoté par des radiologues

Le tableau 4.4 présentant les résultats de la validation sur l'ensemble de données annoté par des radiologues portant sur 20 patients, qui a également produit des scores Dice satisfaisants de $0,9499 \pm 0,0169$ et un IoU de $0,9051 \pm 0,0299$, nous observons un faible écart-type, ce qui indique également la fiabilité des prédictions du modèle.

TABLE 4.4 – Un tableau présentant les résultats de la validation sur l'ensemble de données des 20 patients

La figure 4.7 illustre les résultats d'un CT scan issu de l'ensemble de données annotées par des radiologues portant sur 20 patients, montrant des résultats très satisfaisants en termes de chevauchement des masques et un score dice élevé de 0,96.




FIGURE 4.7 – Une illustration présentant les résultats de validation sur un patient à partir de dataset des 20 patients, avec un score DICE de 0,96 ; les zones vertes représentent le chevauchement entre le masque original et le masque prédit, les zones rouges correspondent aux faux positifs et les zones bleues aux faux négatifs

L'Unet a démontré une efficacité inférieure dans les cas présentant des pathologies susceptibles d'avoir produit des images irrégulières, ainsi que des anomalies. Lors de la deuxième validation sur l'ensemble de données de 20 patients, nous avons pu constater que certains cas affichaient un score de Dice plus faible en raison de l'incapacité du masque à englober une partie des zones pulmonaires infectées, ce qui expliquerait un score de Dice et un score d'IoU légèrement inférieur par rapport à la validation sur LUNA16, comme le montre la figure 4.8 où l'Unet n'a pas réussi à capturer certaines parties des poumons et présente un faible score de Dice de 0,89 et un score IoU aussi faible que 0,81.




FIGURE 4.8 – Résultats du test de validation de l’Unet sur le dataset de 20 patients d’un cas d’échec avec un $\text{dice}=0.89$, les zones vertes représentent le chevauchement entre le masque original et le masque prédit, les zones rouges correspondent aux faux positifs et les zones bleues aux faux négatifs

4.5.3 Analyse comparative avec d’autres méthodes

Afin de mener une évaluation comparative, nous avons consulté le tableau 4.5 présenté dans le travail de Hong, L., et al. [7], qui met en évidence les performances de plusieurs algorithmes flous FCM, KFCM, SAFCM, FRFCM, SNAKE, qui sont des algorithmes classiques de segmentation pulmonaire basée sur le clustering. Dans le cadre de ce projet, nous nous limitons à comparer les scores IoU cités dans ce tableau. Il est clair que notre implémentation de l’Unet a surpassé les algorithmes basés sur le regroupement, avec un score IoU supérieur à celui de Snake, qui possède le score le plus élevé parmi eux.

Method	IoU	HD
FCM	0.625 ± 0.031	1.511 ± 0.011
KFCM	0.761 ± 0.001	1.813 ± 0.092
SAFCM	0.732 ± 0.002	1.868 ± 0.050
FRFCM	0.791 ± 0.009	2.010 ± 0.102
Snake	0.849 ± 0.012	2.120 ± 0.103
Notre methode	0.9043 ± 0.1435	/

TABLE 4.5 – Métrique de performance de divers algorithmes flous pour la segmentation pulmonaire sur l’ensemble de données LUNA16, tirées de l’article de recherche de Hong, L., et al. [7]

Étant donné que l’Unet est un algorithme de génération bien plus récente, il offre naturellement de meilleures performances ; il est donc bien plus intéressant de le comparer aux performances des techniques les plus récentes.

Dans le tableau 4.6 présenté dans l'article de M. Abdullah et al. [8], qui résume les performances de modèles beaucoup plus récents affichant des résultats beaucoup plus élevés, notre modèle a surpassé toutes les références fournies et a obtenu des résultats très compétitifs par rapport à la méthode proposée par M. Abdullah et al., malgré la simplicité de notre modèle.

Author	Year	Method	No. of Samples	Dice (%)	IoU (%)
Ronneberger et al.	2015	UNet	163 CT Scans	91.52	84.73
Chen et al.	2017	DeepLabV1	163 CT Scans	88.67	80.77
Oktaý et al.	2018	Attention-UNet	163 CT Scans	91.96	86.48
Zhang et al.	2023	NASNet-large Net	1000 X-Ray Images	92.00	87.00
Poonkodi et al.	2023	MSCAUNet-3D	335 CT Scans	91.40	90.40
Gang et al.	2025	Pyramidal Pooling Channel Transformer (PPCT)	163 CT Scans	88.99	80.40
Li et al.	2025	AE-UNet	2729 CT images	72.22	57.15
Abdullah et al.	2025	3D-Attention ResUNet	888 CT Scans	93.61	91.03
Notre methode	2026	2D UNet	996 CT Scans	93.39	90.43

TABLE 4.6 – Tableau comparatif des performances des modèles récents de segmentation pulmonaire [8]

Il est intéressant de noter que notre implémentation du modèle de référence U-Net, inspirée de l'architecture de Ronneberger et al. de 2015 [5], a surpassé ce dernier avec un écart notable, ce qui démontre que les améliorations que nous avons apportées à l'augmentation des données, à la fonction de perte et à l'optimisation, combinées à l'entraînement sur l'ensemble de données à grande échelle LIDC-IDRI, se sont avérées être des contributions significatives aux performances du modèle malgré sa simplicité.

4.6 Résultats de la reconstruction 3D surfacique

4.6.1 Sélection du patient et préparation des données

Le patient LIDC-IDRI-0370 a été retenu comme cas de référence pour valider l'ensemble du pipeline : segmentation, suppression de la trachée, lissage et décimation. Les masques 2D produits par le réseau U-Net ont été empilés dans l'ordre axial pour former un volume binaire de dimensions $(333 \times 333 \times 380)$ voxels ; l'espacement voxel a été fixé à $1,0 \times 1,0 \times 1,0$ mm, de sorte que toutes les coordonnées du maillage final sont directement exprimées en millimètres, sans conversion supplémentaire. Le pipeline a ensuite été appliqué à trois patients supplémentaires (LIDC-IDRI-0072, LIDC-IDRI-0164 et LIDC-IDRI-0469) afin d'évaluer sa généralisation sur des morphologies pulmonaires variées.

4.6.2 Inférence U-Net et reconstruction surfacique

Le réseau U-Net a traité l'ensemble des coupes axiales du patient LIDC-IDRI-0370 en appliquant la stratégie d'upsampling bilinéaire sur les prédictions décrite dans la section précédente. Le volume brut résultant, **incluant la trachée**, contient après extraction de surface **862 544 faces** et **431 244 sommets** pour un volume anatomique de **5 450,14 mL**, représentant la segmentation complète avant nettoyage, comme le résume le tableau 4.7. Le maillage initial est topologiquement fermé (*watertight*), ce qui valide la qualité de la reconstruction d'entrée.

Grandeur	Valeur	Unité / Contexte
Dimensions du volume segmenté	$333 \times 333 \times 380$	voxels
Espacement voxel	$1.0 \times 1.0 \times 1.0$	mm
Faces du maillage brut	862 544	avec trachée
Sommets du maillage brut	431 244	avec trachée
Volume pulmonaire brut	5 450.14	mL
Surface pulmonaire brute	3 223.39	cm ²
Topologie du maillage brut	Watertight	fermé hermétiquement

TABLE 4.7 – Caractéristiques du maillage brut de segmentation U-Net pour le patient LIDC-IDRI-0370.

4.6.3 Nettoyage anatomique et suppression de la trachée

L'algorithme de suppression de la trachée a été appliqué en quatre étapes sur le volume brut. Dans un premier temps, la détection coupe par coupe a identifié **85 régions centrales** réparties sur une plage axiale allant de $z = 21$ à $z = 312$, comme illustré dans la figure 4.9. Le balayage a couvert 241 coupes avec un rayon de suppression de 17 voxels. Cette plage couvre non seulement la trachée proprement dite, mais également les deux bronches principales, ce qui explique son amplitude.



FIGURE 4.9 – Trachée détectée (zone centrale) sur le volume brut du patient LIDC-IDRI-0370.

Après une érosion morphologique adaptative (rayon de 4 voxels, 2 itérations) suivie de l'analyse des composantes connexes, 50 composantes ont été détectées. Parmi celles-ci, les deux plus grandes ont été conservées, correspondant aux poumons droit et gauche.

Le volume nettoyé correspond à un maillage sans trachée de **743 696 faces** et **371 852 sommets**, dont le rendu est visible à la figure 4.10.



FIGURE 4.10 – Maillage pulmonaire après suppression de la trachée .

L'impact quantitatif de cette opération est détaillé dans le tableau 4.8. La perte de 217,48 mL, soit **3,99 % du volume initial** montre que l'algorithme supprime efficacement les structures indésirables (trachée et bronches principales) sans empiéter sur le parenchyme pulmonaire, ce qui valide la stratégie de détection coupe par coupe par régression linéaire.

Grandeur	Brut (avec trachée)	Après suppression	Variation
Faces	862 544	743 696	−118 848 (−13,78 %)
Sommets	431 244	371 852	−59 392 (−13,77 %)
Volume (mL)	5 450.14	5 232.66	−217.48 (−3,99 %)
Surface (cm ²)	3 223.39	2 750.25	−473.14 (−14,67 %)
Topologie	Watertight	Watertight	Préservée

TABLE 4.8 – Impact quantifié de la suppression de la trachée pour le patient LIDC-IDRI-0370.

Ce tableau met en évidence une asymétrie notable : la suppression affecte la **surface bien davantage que le volume** (14,67 % contre 3,99 %). Ce contraste s’explique par la géométrie cylindrique de la trachée, dont le rapport surface/volume est structurellement plus élevé que celui du parenchyme, confirmant que le nettoyage cible correctement les structures tubulaires sans altérer les poumons.

4.6.4 Extraction de la surface par Marching Cubes et lissage de Taubin

L’algorithme de Marching Cubes a été appliqué sur le volume nettoyé, après ajout d’un *padding* de 2 voxels nuls sur chaque face. Comme indiqué dans le tableau 4.9, le maillage résultant contient **743 696 faces** et **371 852 sommets**, et est topologiquement fermé (*watertight*) dès l’extraction, sans nécessiter d’étape de réparation. Le volume correspondant atteint 5 232,66 mL pour une surface de 2 750,25 cm² ; ces valeurs constituent la référence pour évaluer l’impact du lissage.

Grandeur	Valeur
Faces du maillage (après MC)	743 696
Sommets du maillage (après MC)	371 852
Topologie watertight	Oui
Volume	5 232.66 mL
Surface	2 750.25 cm ²

TABLE 4.9 – Caractéristiques du maillage après Marching Cubes (avant lissage) pour le patient LIDC-IDRI-0370.




FIGURE 4.11 – Maillage avec faces colorées avant lissage : l’effet d’escalier lié à la discrétisation voxel est clairement visible sur le flanc du volume.

Le maillage brut présente l’effet d’escalier attendu (figure 4.11), conséquence directe de la résolution finie du volume d’entrée. Un filtre de Taubin ($\lambda = 0,5$, $\mu = -0,53$, 20 itérations) a été appliqué pour le corriger.

Métrique	Avant Taubin	Après Taubin	Variation
Faces conservées	743 696	743 696	0 %
Sommets conservés	371 852	371 852	0 %
Topologie watertight	Oui	Oui	Préservée
Volume (mL)	5 232.66	5 221.26	-11.40 (-0,22 %)
Surface (cm ²)	2 750.25	2 495.15	-255.10 (-9,27 %)

TABLE 4.10 – Impact du lissage de Taubin : conservation de la topologie et amélioration de la régularité de surface.

Après lissage, le maillage conserve exactement le même nombre de faces et de sommets et reste watertight, avec un volume de 5 221,26 mL et une surface ramenée à 2 495,15 cm². L’application du filtre a permis de :

- **Réduire la surface de 255,10 cm²** (9,27 %) en éliminant les aspérités sans dissolution du volume ;
- **Préserver le volume à 0,22 % près**, soit moins de 12 mL perdus sur plus de 5 200 mL, confirmant la fidélité du lissage aux grandes structures anatomiques ;
- **Maintenir la fermeture topologique** : aucune fuite n’apparaît après 20 itérations.

Ces résultats confirment que le lissage de Taubin agit comme un algorithme de préservation géométrique, et non de reconstruction forcée, comme l’illustre la figure 4.12.



FIGURE 4.12 – Reconstruction après lissage de Taubin - patient LIDC-IDRI-0370.

4.6.5 Simplification géométrique par décimation quadrique (QEM)

Avec 743 696 faces, le maillage lissé est trop lourd pour une application interactive en temps réel ou un déploiement mobile. La décimation par métriques quadriques (QEM) l'a réduit à **60 000 faces** et **30 004 sommets**, soit une réduction de **91,93 %** du nombre de faces en **19,45 secondes**. Cette compression est rendue nécessaire par le volume anatomique particulièrement étendu de ce patient.

Grandeur	Avant QEM	Après QEM	Variation
Faces	743 696	60 000	−683 696 (−91,93 %)
Sommets	371 852	30 004	−341 848 (−91,93 %)
Watertight	Oui	Oui	Préservée
Volume (mL)	5 221.26	5 220.77	−0.49 (−0,009 %)
Surface (cm ²)	2 495.15	2 495.59	+0.44 (+0,018 %)
Taille STL (MB)	37.19	3.00	facteur ÷12.4

TABLE 4.11 – Comparaison géométrique avant et après décimation QEM pour le patient LIDC-IDRI-0370.

La comparaison entre les figures 4.13 et 4.14 illustre concrètement cette réduction : le maillage avant décimation présente une densité de triangles très élevée avec des faces uniformément petites,



FIGURE 4.13 – Maillage avant décimation
QEM : 743 696 faces.




FIGURE 4.14 – Maillage après décimation
QEM : 60 000 faces.

tandis qu’après décimation, les triangles deviennent plus grands et moins nombreux, rendant la structure du maillage visible à l’œil nu tout en conservant la forme générale des poumons.

Comme le montre le tableau 4.11, la décimation QEM réduit le nombre de faces de 91,93 % tout en préservant quasiment la géométrie du modèle. Le volume ne varie que de 0,009 % et la surface de 0,018 %, confirmant que les simplifications concernent principalement les zones peu courbées du parenchyme. Cette réduction s’accompagne d’une diminution importante de la taille du fichier STL, qui passe de 37,19 MB à 3,00 MB. Cette compression est un objectif majeur de l’opération, le maillage étant destiné à la reconstruction volumique et aux simulations numériques. Un maillage surfacique trop dense génère des coûts de calcul et de mémoire importants et peut devenir difficile à manipuler dans les logiciels de prétraitement et de simulation.

4.6.6 Évaluation quantitative de la fidélité géométrique

Pour vérifier que la décimation n’a pas dégradé la géométrie du modèle, 10 000 points ont été échantillonnés aléatoirement sur chacun des deux maillages (avant et après QEM), et la distance de chaque point au point le plus proche de l’autre maillage a été calculée.

Métrique	Valeur	Interprétation
Hausdorff 95 % (HD95)	4.90 mm	Acceptable pour volume atypique
Écart moyen symétrique (MSD)	2.47 mm	Légèrement en-deçà du seuil clinique
Compression STL	91.9 %	Réduction massive du fichier
Points de référence	10 000	par surface

TABLE 4.12 – Métriques de fidélité géométrique après décimation QEM pour le patient LIDC-IDRI-0370.

Le HD95 de 4,90 mm s'explique mécaniquement par le taux de compression imposé : avec 5 221 mL, ce volume mesuré à l'inspiration profonde est cohérent avec une CPT normale d'adulte (4 500–6 500 mL). La cible fixe de 60 000 faces impose alors un taux de compression de 91,9 %, bien plus forte que pour un volume plus faible, ce qui explique mécaniquement des écarts géométriques plus élevés. Cette tendance est confirmée par la progression régulière du HD95 sur l'ensemble des patients, de 2,90 mm (0164, compression 77,3 %) à 4,90 mm (0370, compression 91,9 %).

Le MSD de 2,47 mm reste en-deçà du seuil clinique de 2,5 mm, ce qui montre que le pipeline maintient un compromis satisfaisant entre précision et compression. La réduction de fichier est également frappante : 37,19 MB sont ramenés à 3,00 MB, soit une division par 12,4.

4.6.7 Synthèse et validation globale du patient LIDC-IDRI-0370

Étape	Faces	Volume (mL)	Surface (cm ²)	Taille STL
01. Brut avec trachée	862 544	5 450.14	3 223.39	43.13 MB
02. Sans trachée	743 696	5 232.66	2 750.25	37.19 MB
03. Après Taubin	743 696	5 221.26	2 495.15	37.19 MB
04. Après QEM (60k)	60 000	5 220.77	2 495.59	3.00 MB

TABLE 4.13 – Résumé des transformations géométriques du pipeline pour le patient LIDC-IDRI-0370.

La perte volumique totale atteint 229,37 mL ($\approx 4,21\%$). Elle provient presque exclusivement de la suppression volontaire de la trachée et des bronches principales (217,48 mL, soit 3,99 %) ; le lissage de Taubin et la décimation QEM n'introduisent ensemble qu'une perte résiduelle de 11,88 mL ($\approx 0,22\%$), confirmant le caractère non destructif du post-traitement géométrique.

Malgré une réduction de 91,97 % du nombre de faces, le maillage final conserve une bonne fidélité anatomique (HD95 = 4,90 mm, MSD = 2,47 mm), une topologie stable et une taille de fichier divisée par 12,4. Ces résultats montrent que la cible de 60 000 faces constitue un compromis efficace entre qualité géométrique, préservation anatomique et légèreté du modèle, même pour des volumes pulmonaires importants, correspondant à des acquisitions TDM réalisées à pleine inspiration et donc proches de la CPT physiologique.

4.6.8 Généralisation à l'ensemble des patients

Le pipeline a été appliqué à trois patients supplémentaires afin d'évaluer sa robustesse sur des morphologies pulmonaires différentes. Les volumes pulmonaires obtenus après reconstruction varient fortement, de 1,216 mL à 5,221 mL. Cette variabilité est attendue et s'explique à la fois par les différences anatomiques entre les patients et par le niveau d'inspiration au moment de l'acquisition tomodensitométrique.

Les examens de la base LIDC-IDRI étant réalisés lors d'une inspiration profonde, les volumes observés peuvent se rapprocher de la capacité pulmonaire totale. Dans ce contexte, le volume de 5,221 mL mesuré pour le patient LIDC-IDRI-0370 reste cohérent

avec les valeurs physiologiques rapportées chez l'adulte. Les volumes plus faibles observés pour les patients LIDC-IDRI-0164 (1,216 mL) et LIDC-IDRI-0072 (1,721 mL) peuvent être attribués à une morphologie pulmonaire plus réduite, à une inspiration moins complète lors de l'examen, ou à la combinaison de ces deux facteurs.

Cette diversité constitue un cas de test intéressant pour l'évaluation du pipeline. Malgré des volumes pulmonaires très différents d'un patient à l'autre, les différentes étapes de reconstruction ont produit des résultats cohérents et stables, ce qui confirme la capacité de la méthode proposée à s'adapter à des anatomies variées.

Le tableau 4.14 récapitule les métriques clés pour les quatre cas traités, ordonnés par volume pulmonaire croissant.

Métrique	0164	0072	0469	0370
Volume brut (mL)	1 316.31	1 834.79	3 639.81	5 450.14
Perte trachée (mL)	-93.42	-106.58	-220.63	-217.48
Perte trachée (%)	7.10	5.81	6.06	3.99
Réduction Taubin vol. (%)	0.55	0.42	0.29	0.22
Réduction Taubin surf. (%)	9.83	9.62	9.51	9.27
Volume final QEM (mL)	1 216.00	1 720.73	3 409.07	5 220.77
HD95 (mm)	2.90	3.22	4.19	4.90
MSD (mm)	1.48	1.65	2.12	2.47
Compression STL (%)	77.3	81.8	88.7	91.9

TABLE 4.14 – Synthèse du pipeline de reconstruction surfacique pour quatre patients (LIDC-IDRI-0164, 0072, 0469, 0370).

L'analyse du tableau 4.14 montre que les différentes étapes du pipeline conservent un comportement relativement homogène malgré les écarts importants de volume entre les patients.

La réduction de surface induite par le lissage de Taubin reste très proche d'un patient à l'autre, avec des valeurs comprises entre 9,27 % et 9,83 %. Cette faible variation est cohérente avec l'utilisation des mêmes paramètres de lissage pour l'ensemble des cas étudiés. Les résultats suggèrent que cette étape est peu influencée par les différences de taille et de morphologie des poumons.

La suppression de la trachée entraîne des pertes volumiques du même ordre de grandeur pour les quatre patients. Les diminutions observées varient entre 3,99 % et 7,10 % du volume initial, ce qui indique que la méthode utilisée reste applicable à des anatomies différentes.

Les écarts géométriques mesurés après décimation montrent en revanche une légère augmentation avec le volume pulmonaire. Les valeurs de HD95 passent de 2,90 mm pour le patient LIDC-IDRI-0164 à 4,90 mm pour le patient LIDC-IDRI-0370, tandis que le MSD évolue de 1,48 mm à 2,47 mm. Cette évolution s'explique par le fait que tous les maillages sont réduits vers une cible fixe de 60 000 faces, ce qui impose une compression plus importante pour les volumes les plus élevés.

Enfin, le taux de compression des fichiers STL augmente progressivement avec la taille des maillages initiaux, atteignant près de 92 % pour le patient LIDC-IDRI-0370. Ce résultat montre que la stratégie de décimation retenue permet de réduire fortement la

complexité géométrique tout en conservant une représentation exploitable pour les étapes suivantes du pipeline.

Dans l'ensemble, les résultats obtenus sur les quatre patients montrent que le pipeline conserve un comportement cohérent malgré des volumes pulmonaires très différents, ce qui constitue un indicateur de sa capacité de généralisation.

4.7 Résultats et analyse de la reconstruction volumique

4.7.1 Séparation anatomique gauche/droite du patient LIDC-IDRI-0370

La décomposition en composantes connexes du maillage réduit (60 000 faces, 30 004 sommets, watertight) a produit exactement deux composantes, résultat cohérent avec la morphologie pulmonaire attendue après suppression de la trachée. Le tableau 4.15 résume les propriétés géométriques de chaque composante.

Grandeur	Poumon droit	Poumon gauche
Faces	30 472	29 528
Sommets	15 238	14 766
Centroïde X (mm)	160.67	167.16
Volume (mL)	2 860.23	2 360.54
Surface (cm ²)	1 293.40	1 202.20
Topologie watertight	Oui	Oui

TABLE 4.15 – Caractéristiques des maillages surfaciques après séparation des poumons gauche et droit pour le patient LIDC-IDRI-0370.

L'identification anatomique repose sur la coordonnée X du centroïde de chaque composante dans l'espace LPS (*Left-Posterior-Superior*) [48], sans nécessiter de paramètre supplémentaire. Les volumes obtenus sont de 2 860,23 mL pour le poumon droit et 2 360,54 mL pour le poumon gauche, soit un rapport D/G d'environ 1,21. Cette différence est cohérente avec l'anatomie pulmonaire humaine, le poumon gauche présentant généralement un volume inférieur en raison de la présence du cœur. La classification basée sur la position des centroïdes a ainsi permis d'identifier correctement les deux poumons.

Aucune correction topologique n'a été nécessaire après la séparation. Les deux composantes obtenues sont restées *watertight*, ce qui montre que les étapes de lissage de Taubin, de décimation QEM et de séparation n'ont pas introduit de défaut topologique sur les surfaces reconstruites.

4.7.2 Généralisation de la séparation anatomique

Patient	Vol. droit (mL)	Vol. gauche (mL)	Rapport D/G	Watertight (D/G)
LIDC-IDRI-0164	558.21	657.80	0.85	Oui / Oui
LIDC-IDRI-0072	791.31	929.42	0.85	Oui / Oui
LIDC-IDRI-0469	1 712.41	1 696.67	1.01	Oui / Oui
LIDC-IDRI-0370	2 860.23	2 360.54	1.21	Oui / Oui

TABLE 4.16 – Résultats de la séparation anatomique des poumons gauche et droit pour les quatre patients étudiés.

La séparation génère des maillages fermés (*watertight*) pour tous les poumons, sans correction manuelle. Le rapport D/G varie d'un patient à l'autre. Pour LIDC-IDRI-0370 (1,21) et LIDC-IDRI-0469 (1,01), les valeurs correspondent à la répartition anatomique généralement observée. Pour LIDC-IDRI-0164 et LIDC-IDRI-0072, le rapport inférieur à 1 signifie que le poumon gauche est légèrement plus volumineux. Ces deux cas présentent également des volumes pulmonaires globaux plus faibles que les autres patients, ce qui peut correspondre à des poumons de plus petite taille ou à une capacité pulmonaire réduite.

4.7.3 Génération des maillages volumiques tétraédriques du patient LIDC-IDRI-0370

Les deux maillages surfaciques ont été soumis à l'algorithme frontal tridimensionnel de Gmsh avec une taille caractéristique uniforme de $h = 7,0$ mm. Le tableau 4.17 présente les caractéristiques structurales des maillages volumiques obtenus, tandis que la figure 4.15 illustre la reconstruction volumique du poumon gauche du patient.

Grandeur	Poumon droit	Poumon gauche
Nœuds	7 994	6 869
Tétraèdres	36 891	30 938
Temps de génération (s)	9.32	7.40

TABLE 4.17 – Caractéristiques structurales des maillages volumiques tétraédriques pour le patient LIDC-IDRI-0370.

La densité des maillages est cohérente avec le choix de $h = 7,0$ mm : le nombre de tétraèdres croît proportionnellement au volume de chaque lobe, le poumon droit (2 860 mL) générant 36 891 éléments contre 30 938 pour le poumon gauche (2 360 mL). Ce niveau de résolution est adapté à la capture des propriétés mécaniques globales du parenchyme pulmonaire à l'échelle de l'organe, et le temps de génération inférieur à 10 s par lobe est compatible avec un pipeline automatisé.




FIGURE 4.15 – Reconstruction volumique du patient LIDC-IDRI-0370.

4.7.4 Validation par critères FEM médicaux du patient LIDC-IDRI-0370

La conformité des maillages pour une utilisation en simulation par éléments finis a été évaluée selon trois critères complémentaires : conservation du volume, qualité de forme des tétraèdres et absence d'éléments dégénérés. Le tableau 4.18 synthétise l'ensemble des résultats.

Critère	Poumon droit	Poumon gauche	Seuil
Volume surfacique (mL)	2 860.23	2 360.54	/
Volume tétraédrique (mL)	2 852.13	2 352.42	/
Erreur volumique (%)	0.283	0.344	$\leq 5,0$
Aspect Ratio moyen	1.196	1.205	/
Aspect Ratio max	7.148	8.489	/
Éléments AR > 3,0 (%)	0.03	0.05	< 5,0
Slivers détectés (%)	0.00	0.00	< 1,0
Verdict FEM	✓ Conforme	✓ Conforme	–

TABLE 4.18 – Métriques de validation par analyse éléments finis (FEM) des maillages volumiques du patient LIDC-IDRI-0370.

Conservation du volume. Les erreurs volumiques de 0,283 % et 0,344 % sont très inférieures du seuil de 5 % généralement admis pour les organes mous en imagerie médicale [65]. Ces pertes sont principalement dues à la discrétisation géométrique introduite lors de la tétraédrisation. L'algorithme frontal peut entraîner une légère sous-estimation du volume lorsque les éléments du maillage volumique ne s'alignent pas parfaitement avec la surface du maillage d'origine. Cet écart reste faible et relativement constant, ce qui permet éventuellement d'appliquer un facteur de correction lorsque une estimation volumique très précise est nécessaire.

Qualité de forme des éléments. Les Aspect Ratios moyens de 1,196 et 1,205 sont proches de la valeur idéale du tétraèdre régulier, témoignant de la qualité de l’optimisation combinée (lissage de Laplace puis passe Netgen). Pour le poumon droit, seulement 0,03 % des éléments dépassent le seuil $\beta > 3,0$, garantissant l’absence de distorsion susceptible de dégrader le conditionnement de la matrice de rigidité. Le poumon gauche présente un maximum isolé de 8,489, probablement localisé dans une zone à faible rayon de courbure ; avec 0,05 % d’éléments au-delà du seuil, cela reste très en-deçà du critère de conformité à 5 %.

Absence d’éléments *sliver*. Aucun élément dégénéré n’a été détecté dans les deux maillages ($V_{\text{norm}} \geq 10^{-3}$ pour tous les tétraèdres). Ce résultat est particulièrement favorable car les slivers constituent la principale source d’instabilité numérique dans les solveurs FEM, et leur absence garantit la robustesse du maillage pour des simulations ultérieures.

4.7.5 Validation FEM et comparaison multi-patients

Le tableau 4.19 présente les métriques FEM pour l’ensemble des huit poumons traités sur les quatre patients.

Patient	L.	Nœuds	Tétrras	ΔVol (%)	AR moy.	AR max	AR > 3 (%)	Slivers
LIDC-IDRI-0164	D	1 940	7 983	0.80	1.209	2.164	0.00	0
LIDC-IDRI-0164	G	2 129	8 779	0.74	1.211	2.262	0.00	0
LIDC-IDRI-0072	D	2 810	12 252	0.65	1.195	3.270	0.01	0
LIDC-IDRI-0072	G	3 069	13 574	0.55	1.193	2.423	0.00	0
LIDC-IDRI-0469	D	3 865	15 668	0.39	1.261	5.127	0.06	0
LIDC-IDRI-0469	G	4 126	16 747	0.41	1.264	8.950	0.21	0
LIDC-IDRI-0370	D	7 994	36 891	0.28	1.196	7.148	0.03	0
LIDC-IDRI-0370	G	6 869	30 938	0.34	1.205	8.489	0.05	0

TABLE 4.19 – Métriques de validation FEM pour les huit poumons des quatre patients étudiés (D = droit, G = gauche).

Patient	L.	$\Delta\text{Vol} \leq 5.0\%$	AR > 3 (< 5.0%)	Slivers < 1.0%	Verdict
LIDC-IDRI-0164	D	✓ 0.80	✓ 0.00	✓ 0.00	Conforme
LIDC-IDRI-0164	G	✓ 0.74	✓ 0.00	✓ 0.00	Conforme
LIDC-IDRI-0072	D	✓ 0.65	✓ 0.01	✓ 0.00	Conforme
LIDC-IDRI-0072	G	✓ 0.55	✓ 0.00	✓ 0.00	Conforme
LIDC-IDRI-0469	D	✓ 0.39	✓ 0.06	✓ 0.00	Conforme
LIDC-IDRI-0469	G	✓ 0.41	✓ 0.21	✓ 0.00	Conforme
LIDC-IDRI-0370	D	✓ 0.28	✓ 0.03	✓ 0.00	Conforme
LIDC-IDRI-0370	G	✓ 0.34	✓ 0.05	✓ 0.00	Conforme
Total	8/8	8/8	8/8	8/8	8/8 conformes

TABLE 4.20 – Conformité des huit maillages pulmonaires aux critères de qualité FEM rapportés dans la littérature.

Cette synthèse s’appuie sur les résultats présentés dans les tableaux 4.19 et 4.20, qui regroupent respectivement les métriques FEM détaillées et leur vérification par rapport aux seuils de validation.

L'ensemble des huit poumons satisfait simultanément les trois critères de conformité, sans exception. Plusieurs observations transversales méritent d'être soulignées.

Erreur volumique. L'erreur volumique décroît lorsque le volume du lobe augmente : les poumons de LIDC-IDRI-0164 (558 et 658 mL) présentent les erreurs les plus élevées (0,74–0,80 %), tandis que ceux de LIDC-IDRI-0370 (2 360 et 2 860 mL) atteignent les plus faibles (0,28–0,34 %). Ce comportement s'explique par l'amélioration du rapport volume sur surface à mesure que l'organe s'agrandit : pour un volume important, la zone de bord non couverte par les tétraèdres de surface représente une fraction plus petite du total.

Qualité de forme. Les Aspect Ratios moyens sont homogènes entre patients et entre poumons, tous compris entre 1,19 et 1,26, témoignant de la robustesse de l'optimisation Netgen indépendamment de la morphologie individuelle. Les valeurs maximales d'AR sont plus élevées pour les poumons de grande taille (0469, 0370), ce qui reflète l'apparition de tétraèdres allongés dans les zones à fort gradient de courbure. Dans tous les cas, la proportion d'éléments à $AR > 3,0$ reste inférieure à 0,21 %, très en-deçà du seuil de 5 %.

Absence de slivers. L'absence totale de *slivers* sur les huit maillages constitue le résultat le plus robuste de cette validation. Elle confirme que la chaîne de traitement en amont (lissage de Taubin, décimation QEM et séparation par composantes connexes) produit des maillages surfaciques exempts de singularités géométriques susceptibles de compromettre la tétraédrisation.

À l'échelle de ce travail, la reconstruction volumique remplit son rôle de preuve de concept : elle démontre qu'un maillage surfacique issu d'une segmentation U-Net automatique peut être converti en maillage tétraédrique conforme sans intervention manuelle ni réparation topologique intermédiaire. La chaîne complète (de la segmentation à la validation FEM) est ainsi entièrement automatisée et reproductible sur des cas anatomiques variés, couvrant un spectre volumique de 1 216 mL à 5 221 mL.

4.8 Résultats de la simulation

4.8.1 Matériaux et méthodes

La simulation respiratoire a été réalisée sur SOFA, un *framework* open source dédié à la simulation physique en temps réel, axé sur la simulation médicale. La simulation et la validation ont été effectuées sur 5 patients spécifiquement sélectionnés comme candidats à la simulation de respiration calme, car leur volume correspondait au volume résiduel fonctionnel attendu de (2 à 3 L $\pm$), ce qui correspond au volume restant dans les poumons après une expiration passive normale [129, 130]. Pour chaque patient, les maillages bilatéraux (poumons droit et gauche) ont été chargés à partir d'une seule segmentation de tomodensitométrie. Tous les paramètres de simulation ont été dérivés automatiquement de la géométrie du maillage lors de l'initialisation.

Configuration des paramètres

Au début de chaque simulation, le cadre de délimitation de chaque maillage pulmonaire est extrait afin de calculer l'amplitude SI à 13 % de la hauteur pulmonaire ; l'amplitude latérale a été fixée à 2 mm et l'amplitude ventrale à 5 mm, ces valeurs ayant

été choisies pour rester dans les limites des intervalles documentés dans la littérature et produire des résultats cohérents.

La fonction de pondération est ensuite appliquée nœud par nœud à l'aide de la coordonnée verticale normalisée, à l'exception du cadre de délimitation fixe situé en haut.

La courbe respiratoire est fixée pour tous les patients à 1,3 s d'inspiration et 2,6 s d'expiration (15,4 respirations/min), ce qui correspond aux normes de respiration tidale chez l'adulte [131].

Sept cycles consécutifs ont été simulés pour chaque patient ; à la fin de chaque cycle, le taux de variation du volume et le déplacement maximal du diaphragme ont été enregistrés et comparés aux plages cibles physiologiques de l'augmentation attendue du volume courant (400–500 ml) chez les adultes en bonne santé, telles que rapportées dans de nombreuses études [132].

4.8.2 Analyse qualitative

La simulation met en évidence la déformation pulmonaire au cours des cycles respiratoires successifs. Les principales observations sont les suivantes :

1. **Modèle d'insufflation/désinsufflation** : la géométrie pulmonaire alterne entre un état de repos initial et des états d'insufflation correspondant à chaque cycle respiratoire.
2. **Déplacement non uniforme** : une grande partie de la région supérieure présente des mouvements très minimes, le déplacement maximal se produisant à la base du poumon, ce qui correspond au comportement physiologique des mouvements pulmonaires pendant la respiration courante et respecte effectivement la contrainte aux limites.
3. **Répétabilité cyclique** : la simulation étant un calcul numérique du déplacement des nœuds à l'aide de valeurs fixes tout au long du test, les cycles reproduisent des schémas de déformation identiques à chaque cycle.
4. **Mouvement du diaphragme** : la région inférieure du poumon présente des déplacements verticaux, démontrant un couplage efficace entre le mouvement du diaphragme et l'expansion pulmonaire.

La figure 4.16 illustre la déformation d'un patient pendant la respiration tidale, T1 représentant la fin de l'expiration et T2 la fin de l'inspiration. La figure 4.17 illustre les mêmes phases de déformation du point de vue de la base, mettant en évidence la dilatation de la base à la fin de l'inspiration.

4.8.3 Analyse quantitative

Pour compléter l'évaluation qualitative, nous avons procédé à divers contrôles afin de nous assurer que notre modèle heuristique fonctionnait correctement et produisait des résultats conformes aux prévisions.

Amplitude maximale du diaphragme. Les déplacements maximaux du diaphragme chez plusieurs patients lors de la respiration courante, en utilisant une estimation de 13 % de la hauteur pulmonaire, ont donné des valeurs s'inscrivant largement dans la plage prévue de 10 à 25 mm, tout en conservant des niveaux de mouvement et de volume constants.




FIGURE 4.16 – Images illustrant la déformation pulmonaire au cours d’un cycle respiratoire : T1 (fin de l’expiration) et T2 (fin de l’inspiration).




FIGURE 4.17 – Images illustrant la déformation pulmonaire au cours d’un cycle respiratoire : T1 (fin de l’expiration) et T2 (fin de l’inspiration) ; variation vue sous un angle différent, mettant en évidence les mouvements latéraux et ventraux.

Patient	Amplitude SI (mm)	Déplacement diaphragme max (mm)
100	21,8	20,97
575	24,5	22,23
791	20,3	19,41
883	19,0	18,27
922	25,0	24,06

TABLE 4.21 – Déplacement du diaphragme pendant la respiration tidale pour plusieurs patients, avec une estimation SI de 13 % de la hauteur pulmonaire.

Variation du volume. Pour valider le volume, nous avons observé le volume courant par rapport à la fourchette cible de 400 à 500 ml chez plusieurs patients. Le tableau 4.22 présente 5 patients présentant des volumes pulmonaires variés, qui produisent un volume courant (VT) compris dans la fourchette attendue ou proche de celle-ci, avec une légère variation attribuable aux différences de volume et de taille des poumons.

Patient	FRC (ml)	VT (ml) [400–500]
100	2026,8	418,3
575	2027,3	420,7
791	2063,4	420,6
883	1933,3	380,8
922	2887,1	531,4

TABLE 4.22 – Volume courant (VT) pour plusieurs patients (fourchette cible : 400–500 ml).

Cohérence du cycle. Les variations de déplacement et de volume sont restées stables sur les 7 cycles simulés, ce qui confirme la répétabilité. Le tableau 4.23 résume les paramètres quantitatifs pour chaque cycle respiratoire du patient 100.

Cycle	Déplacement diaphragme (mm)	VT (ml)
1	20,97	418,3
2	20,97	418,3
3	20,97	418,3
4	20,97	418,3
5	20,97	418,3
6	20,97	418,3
7	20,97	418,3

TABLE 4.23 – Paramètres quantitatifs sur 7 cycles respiratoires consécutifs patient 100.

Les résultats présentés dans le tableau 4.23 semblent identiques, car les valeurs d’amplitude (S/I, ventrale/latérale) restent inchangées tout au long de la simulation ; la fonction produit donc des résultats identiques.

Tout au long de cette simulation, nous avons mis en œuvre une approche géométrique simplifiée intégrant les principales contraintes physiologiques du mouvement respiratoire. Bien que la validation repose sur des vérifications simples plutôt que sur un cadre rigoureux, elle nous a permis de visualiser notre modèle 3D du poumon en action et de nous rapprocher d’une représentation réaliste des poumons humains.

Cela dit, certaines limites méritent d’être soulignées : l’utilisation d’estimations de déplacement au niveau de la population plutôt que de données spécifiques au patient signifie que la variabilité interindividuelle n’est pas entièrement prise en compte, et la fonction de pondération heuristique reste une approximation géométrique qui ne reflète pas la mécanique réelle de la déformation pulmonaire induite par la pression.

Les travaux futurs pourraient remédier à cela en évoluant vers une simulation par éléments finis basée sur la physique, avec des propriétés tissulaires réalistes et des données d’imagerie spécifiques au patient, ce qui permettrait d’obtenir un modèle de plus haute fidélité mieux adapté aux applications cliniques.

4.9 Conclusion

Ce chapitre a présenté les résultats obtenus à chaque étape du pipeline, depuis la segmentation pulmonaire jusqu’à la simulation respiratoire.

Le modèle U-Net 2D a atteint un Dice de 0,93 et un IoU de 0,90 sur le test interne. Ces résultats ont été confirmés sur deux ensembles externes (LUNA16 et 20 patients annotés par des radiologues), avec des performances globalement comparables aux méthodes récentes de la littérature.

Le pipeline de reconstruction 3D a permis d’obtenir des maillages *watertight* à toutes les étapes pour les quatre patients étudiés, avec une perte volumique inférieure à 5 % pour trois cas et inférieure à 8 % dans le pire des cas. La validation FEM a également montré que les huit poumons respectent les critères de qualité retenus.

Enfin, la simulation respiratoire réalisée sur cinq patients a produit des volumes courants et des déplacements du diaphragme cohérents avec les ordres de grandeur physiologiques d’une respiration calme au repos.

Conclusion générale

L’objectif de ce travail était de concevoir et de valider un pipeline entièrement automatisé pour la modélisation numérique du poumon humain, depuis l’acquisition tomodensitométrique jusqu’à la simulation biomécanique de la respiration. L’ambition était de construire une chaîne complète reposant uniquement sur des outils ouverts, sans aucune intervention manuelle.

La première contribution a consisté à constituer une base de données d’entraînement à grande échelle. Le dataset LIDC-IDRI ne contenant pas de masques pulmonaires, un pipeline de segmentation classique en bio-imagerie a été développé afin de générer automatiquement ces annotations sur les 996 volumes retenus, produisant ainsi plus de 106 000 coupes annotées, correctement réparties en ensembles d’entraînement, de validation et de test avec une séparation stricte par patient. Ce travail de préparation des données, s’est avéré déterminant pour la qualité et la généralisabilité de l’ensemble du pipeline.

La deuxième contribution porte sur la segmentation pulmonaire automatique par un réseau U-Net 2D entraîné sur cette base. Le modèle atteint un score Dice de 0,93 et un IoU de 0,90 sur l’ensemble de test interne, ces performances ont été confirmées par deux validations externes indépendantes, la LUNA16 et sur un ensemble de 20 patients annotés par des radiologues. L’analyse comparative a montré que cette approche surpasse les méthodes classiques de clustering et reste très compétitive face à des architectures bien plus complexes, soulignant que les choix d’augmentation de données, de fonction de perte et d’optimisation ont joué un rôle tout aussi déterminant que la complexité architecturale du réseau.

La troisième contribution concerne la reconstruction surfacique 3D. Appliquée à quatre patients différents, cette étape a produit des maillages topologiquement fermés (*water-tight*) à chaque étape du traitement, sans nécessiter la moindre correction manuelle. La perte volumique est restée faible, principalement due à la suppression volontaire de la trachée et des bronches principales. La décimation QEM a permis de diminuer la taille des fichiers tout en conservant une fidélité géométrique satisfaisante, avec un écart moyen inférieur à 2,5 mm.

La quatrième contribution porte sur la génération de maillages volumiques tétraédriques destinés à la simulation par éléments finis. Sur les huit poumons traités (gauche + droits), tous ont satisfait simultanément les trois critères de conformité FEM retenus : erreur volumique inférieure à 1 %, Aspect Ratios moyens proches du tétraèdre régulier et absence totale d’éléments dégénérés. Ces résultats établissent qu’il est possible de convertir des segmentations automatiques en maillages volumiques conformes, sans réparation manuelle, sur une large gamme de volumes pulmonaires allant de 1 216 mL à 5 221 mL.

Enfin, une preuve de concept de simulation respiratoire a été réalisée dans SOFA sur cinq patients sélectionnés pour leur volume pulmonaire proche de la capacité résiduelle fonctionnelle attendue. Le modèle heuristique mis en œuvre, fondé sur un couplage géométrique entre le mouvement du diaphragme et l’expansion pulmonaire, a produit des

volumes courants et des amplitudes diaphragmatiques cohérents avec les données physiologiques rapportées dans la littérature pour une respiration calme au repos.

Globalement, les objectifs initiaux ont été atteints. Une chaîne complète et automatique permet désormais de transformer des images CT en un modèle pulmonaire exploitable pour la simulation numérique, avec une robustesse démontrée sur des cas anatomiques variés.

Des perspectives d'amélioration demeurent à chaque niveau du pipeline. En segmentation, des architectures plus récentes telles que le U-Net 3D, nnU-Net ou les modèles fondés sur les Transformers devraient permettre de mieux exploiter l'information volumique et d'améliorer la généralisation sur des données plus variées. La reconstruction géométrique gagnerait à être évaluée sur un plus grand nombre de patients, incluant des morphologies pathologiques plus diversifiées. Quant à la simulation, qui constitue pour l'heure une preuve de concept, l'intégration de propriétés mécaniques tissulaires plus réalistes ainsi que l'utilisation de conditions aux limites issues de données cliniques spécifiques au patient représentent les prochaines étapes vers un modèle de haute fidélité.

À plus long terme, la combinaison de ces outils pourrait contribuer au développement de jumeaux numériques pulmonaires personnalisés, ouvrant des perspectives concrètes pour la compréhension des maladies respiratoires, l'évaluation de stratégies thérapeutiques, la planification préopératoire et la médecine de précision.

Bibliographie

- [1] Institut National du Cancer (INCa), “Les poumons - comprendre la maladie du cancer du poumon,” 2026. Consulté le 14 mai 2026.
- [2] M. Locqueville, “La respiration, le diaphragme et l’ostéopathe,” 10 2019. Mon Ostéopathe Paris.
- [3] National Cancer Institute, “Computed tomography (ct) scans and cancer,” 2026. Consulté le 15 mai 2026.
- [4] iStock, “Ct scan lung cancer - medical imaging,” 2026. Consulté le 15 mai 2026.
- [5] O. Ronneberger, P. Fischer, and T. Brox, “U-net : Convolutional networks for biomedical image segmentation,” in *MICCAI*, Springer, 2015.
- [6] Jmtrivial, “Marching cubes lookup table — original 15 cases,” 2006. Licence GPL. Wikimedia Commons.
- [7] L. Hong *et al.*, “Gan-lstm-3d : An efficient method for lung tumour 3d reconstruction enhanced by attention-based lstm,” *CAAI Transactions on Intelligence Technology*, 2023.
- [8] M. Abdullah, F. Shaukat, M. H. Zafar, S. J. Abdulkadir, and A. O. A. Ismail, “Attention-resunet and efficientsasm-unet : Unet-based frameworks for lung and nodule segmentation,” *IEEE Access*, 2026.
- [9] S. Nakazawa, T. Nagashima, N. Kawatani, P. C. Gedeon, A. K. DeSimone, H. Igai, T. Kosaka, and K. Shirabe, “Anatomy of the lung revisited by 3d-ct imaging,” *Video-Assisted Thoracic Surgery*, 2023.
- [10] B. Bordoni, S. Kaura, and D. C. Dinu, *Anatomy, Thorax, Lungs*. StatPearls Publishing, 2024.
- [11] R. Werner, J. Ehrhardt, R. Schmidt, and H. Handels, “Patient-specific finite element modeling of respiratory lung motion using 4d ct image data,” *Medical Physics*, vol. 36, no. 5, pp. 1500–1511, 2009.
- [12] K. N. S. Bains, S. Kashyap, and S. L. Lappin, “Anatomy, thorax : Diaphragm.” StatPearls Publishing, 2023. Updated 2023 Jul 24.
- [13] K. Neupane and R. T. Jamil, “Physiology, transpulmonary pressure.” StatPearls Publishing, 2023. Updated 2023 May 1.
- [14] D. N. Briganti, C. E. Choi, J. Nguyen, and C. W. Lanks, “Determinants of point-of-care ultrasound lung sliding amplitude in mechanically ventilated patients,” *The Ultrasound Journal*, vol. 15, p. 25, 2023.
- [15] J. B. West, *Respiratory Physiology : The Essentials*. Wolters Kluwer / Lippincott Williams & Wilkins, 9th ed., 2012.

- [16] Y. A. Al-Naser, “Ct instrumentation and physics,” 2023. In : StatPearls [Internet]. Treasure Island (FL) : StatPearls Publishing; 2026 Jan-. Available from : <https://www.ncbi.nlm.nih.gov/books/NBK597347/>.
- [17] National Research Council, *Mathematics and Physics of Emerging Biomedical Imaging*. National Academies Press, 1996.
- [18] Rigaku Corporation, “Basics of x-ray ct reconstruction,” *Rigaku Journal*, 2023.
- [19] OncologyMedicalPhysics.com, “Ct design and operation.”
- [20] NIMH, “Nifti-1 data format.”
- [21] Tasq.ai, “Nifti format,” 2024.
- [22] nipraxis contributors, “Three-dimensional images, nifti.”
- [23] A. Botnari, M. Kadar, and J. M. Patrascu, “Considerations on image preprocessing techniques required by deep learning models. the case of the knee mris,” *Maedica*, 2024.
- [24] D. Carmo, J. Ribeiro, S. Dertkigil, S. Appenzeller, R. Lotufo, and L. Rittner, “A systematic review of automated segmentation methods and public datasets for the lung and its lobes and findings on computed tomography images,” *Yearbook of Medical Informatics*, 2022.
- [25] Y. Xu, R. Quan, W. Xu, Y. Huang, X. Chen, and F. Liu, “Advances in medical image segmentation : A comprehensive review of traditional, deep learning and hybrid approaches,” *Bioengineering*, 2024.
- [26] X. Liu, L. Song, S. Liu, and Y. Zhang, “A review of deep-learning-based medical image segmentation methods,” *Sustainability*, 2021.
- [27] M. Cereda *et al.*, “Automatic lung segmentation and quantification of aeration in computed tomography of the chest using 3d transfer learning,” *Frontiers in Physiology*, 2021.
- [28] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
- [29] V. Nair and G. E. Hinton, “Rectified linear units improve restricted boltzmann machines,” *ICML*, 2010.
- [30] O. Oktay, J. Schlemper, L. Le Folgoc, M. Lee, M. Heinrich, K. Misawa, K. Mori, S. McDonagh, N. Y. Hammerla, B. Kainz, B. Glocker, and D. Rueckert, “Attention u-net : Learning where to look for the pancreas,” *arXiv preprint arXiv :1804.03999*, 2018.
- [31] F. Milletari, N. Navab, and S.-A. Ahmadi, “V-net : Fully convolutional neural networks for volumetric medical image segmentation,” in *Proceedings of the 4th International Conference on 3D Vision (3DV)*, 2016.
- [32] J. Chen, Y. Lu, Q. Yu, X. Luo, E. Adeli, Y. Wang, L. Lu, A. L. Yuille, and Y. Zhou, “Transunet : Transformers make strong encoders for medical image segmentation,” *arXiv preprint arXiv :2102.04306*, 2021.
- [33] S.-H. Gao, M.-M. Cheng, K. Zhao, X.-Y. Zhang, M.-H. Yang, and P. Torr, “Res2net : A new multi-scale backbone architecture,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2021.
- [34] S. Liu *et al.*, “A comprehensive survey on deep active learning in medical image analysis,” *Medical Image Analysis*, 2024.

- [35] D. Reska and M. Kretowski, “GPU-accelerated lung CT segmentation based on level sets and texture analysis,” *Scientific Reports*, vol. 14, p. 1535, 2024.
- [36] V. Fredriksen *et al.*, “Teacher-student approach for lung tumor segmentation from mixed-supervised datasets,” *PLOS ONE*, vol. 17, no. 4, p. e0266147, 2022.
- [37] G.-W. Cai *et al.*, “Semi-supervised segmentation of ILD patterns via self-training,” *Bioengineering*, vol. 10, no. 7, p. 830, 2023.
- [38] R. Jiao *et al.*, “Learning with limited annotations : A survey on deep semi-supervised learning for medical image segmentation,” *Computers in Biology and Medicine*, vol. 169, p. 107840, 2024.
- [39] A. Mansoor *et al.*, “Segmentation and image analysis of abnormal lungs at CT : Current approaches, challenges, and future trends,” *RadioGraphics*, vol. 35, no. 4, pp. 1056–1076, 2015.
- [40] S. Hu, E. A. Hoffman, and J. M. Reinhardt, “Automatic lung segmentation for accurate quantitation of volumetric x-ray ct images,” *IEEE Transactions on Medical Imaging*, 2001.
- [41] W. E. Lorensen and H. E. Cline, “Marching cubes : A high resolution 3d surface construction algorithm,” in *Proceedings of the 14th Annual Conference on Computer Graphics and Interactive Techniques (SIGGRAPH '87)*, ACM, 1987.
- [42] D. Rahmawati, R. Sarno, and C. Fatichah, “Modification rules for improving marching cubes algorithm to represent 3d point cloud curve images,” *International Journal of Intelligent Engineering and Systems*, 2024.
- [43] T. Lewiner, H. Lopes, A. W. Vieira, and G. Tavares, “Efficient implementation of marching cubes’ cases with topological guarantees,” *Journal of Graphics Tools*, 2003.
- [44] R. Grosso and D. Zint, “A parallel dual marching cubes approach to quad only surface reconstruction,” *The Visual Computer*, 2022.
- [45] R. E. Tarjan, “Efficiency of a good but not linear set union algorithm,” *Journal of the ACM*, 1975.
- [46] Y. Boykov and M.-P. Jolly, “Interactive graph cuts for optimal boundary and region segmentation of objects in n-d images,” in *Proceedings of the Eighth IEEE International Conference on Computer Vision (ICCV)*, IEEE, 2001.
- [47] Y. Zhang and C. Bajaj, “Adaptive and quality quadrilateral/hexahedral meshing from volumetric data,” *Computer Methods in Applied Mechanics and Engineering*, 2006.
- [48] National Electrical Manufacturers Association, “Digital imaging and communications in medicine (dicom) standard, part 3 : Information object definitions,” 2021. Section C.7.6.2.1.1 – Image Position and Image Orientation.
- [49] D. Rueckert, L. I. Sonoda, C. Hayes, D. L. G. Hill, M. O. Leach, and D. J. Hawkes, “Nonrigid registration using free-form deformations : Application to breast mr images,” *IEEE Transactions on Medical Imaging*, 1999.
- [50] F. Isensee, P. F. Jaeger, S. A. A. Kohl, J. Petersen, and K. H. Maier-Hein, “nnu-net : a self-configuring method for deep learning-based biomedical image segmentation,” *Nature Methods*, 2021.
- [51] V. Shapiro, “Solid modeling,” in *Handbook of Computer Aided Design*, pp. 473–518, Elsevier, 2002.

- [52] Open Cascade SAS, “Open cascade technology (occt) – overview.” Documentation technique, 2019.
- [53] R. Löhner and P. Parikh, “Generation of three-dimensional unstructured grids by the advancing-front method,” *International Journal for Numerical Methods in Fluids*, 1988.
- [54] P.-L. George, F. Hecht, and E. Saltel, “Automatic mesh generator with specified boundary,” *Computer Methods in Applied Mechanics and Engineering*, 1991.
- [55] P. J. Frey and P.-L. George, *Mesh Generation : Application to Finite Elements*. HERMES Science Publications, 2000.
- [56] H. Si, “Tetgen, a delaunay-based quality tetrahedral mesh generator,” *ACM Transactions on Mathematical Software*, 2015.
- [57] J. Ruppert, “A delaunay refinement algorithm for quality 2-dimensional mesh generation,” *Journal of Algorithms*, 1995.
- [58] J. R. Shewchuk, “What is a good linear element ? interpolation, conditioning, and quality measures,” in *Proceedings of the 11th International Meshing Roundtable*, Sandia National Laboratories, 2002.
- [59] J. R. Shewchuk, “Tetrahedral mesh generation by delaunay refinement,” in *Proceedings of the 14th Annual Symposium on Computational Geometry*, ACM, 1998.
- [60] C. Geuzaine and J.-F. Remacle, “Gmsh : A 3-d finite element mesh generator with built-in pre- and post-processing facilities,” *International Journal for Numerical Methods in Engineering*, 2009.
- [61] L. A. Freitag and C. Ollivier-Gooch, “Tetrahedral mesh improvement using swapping and smoothing,” *International Journal for Numerical Methods in Engineering*, 1997.
- [62] B. M. Klingner and J. R. Shewchuk, “Aggressive tetrahedral mesh improvement,” in *Proceedings of the 16th International Meshing Roundtable*, 2008.
- [63] J. Schöberl, “Netgen – an advancing front 2d/3d-mesh generator based on abstract rules,” *Computing and Visualization in Science*, 1997.
- [64] C. J. Stimpson, C. D. Ernst, P. M. Knupp, P. P. Pébay, and D. C. Thompson, “The verdict geometric quality library,” tech. rep., Sandia National Laboratories, 2007.
- [65] J. Eom, X. G. Xu, S. De, and C. Shi, “Predictive modeling of lung motion over the entire respiratory cycle using measured pressure-volume data, 4dct images, and finite-element analysis,” *Medical Physics*, 2010.
- [66] Sandia National Laboratories, “Cubit 16.12 user documentation : Metrics for tetrahedral elements.” Consulté en 2026.
- [67] N. Avilés-Rojas and D. E. Hurtado, “Whole-lung finite-element models for mechanical ventilation and respiratory research applications,” *Frontiers in Physiology*, 2022.
- [68] E. VanDerHorn and S. Mahadevan, “Digital twin : Generalization, characterization and implementation,” *Decision Support Systems*, 2021.
- [69] H. Khoshfekar Rudsari *et al.*, “Digital twins in healthcare : A comprehensive review and future directions,” *Frontiers in Digital Health*, 2025.
- [70] S. G. Armato III *et al.*, “Data from lidc-idri,” 2015. The Cancer Imaging Archive (TCIA).

- [71] B. van Ginneken and C. Jacobs, “Luna16 part 1/2,” 2019.
- [72] B. van Ginneken and C. Jacobs, “Luna16 part 2/2,” 2019.
- [73] J. Ma, C. Ge, Y. Wang, X. An, J. Gao, Z. Yu, M. Zhang, X. Liu, X. Deng, S. Cao, H. Wei, S. Mei, X. Yang, Z. Nie, C. Li, L. Tian, Y. Zhu, Q. Zhu, G. Dong, and J. He, “Covid-19 ct lung and infection segmentation dataset,” 2020.
- [74] National Electrical Manufacturers Association, “Digital imaging and communications in medicine (dicom) standard,” 2024.
- [75] T. D. DenOtter and J. Schubert, *Hounsfield Unit*. StatPearls Publishing, 2023.
- [76] Neuroimaging Informatics Technology Initiative, “Nifti-1 data format,” 2024.
- [77] G. J. Kemmerink, R. J. Lamers, B. J. Pellis, H. H. Kruize, and J. M. van Engelshoven, “On segmentation of lung parenchyma in quantitative computed tomography of the lung,” *Medical Physics*, 1998.
- [78] P. Soille, *Morphological Image Analysis : Principles and Applications*. Springer, 2 ed., 2003.
- [79] J. Wang and H. Guo, “Automatic approach for lung segmentation with juxta-pleural nodules from thoracic ct based on contour tracing and correction,” *Computational and Mathematical Methods in Medicine*, 2016.
- [80] R. Ge, F. Shi, Y. Chen, S. Tang, H. Zhang, X. Lou, W. Zhao, G. Coatrieux, D. Gao, S. Li, and X. Mai, “Improving anisotropy resolution of computed tomography and annotation using 3d super-resolution network,” *Biomedical Signal Processing and Control*, 2023.
- [81] T. Sarsembayeva, M. Mansurova, A. Abdildayeva, and S. Serebryakov, “Enhancing u-net segmentation accuracy through comprehensive data preprocessing,” *Journal of Imaging*, 2025.
- [82] M. Liu, J. Dong, X. Dong, H. Yu, and L. Qi, “Segmentation of lung nodule in ct images based on mask r-cnn,” in *2018 9th International Conference on Awareness Science and Technology (iCAST)*, 2018.
- [83] F. Garcea *et al.*, “Data augmentation for medical imaging : A systematic literature review,” *Computers in Biology and Medicine*, 2023.
- [84] E. Yagis *et al.*, “Effect of data leakage in brain mri classification using 2d convolutional neural networks,” *Scientific Reports*, 2021.
- [85] A. Al-Mutairi *et al.*, “Multicenter deep learning study for lung tumor subtype segmentation in ct images using swin unetr, nnu-net, and transunet,” *Journal of King Saud University - Computer and Information Sciences*, 2025.
- [86] A. Buslaev *et al.*, “Albumentations : Fast and flexible image augmentations,” *Information*, 2020.
- [87] A. Hiranman, S. Viriri, and M. Gwetu, “Lung tumor segmentation : A review of the state of the art,” *Frontiers in Computer Science*, 2024.
- [88] T. DeVries and G. W. Taylor, “Improved regularization of convolutional neural networks with cutout,” *arXiv preprint arXiv :1708.04552*, 2017.
- [89] X. Y. Zhou and G. Z. Yang, “Normalization in training u-net for 2d biomedical semantic segmentation,” *IEEE Robotics and Automation Letters*, 2019.
- [90] S. A. Taghanaki *et al.*, “Combo loss : Handling input and output imbalance in multi-organ segmentation,” *arXiv preprint arXiv :1805.02798*, 2018.

- [91] A. Galdran, G. Carneiro, and M. A. G. Ballester, “On the optimal combination of cross-entropy and soft dice losses for lesion segmentation with out-of-distribution robustness,” in *Lecture Notes in Computer Science*, Springer, 2023.
- [92] S. Abbasi, A. S. Wahd, S. Ghosh, M. Ezzelarab, M. Panicker, Y. T. Chen, J. L. Jaremko, and A. Hareendranathan, “Improved a-line and b-line detection in lung ultrasound using deep learning with boundary-aware dice loss,” *Bioengineering*, 2025.
- [93] S. Jadon, “A survey of loss functions for semantic segmentation,” in *IEEE Conference on Computational Intelligence in Bioinformatics and Computational Biology (CIBCB)*, 2020.
- [94] D. Müller, I. Soto-Rey, and F. Kramer, “Towards a guideline for evaluation metrics in medical image segmentation,” *BMC Research Notes*, 2022.
- [95] R. G. Keys, “Cubic convolution interpolation for digital image processing,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 1981.
- [96] P. Thévenaz, T. Blu, and M. Unser, “Interpolation revisited,” *IEEE Transactions on Medical Imaging*, 2000.
- [97] H. Su *et al.*, “Pixel-level image processing and interpolation methods,” 2021. Online resource.
- [98] G. De Nunzio, E. Tommasi, A. Agrusti, *et al.*, “Automatic lung segmentation in ct images with accurate handling of the hilar region,” *Journal of Digital Imaging*, 2009.
- [99] Y. Wei, G. Shen, and J. J. Li, “A fully automatic method for lung parenchyma segmentation and repairing,” *Journal of Digital Imaging*, 2012.
- [100] E. M. van Rikxoort and B. van Ginneken, “Automated segmentation of pulmonary structures in thoracic computed tomography scans : A review,” *Physics in Medicine and Biology*, 2013.
- [101] G. Taubin, “A signal processing approach to fair surface design,” in *SIGGRAPH*, 1995.
- [102] M. Garland and P. S. Heckbert, “Surface simplification using quadric error metrics,” in *SIGGRAPH*, 1997.
- [103] Y. Wei, G. Shen, and J.-j. Li, “A fully automatic method for lung parenchyma segmentation and repairing,” *Journal of Digital Imaging*, vol. 26, no. 3, pp. 483–495, 2013.
- [104] W. J. Kim, M. N. Prasad, M. S. Brown, F. Abtin, and J. G. Goldin, “Separation of left and right lungs using 3D information of sequential CT images and a guided dynamic programming algorithm,” *Journal of Applied Clinical Medical Physics*, vol. 12, no. 1, p. 3303, 2011. PMC3061932.
- [105] Y. J. Lee, M. Lee, N. Kim, J. B. Seo, and J. Y. Park, “Automatic left and right lung separation using free-formed surface fitting on volumetric CT,” *Journal of Digital Imaging*, vol. 27, no. 4, pp. 538–547, 2014.
- [106] M. W. El-Anwar, A. El-Hussiny, H. Osman, and M. A. Mobasher, “Tracheal and subglottic dimensions : A computed tomography cross section study of adult population,” *The Egyptian Journal of Otolaryngology*, 2024.
- [107] T. Akenine-Möller, E. Haines, and N. Hoffman, *Real-Time Rendering*. CRC Press, 4 ed., 2018.

- [108] D. Karimi and S. E. Salcudean, “Reducing the hausdorff distance in medical image segmentation with convolutional neural networks,” *IEEE Transactions on Medical Imaging*, 2020.
- [109] G. Podobnik and T. Vrtovec, “Understanding implementation pitfalls of distance-based metrics for image segmentation,” 2024.
- [110] V. Yeghiazaryan and I. Voiculescu, “Family of boundary overlap metrics for the evaluation of medical image segmentation,” *Journal of Medical Imaging*, 2018.
- [111] M. R. Consortium, “Metrics reloaded : Recommendations for image analysis validation,” 2022.
- [112] M. Dawson-Haggerty *et al.*, “Trimesh,” 2019. Logiciel open source.
- [113] A. A. G. Requicha, “Representations for rigid solids : Theory, methods, and systems,” *ACM Computing Surveys*, vol. 12, no. 4, pp. 437–464, 1980.
- [114] K.-J. Bathe, *Finite Element Procedures*. Prentice Hall, 1996.
- [115] M. Hershman, B. Yousefi, L. Serletti, and et al., “Impact of interobserver variability in manual segmentation of non-small cell lung cancer,” *Cancers*, vol. 13, no. 23, p. 5985, 2021.
- [116] P. Knupp, K. Kivivali, and T. Wilson, “Tetrahedral element shape optimization via the jacobian determinant and condition number,” *Sandia National Laboratories Technical Report*, 2015. SAND2015-3332C.
- [117] A. Boussuges, J. Finance, G. Chaumet, and F. Brégeon, “Diaphragmatic motion recorded by M-mode ultrasonography : limits of normality,” *ERJ Open Research*, vol. 7, no. 1, pp. 00714–2020, 2021.
- [118] A. E. Kabil, E. Sobh, M. Elsaed, H. E. Hassanin, I. H. Yousef, H. H. Eltrawy, A. M. Ewis, A. Aboseif, A. M. Albalsha, S. Elsayy, and A. R. H. Ali, “Diaphragmatic excursion by ultrasound : reference values for the normal population ; a cross-sectional study in Egypt,” *Multidisciplinary Respiratory Medicine*, vol. 17, p. 842, 2022.
- [119] A. De Groote, M. Wantier, G. Cheron, M. Estenne, and M. Paiva, “Chest wall motion during tidal breathing,” *Journal of Applied Physiology*, vol. 83, no. 5, pp. 1531–1537, 1997.
- [120] B. Bordoni, S. Purgol, A. Bizzarri, M. Modica, and B. Morabito, “Physiology, respiratory rate,” in *StatPearls*, Treasure Island (FL) : StatPearls Publishing, 2022. PMID : 30725990.
- [121] M. G. Levitsky, *Pulmonary Physiology*. New York : McGraw-Hill Education, 9th ed., 2018.
- [122] A. L. Mora Carpio and J. I. Mora, “Ventilator management,” in *StatPearls*, Treasure Island (FL) : StatPearls Publishing, 2023. PMID : 30571016.
- [123] T. E. Fernández-Pardo, M. J. Rodríguez-Nieto, M. Furío-Valverde, M. García-Arrabé, A. Mallo-Lopez, I. Mahillo-Fernández, and G. Peces-Barba Romero, “Inspiration time : the ultrasound variable necessary to study the diaphragm functionality. A cross-sectional controlled study,” *Chronic Respiratory Disease*, vol. 22, p. 23779608251337591, 2025.
- [124] F. Faure *et al.*, “SOFA : A multi-model framework for interactive physical simulation,” in *Soft Tissue Biomechanical Modeling for Computer Assisted Surgery*, 2012.
- [125] Hugging Face, “Hugging face – the ai community building the future,” 2020.

- [126] A. Paszke *et al.*, “Pytorch : An imperative style, high-performance deep learning library,” in *Advances in Neural Information Processing Systems 32*, 2019.
- [127] P. Virtanen *et al.*, “Scipy 1.0 : Fundamental algorithms for scientific computing in python,” *Nature Methods*, 2020.
- [128] C. R. Harris *et al.*, “Array programming with NumPy,” *Nature*, vol. 585, pp. 357–362, 2020.
- [129] E. Hopkins and S. Sharma, “Physiology, functional residual capacity,” *StatPearls*, Dec 2022. Updated 2022 Dec 26.
- [130] M. Pichelin, G. Caillibotte, I. Katz, and T. Martonen, “Categorization of lung morphology based on frc and height : Computer simulations of aerosol deposition,” *Aerosol Science and Technology - AEROSOL SCI TECH*, vol. 46, 01 2011.
- [131] S. Motamedi-Fakhr, R. Iles, N. Barker, J. Alexander, and B. G. Cooper, “Reference equations for tidal breathing parameters using structured light plethysmography,” *ERJ Open Research*, vol. 7, no. 2, pp. 00050–2021, 2021. PMID : 34109249.
- [132] S. Hallett Reid, F. Toro, and J. V. Ashurst, “Physiology, tidal volume,” in *StatPearls*, Treasure Island (FL) : StatPearls Publishing, 2026. Updated 2023 May 1.